netfilter + nf_conntrack + iptables

原著：pywj777

netfilter

netfilter 的核心框架图

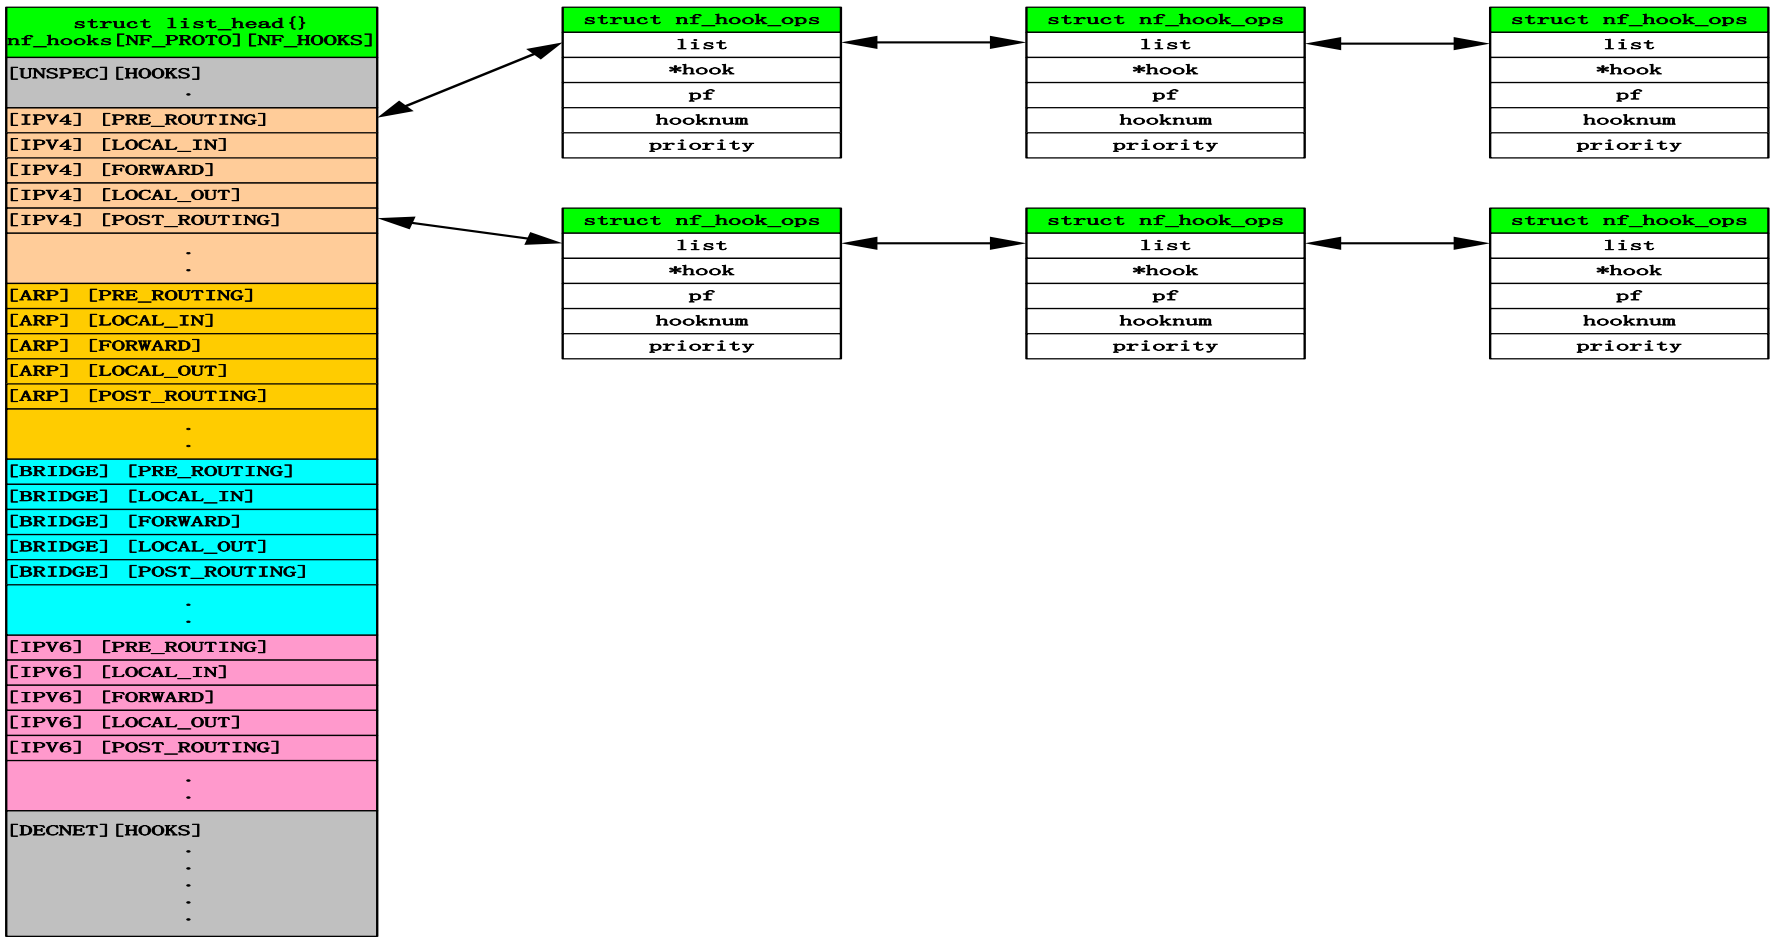

1 这个二维数组的每一项代表了一个钩子被调用的点，NF_PROTO 代表协议栈，NF_HOOK 代表协议栈中某个路径点。

2 所有模块都可以通过 nf_register_hook ()函数将一个钩子项挂入想被调用点的链表中（通过 protocol 和 hook 指定一个点）。这样，该钩子项就能够处理指定 protocol 中和指定 hook 点流经的所有数据包。

3 netfilter 在不同协议栈的不同点上(例如 arp_rcv()、ip_rcv()、ip6_rcv()、br_forward()等)放置 NF_HOOK()函数，当数据包经过了某个协议栈(NF_PROTO)的某个点(NF_HOOK)时，该协议栈会通过 NF_HOOK()函数调用对应钩子链表（nf_hooks[NF_PROTO][NF_HOOK]）中注册的每一个钩子项来处理该数据包。如上一章《IPv4 接收与转发协议栈流程图》中 IPv4 协议处理函数调用的 HOOK 点。

netfilter 提供的全局资源及相应的锁

1 nf_hooks[][]数组链表

1.1 它的定义是 struct list_head nf_hooks[NFPROTO_NUMPROTO][NF_MAX_HOOKS] __read_mostly;
用户通过 nf_register_hook()和 nf_unregister_hook()在这个全局链表中添加或删除 HOOK 点。并且在协议栈中会通过 NF_HOOK()->nf_hook_slow()来调用这些 hook 点。

1.2 读者与写者之间通过 list_add_rcu()、list_del_rcu()和 synchronize_net()、list_for_each_continue_rcu()来保证数据的一致性。
写者与写者之间通过 DEFINE_MUTEX(nf_hook_mutex)信号量来保证多个写者之间的互斥。

2 *nf_afinfo[]指针数组

2.1 它的定义是 const struct nf_afinfo *nf_afinfo[NFPROTO_NUMPROTO] __read_mostly;
用户通过 nf_register_afinfo()和 nf_unregister_afinfo 在这个指针数组中添加和删除指针项。并且通过 nf_get_afinfo()引用这些指针项。

2.2 读者与写者之间通过 rcu_assign_pointer()和 synchronize_rcu()、rcu_dereference()来保证数据一致性。
写者与写者之间通过 DEFINE_MUTEX(afinfo_mutex)信号量来保证多个写者之间的互斥。

3 nf_register_hook(struct nf_hook_ops *reg)、nf_unregister_hook(struct nf_hook_ops *reg)
用于在 nf_hooks[][]数组的指定位置挂载一个钩子项，用于在指定协议栈相应位置处理数据包。

4 nf_register_hooks(struct nf_hook_ops *reg, unsigned int n)、nf_unregister_hooks(struct nf_hook_ops *reg, unsigned int n)
用于在 nf_hooks[][]数组的指定位置挂载一组钩子项，用于在指定协议栈相应位置处理数据包。

netfilter 为每个钩子函数提供返回值

NF_DROP（0） 数据包被丢弃。即不被下一个钩子函数处理，同时也不再被协议栈处理，并释放掉该数据包。协议栈将处理下一个数据包。

NF_ACCEPT（1） 数据包允许通过。即交给下一个钩子函数处理、或交给协议栈继续处理（okfn()）。

NF_STOLEN（2） 数据包被停止处理。即不被下一个钩子函数处理，同时也不被协议栈处理，但也不释放数据包。协议栈将处理下一个数据包。

NF_QUEUE（3） 将数据包交给 nf_queue 子系统处理。即不被下一个钩子函数处理，同时也不被协议栈处理，但也不释放数据包。协议栈将处理下一个数据包。

NF_REPEAT（4） 数据包将被该返回值的钩子函数再次处理一遍。

NF_STOP（5） 数据包停止被该 HOOK 点的后续钩子函数处理，并交给协议栈继续处理（okfn()）

nf_queue 子功能

1 nf_queue 是 netfilter 的一个子功能，当某个钩子函数的返回值 NF_QUEUE 时，netfilter 就会调用 nf_queue()函数将数据包交给 nf_queue 子功能进行处理。

2 nf_queue 的功能，就是调用对该协议数据包感兴趣的函数处理该数据包。然后由该函数决定该数据包的后续处理。

3 nf_queue 提供的 API

3.1 nf_register_queue_handler(u_int8_t pf, const struct nf_queue_handler *qh) 注册一个 nf_queue_handler 项。参数 pf 与 netfilter 的 NF_PROTO 相对应，表示协议栈值。参数 qh 是用来处理 pf 指定协议栈中的数据包。该函数就是将 qh 项挂载到 queue_handler[NFPROTO_NUMPROTO]指针数组中，位置由 pf 指定。

3.2 nf_unregister_queue_handler(u_int8_t pf, const struct nf_queue_handler *qh) 注销一个 nf_queue_handler 项。该项由参数 pf 和 qh 指定。

3.3 nf_unregister_queue_handlers(const struct nf_queue_handler *qh) 注销一个 nf_queue_handler 项。该项由参数 qh 指定。

3.4 nf_queue(struct sk_buff *skb, u_int8_t pf, . . .) 由 netfilter 调用，当钩子函数返回 NF_QUEUE 结果时，netfilter 将数据包交给该函数进行处理。nf_queue()首先根据参数信息，构建一个 nf_queue_entry 结构数据（它包含 skb、输入设备、输出设备、HOOK 点、下一个协议栈处理函数等信息）。其次根据参数 pf 值（该数据包所在的协议栈）在 queue_handler[NFPROTO_NUMPROTO]指针数组中找到对应的 nf_queue_handler 项（通过 nf_register_queue_handler()函数注册的）。最后将构建好的 nf_queue_entry 结构数据交给该注册项指定的函数进行处理。

3.5 nf_reinject(struct nf_queue_entry *entry, unsigned int verdict) 用于对 entry 中数据包做进一步处理。参数 entry 是上面 nf_queue()构建的数据（它被传递给注册项做进一步处理），参数 verdict 决定了对该 entry 中数据包如何处理。

4 ip_queue 利用了 nf_queue 子功能将数据包传递给应用层处理

4.1 它调用 nf_register_queue_handler(NFPROTO_IPV4, &nfqh)注册一个 nf_queue_handler 项 nfqh，用来处理 IPV4 协议栈中的数据包。

4.2 当 IPV4 协议栈的某个钩子函数返回 NF_QUEUE 结果，netfilter 将调用 nf_queue()将该数据包交给之前注册的 nfqh 项处理。

4.3 nfqh 指定的函数是 ipq_enqueue_packet()，它将数据包通过 netlink 接口传递给应用层处理。（仅仅是将数据包挂到对应 socket 队列中，然后返回继续处理下一个数据包）

4.4 当用户处理完数据包并通过 netlink 接口发送对该数据包的处理结果，ip_queue 会调用 nf_reinject()按照用户指定的结果对数据包进行处理。

nf_log 子功能

5 nf_log 是 netfilter 的一个子功能，它提供了一个调用接口函数 nf_log_packet(pf, ...)，它主要调用 pf 协议指定的函数来记录日志。

6 nf_log 提供的 API

6.1 nf_log_register(u_int8_t pf, struct nf_logger *logger) 注册一个 nf_logger 项。参数 pf 与 netfilter 的 NF_PROTO 相对应，表示协议栈值。参数 logger 是用来处理 pf 指定协议栈中的记录信息。该函数就是将 logger 项挂载到*nf_loggers[NFPROTO_NUMPROTO]指针数组中，位置由 pf 指定。

6.2 nf_log_unregister(struct nf_logger *logger) 注销一个 nf_logger 项。

6.3 nf_unregister_queue_handlers(const struct nf_queue_handler *qh) 注销一个 nf_queue_handler 项。该项由参数 qh 指定。

6.4 nf_log_packet(pf, ...) 该函数可被协议栈中任何函数调用，用于记录日志信息。它主要调用 pf 协议指定的注册函数来记录日志。

7 nfnetlink_log 在 nf_log 子系统中注册对应协议的日志记录函数来记录日志，这些函数通过 nfnetlink 接口将日志传递给应用层。

nfnetlink 通信接口

1 nfnetlink 是建立在 netlink 基础上的一个与应用层进行通信的接口。它采用了 netlink attributes 接口，该接口使用 TLV<Type, Length, Value>（类型，长度，值）三元组来描述在传输中每一个数据单元，保证了发送方和接收方都以同样的方式来解释传输的数据。这样该接口就可以传输任何数据了。

2 nfnetlink 利用 netlink 接口创建一个类型为 NETLINK_NETFILTER 的内核 socket 接口。它接收应用层传输数据的接口是 nfnetlink_rcv()，nfnetlink_rcv()根据 nlmsghdr->nlmsg_type 值决定交给某个子系统处理。

3 nfnetlink 提供的 API

3.1 nfnetlink_subsys_register(const struct nfnetlink_subsystem *n) 在 nfnetlink 上注册一个子系统，该子系统被注册到 subsys_table[]数组中，位置由 n->subsys_id 指定。

3.2 nfnetlink_subsys_unregister(const struct nfnetlink_subsystem *n) 在 nfnetlink 上注销一个子系统。

3.3 nfnetlink_get_subsys(u_int16_t type) 获得一个由 type 指定的子系统，type 值就是 nlmsghdr->nlmsg_type。

3.4 nfnetlink_find_client(u_int16_t type, const struct nfnetlink_subsystem *ss) 获得 ss 指定的子系统中的某个功能，有 type 指定，type 值就是 nlmsghdr->nlmsg_type。

3.5 nfnetlink_unicast(struct sk_buff *skb, struct net *net, u_int32_t pid, int flags) 向应用层发送信息，它其实就是直接调用 netlink 的发送函数 netlink_unicast()。

3.6 nfnetlink_send(struct sk_buff *skb, struct net *net, u32 pid, unsigned group, int echo, gfp_t flags) 向应用层发送一个通知，它其实就是直接调用 netlink 的通知函数 nlmsg_notify()。

4 nfnetlink_queue 模块就是在 nfnetlink 接口上注册的一个子系统，功能类似于 ip_queue，但它使用 nfnetlink 接口与应用层进行通信，并且使用 netlink attributes 接口对数据进行封装和解析。它同时接收应用层的命令，用于在 nf_queue 子功能中注册对应协议的处理项。

5 nfnetlink_log 模块就是在 nfnetlink 接口上注册的一个子系统，它使用 nfnetlink 接口与应用层进行通信，并且使用 netlink attributes 接口对数据进行封装和解析。它同时接收应用层的命令，用于在 nf_log 子功能中注册对应协议的处理项。

netfilter 相关功能在内核中文件分布图

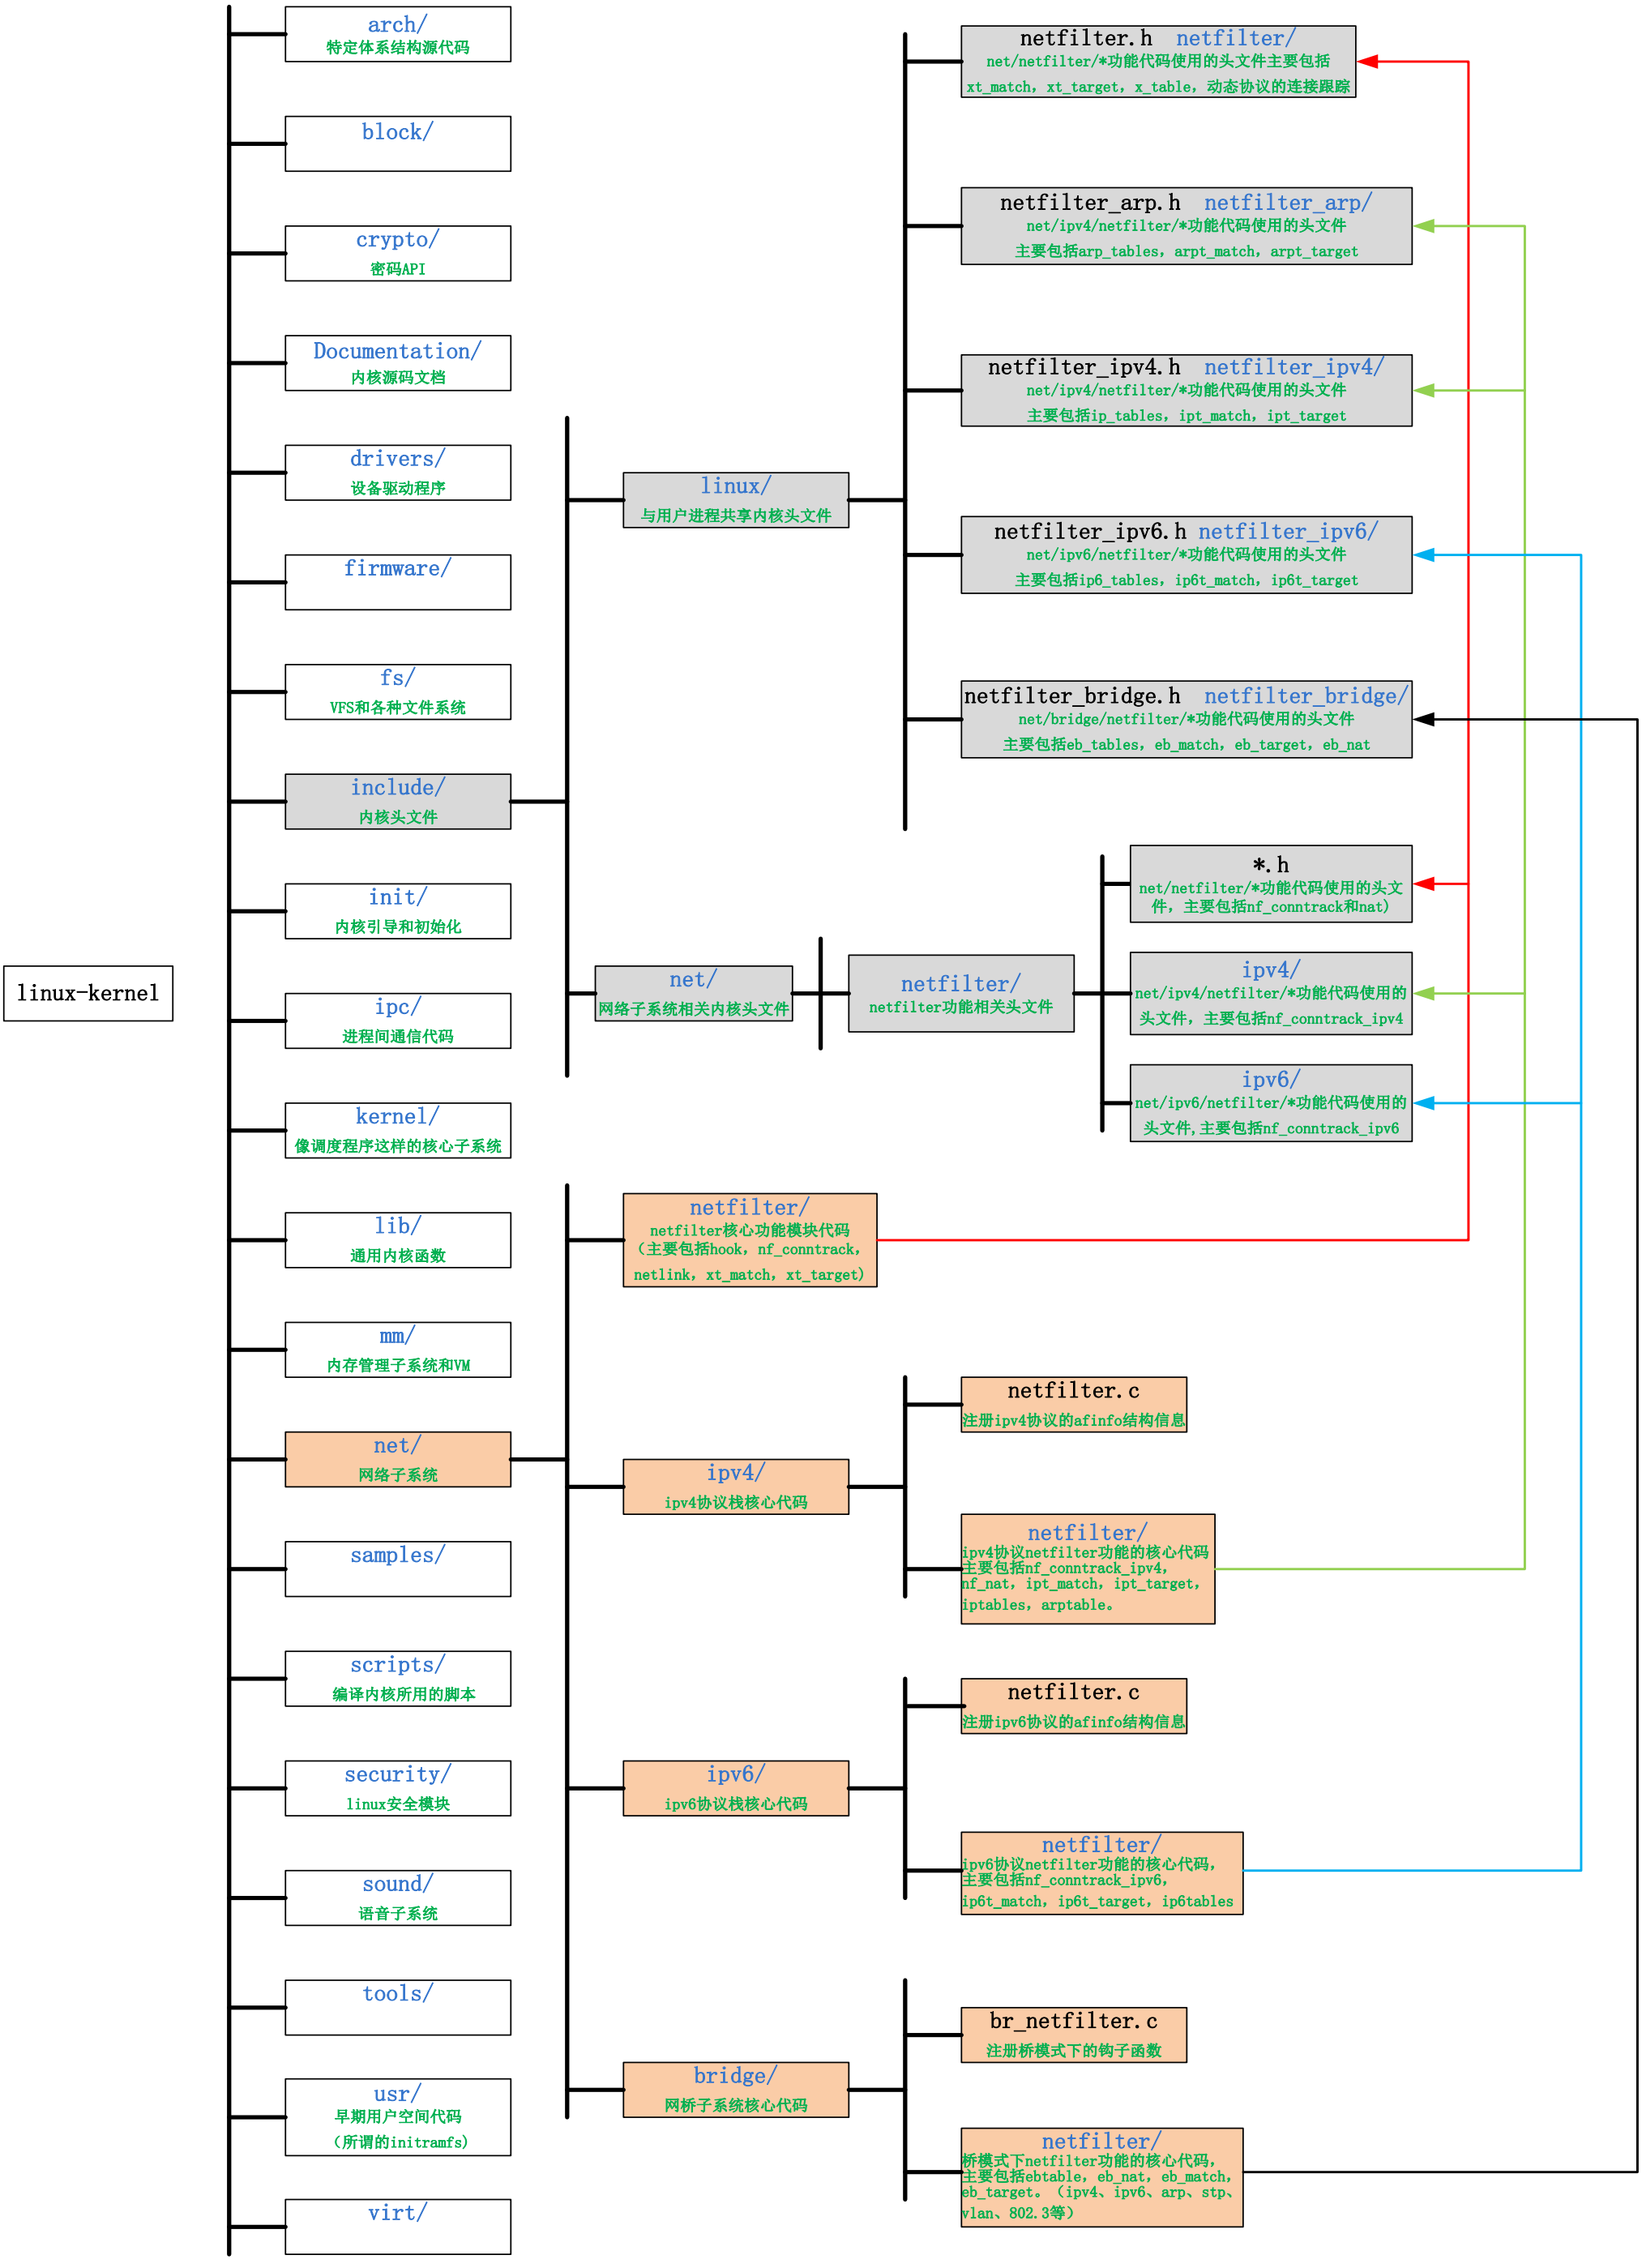

基于 netfilter 的链接跟踪、NAT、包过滤规则、NF-hipac、nf_queue

在 IPv4 协议栈中 netfilter 挂的 HOOK 函数

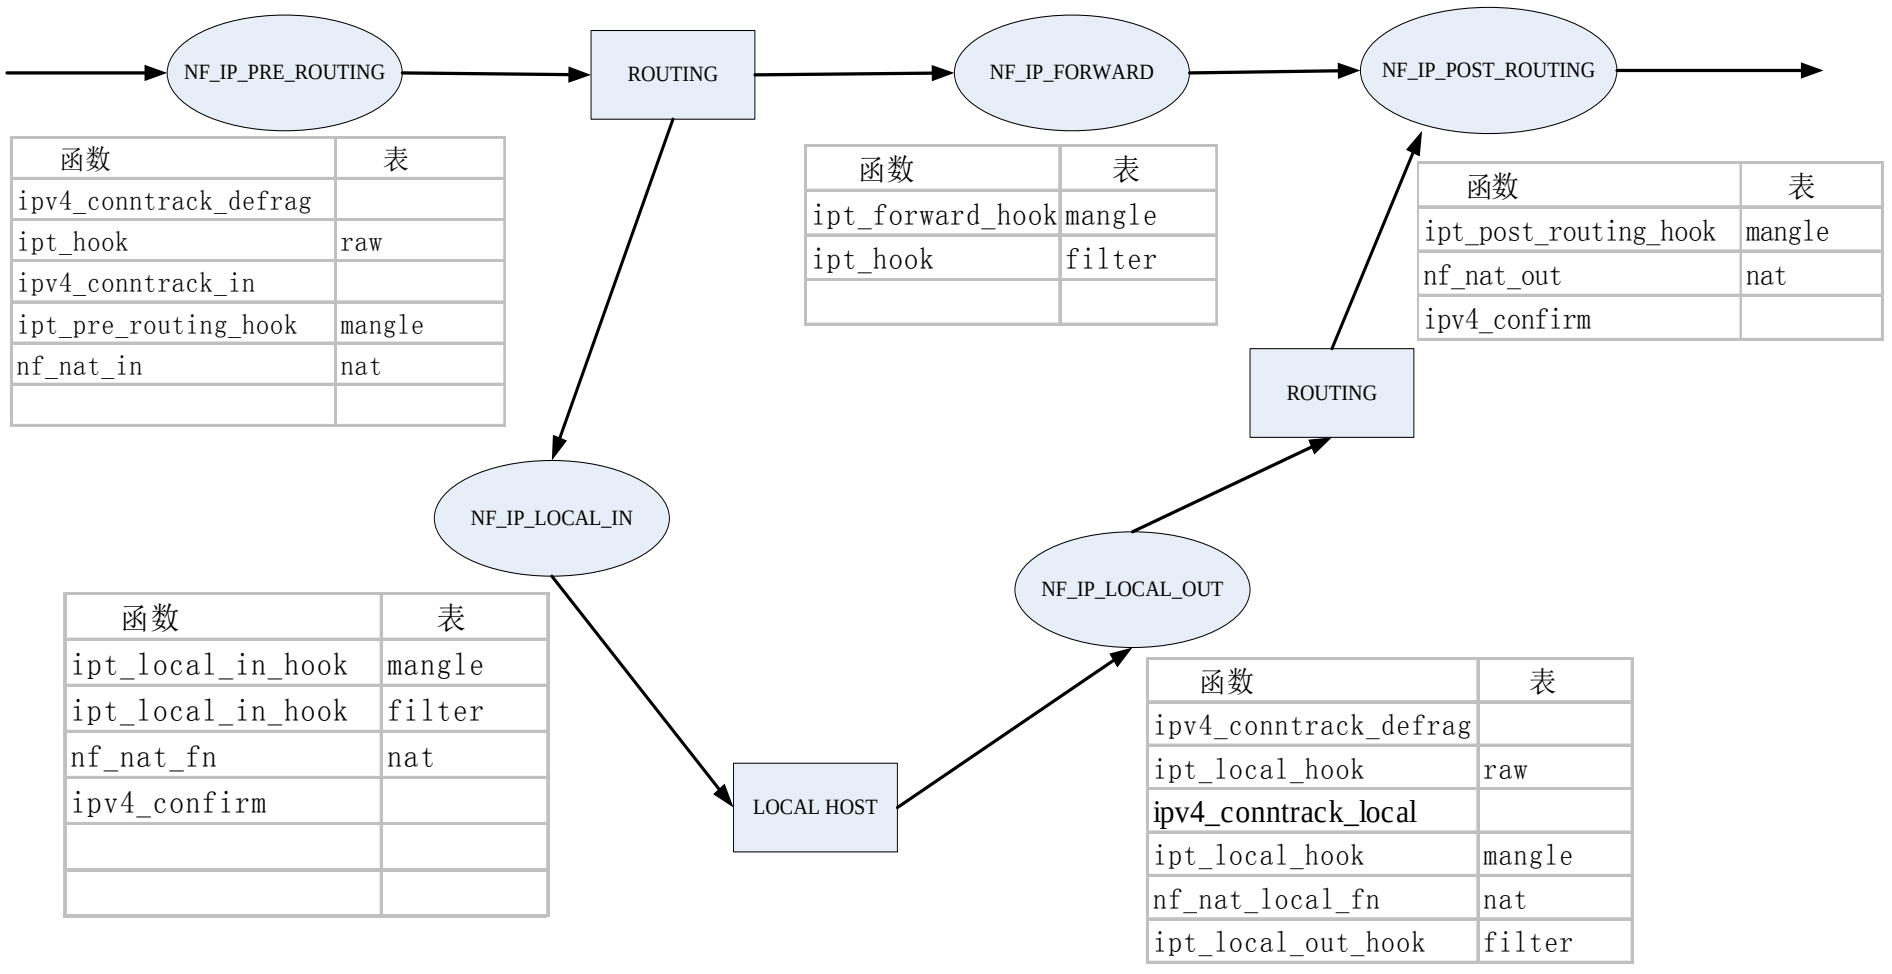

函数	表
ipv4_conntrack_defrag	
ipt_hook	raw
ipv4_conntrack_in	
ipt_pre_routing_hook	mangle
nf_nat_in	nat

函数	表
ipt_forward_hook	mangle
ipt_hook	filter

函数	表
ipt_post_routing_hook	mangle
nf_nat_out	nat
ipv4_confirm	

函数	表
ipt_local_in_hook	mangle
ipt_local_in_hook	filter
nf_nat_fn	nat
ipv4_confirm	

函数	表
ipv4_conntrack_defrag	
ipt_local_hook	raw
ipv4_conntrack_local	
ipt_local_hook	mangle
nf_nat_local_fn	nat
ipt_local_out_hook	filter

连接跟踪 nf_conntrack

nf_conntrack 提供的资源

1　与连接跟踪相关的全局资源放在了 net->ct 网络命名空间中，它的类型是 struct netns_ct。

```
struct netns_ct {
    atomic_t                count;                  /*  当前连接表中连接的个数  */
    unsigned int            expect_count;           /* nf_conntrack_helper 创建的期待子连接 nf_conntrack_expect 项的个数  */
    unsigned int            htable_size;            /*  存储连接（nf_conn）的 HASH 桶的大小  */
    struct kmem_cache       *nf_conntrack_cachep;   /*  指向用于分配 nf_conn 结构而建立的高速缓存（slab）对象  */
    struct hlist_nulls_head *hash;                  /*  指向存储连接（nf_conn）的 HASH 桶  */
    struct hlist_head       *expect_hash;           /*  指向存储期待子连接 nf_conntrack_expect 项的 HASH 桶  */
    struct hlist_nulls_head unconfirmed;            /*  对于一个链接的第一个包，在 init_conntrack()函数中会将该包 original 方向的 tuple 结构挂入该链，这
                                                        是因为在此时还不确定该链接会不会被后续的规则过滤掉，如果被过滤掉就没有必要挂入正式的链接
                                                        跟踪表。在 ipv4_confirm()函数中，会将 unconfirmed 链中的 tuple 拆掉，然后再将 original 方向和 reply
                                                        方向的 tuple 挂入到正式的链接跟踪表中，即 init_net.ct.hash 中，这是因为到达 ipv4_confirm()函数时，
                                                        应经在钩子 NF_IP_POST_ROUTING 处了，已经通过了前面的 filter 表。
                                                        通过 cat   /proc/net/nf_conntrack 显示连接，是不会显示该链中的连接的。但总的连接个数（net->ct.count）
                                                        包含该链中的连接。
                                                        当注销 l3proto、l4proto、helper、nat 等资源或在应用层删除所有连接（conntrack -F）时，除了释放
                                                        confirmed 连接（在 net->ct.hash 中的连接）的资源，还要释放 unconfirmed 连接（即在该链中的连接）
                                                        的资源。*/
    struct hlist_nulls_head dying;                  /*  释放连接时，通告 DESTROY 事件失败的 ct 被放入该链中，并设置定时器，等待下次通告。
                                                        通过 cat   /proc/net/nf_conntrack 显示连接，是不会显示该链中的连接的。但总的连接个数（net->ct.count）
                                                        包含该链中的连接。
                                                        当注销连接跟踪模块时，同时要清除正再等待被释放的连接（即该链中的连接）*/
    struct ip_conntrack_stat __percpu *stat;        /*  连接跟踪过程中的一些状态统计，每个 CPU 一项，目的是为了减少锁  */
    int                     sysctl_events;          /*  是否开启连接事件通告功能  */
    unsigned int            sysctl_events_retry_timeout; /*  通告失败后，重试通告的间隔时间，单位是秒  */
    int                     sysctl_acct;            /*  是否开启每个连接数据包统计功能  */
    int                     sysctl_checksum;
    unsigned int            sysctl_log_invalid;     /* Log invalid packets */
#ifdef CONFIG_SYSCTL
    struct ctl_table_header *sysctl_header;
    struct ctl_table_header *acct_sysctl_header;
    struct ctl_table_header *event_sysctl_header;
#endif
    int                     hash_vmalloc;           /*  存储连接（nf_conn）的 HASH 桶是否是使用 vmalloc()进行分配的  */
    int                     expect_vmalloc;         /*  存储期待子连接 nf_conntrack_expect 项的 HASH 桶是否是使用 vmalloc()进行分配的  */
    char                    *slabname;              /*  用于分配 nf_conn 结构而建立的高速缓存（slab）对象的名字  */
};
```

2　连接跟踪通过 nf_conn 结构进行描述

```
struct nf_conn {
    /* Usage count in here is 1 for hash table/destruct timer, 1 per skb, plus 1 for any connection(s) we are `master' for */
    struct    nf_conntrack    ct_general;                          /*  连接跟踪的引用计数  */
    spinlock_t    lock;
    /* These are my tuples; original and reply */
    struct    nf_conntrack_tuple_hash    tuplehash[IP_CT_DIR_MAX];/* Connection tracking(链接跟踪)用来跟踪、记录每个链接的信息(目前仅支持 IP 协议的连接跟踪)。
                                                                   每个链接由“tuple”来唯一标识，这里的“tuple”对不同的协议会有不同的含义，例如对 tcp,udp
                                                                   来说就是五元组: (源 IP，源端口，目的 IP，目的端口，协议号)，对 ICMP 协议来说是: (源 IP，目
                                                                   的 IP, id, type, code)，其中 id,type 与 code 都是 icmp 协议的信息。链接跟踪是防火墙实现状态检
                                                                   测的基础，很多功能都需要借助链接跟踪才能实现，例如 NAT、快速转发、等等。*/
    /* Have we seen traffic both ways yet? (bitset) */
    unsigned long    status;                                       /*  可以设置由 enum ip_conntrack_status 中描述的状态  */
    /* If we were expected by an expectation, this will be it */
    struct    nf_conn    *master;                                  /*  如果该连接是某个连接的子连接，则 master 指向它的主连接  */
    /* Timer function; drops refcnt when it goes off. */
    struct    timer_list    timeout;
#if defined(CONFIG_NF_CONNTRACK_MARK)
    u_int32_t    mark;
#endif
#ifdef CONFIG_NF_CONNTRACK_SECMARK
    u_int32_t secmark;
#endif
    /* Storage reserved for other modules: */
    union nf_conntrack_proto proto;                                /*  用于保存不同协议的私有数据  */
    /* Extensions */
    struct nf_ct_ext *ext;                                         /*  用于扩展结构  */
```

```
#ifdef CONFIG_NET_NS
        struct net *ct_net;
#endif
};
```

3 连接跟踪可以设置的标志，即在 ct->status 中可以设置的标志，由下面的 enum ip_conntrack_status 描述，它们可以共存。这些标志设置后就不会再被清除。

```
enum ip_conntrack_status {
    /* It's an expected connection: bit 0 set.  This bit never changed */
    IPS_EXPECTED_BIT = 0,              /* 表示该连接是个子连接 */
    /* We've seen packets both ways: bit 1 set.  Can be set, not unset. */
    IPS_SEEN_REPLY_BIT = 1,            /* 表示该连接上双方向上都有数据包了 */
    /* Conntrack should never be early-expired. */
    IPS_ASSURED_BIT = 2,               /* TCP：在三次握手建立完连接后即设定该标志。
                                          UDP：如果在该连接上的两个方向都有数据包通过，则再有数据包在该连接上通过时，就设定该标志。
                                          ICMP：不设置该标志 */
    /* Connection is confirmed: originating packet has left box */
    IPS_CONFIRMED_BIT = 3,             /* 表示该连接已被添加到 net->ct.hash 表中 */
    /* Connection needs src nat in orig dir.  This bit never changed. */
    IPS_SRC_NAT_BIT = 4,               /*在 POSTROUTING 处，当替换 reply tuple 完成时，设置该标记 */
    /* Connection needs dst nat in orig dir.  This bit never changed. */
    IPS_DST_NAT_BIT = 5,               /* 在 PREROUTING 处，当替换 reply tuple 完成时，设置该标记 */
    /* Both together. */
    IPS_NAT_MASK = (IPS_DST_NAT | IPS_SRC_NAT),
    /* Connection needs TCP sequence adjusted. */
    IPS_SEQ_ADJUST_BIT = 6,
    /* NAT initialization bits. */
    IPS_SRC_NAT_DONE_BIT = 7,          /* 在 POSTROUTING 处，已被 SNAT 处理，并被加入到 bysource 链中，设置该标记 */
    IPS_DST_NAT_DONE_BIT = 8,          /* 在 PREROUTING 处，已被 DNAT 处理，并被加入到 bysource 链中，设置该标记 */
    /* Both together */
    IPS_NAT_DONE_MASK = (IPS_DST_NAT_DONE | IPS_SRC_NAT_DONE),
    /* Connection is dying (removed from lists), can not be unset. */
    IPS_DYING_BIT = 9,                 /* 表示该连接正在被释放，内核通过该标志保证正在被释放的 ct 不会被其它地方再次引用。有了这个标志，当某个连接要被删
                                          除时，即使它还在 net->ct.hash 中，也不会再次被引用。（但好像还是没有太大作用？？？？）*/
    /* Connection has fixed timeout. */
    IPS_FIXED_TIMEOUT_BIT = 10,        /* 固定连接超时时间，这将不根据状态修改连接超时时间。通过函数 nf_ct_refresh_acct()修改超时时间时检查该标志。但该标
                                          志在哪设置的？？？？ */
    /* Conntrack is a template */
    IPS_TEMPLATE_BIT = 11,             /* 由 CT target 进行设置（这个 target 只能用在 raw 表中，用于为数据包构建指定 ct，并打上该标志），用于表明这个 ct 是由 CT
                                          target 创建的 */
};
```

4 连接跟踪对数据包在用户空间可以表现的状态，由下面 enum ip_conntrack_info 表示，被设置在 skb->nfctinfo 中。

```
enum ip_conntrack_info {
    /* Part of an established connection (either direction). */
    IP_CT_ESTABLISHED（0）,                  /* 表示这个数据包对应的连接在两个方向都有数据包通过，并且这是 ORIGINAL 初始方向数据包（无论是 TCP、UDP、
                                                ICMP 数据包，只要在该连接的两个方向上已有数据包通过，就会将该连接设置为 IP_CT_ESTABLISHED 状态。不
                                                会根据协议中的标志位进行判断，例如 TCP 的 SYN 等）。但它表示不了这是第几个数据包，也说明不了这个 CT
                                                是否是子连接。*/
    /* Like NEW, but related to an existing connection, or ICMP error (in either direction). */
    IP_CT_RELATED（1）,                      /* 表示这个数据包对应的连接还没有 REPLY 方向数据包，当前数据包是 ORIGINAL 方向数据包。并且这个连接关
                                                联一个已有的连接，是该已有连接的子连接，（即 status 标志中已经设置了 IPS_EXPECTED 标志，该标志在
                                                init_conntrack()函数中设置）。但无法判断是第几个数据包（不一定是第一个）*/
    /* Started a new connection to track (only IP_CT_DIR_ORIGINAL); may be a retransmission. */
    IP_CT_NEW（2）,                          /* 表示这个数据包对应的连接还没有 REPLY 方向数据包，当前数据包是 ORIGINAL 方向数据包。该连接不是子连
                                                接，但无法判断是第几个数据包（不一定是第一个）*/
    /* >= this indicates reply direction */
    IP_CT_IS_REPLY（3）,                     /* 这个状态一般不单独使用，通常以下面两种方式使用 */
    IP_CT_ESTABLISHED + IP_CT_IS_REPLY（3）, /* 表示这个数据包对应的连接在两个方向都有数据包通过，并且这是 REPLY 应答方向数据包。但它表示不了这是
                                                第几个数据包，也说明不了这个 CT 是否是子连接。*/
    IP_CT_RELATED + IP_CT_IS_REPLY（4）,     /* 这个状态仅在 nf_conntrack_attach()函数中设置，用于本机返回 REJECT，例如返回一个 ICMP 目的不可达报文，
                                                或返回一个 reset 报文。它表示不了这是第几个数据包。*/
    /* Number of distinct IP_CT types (no NEW in reply dirn). */
    IP_CT_NUMBER = IP_CT_IS_REPLY * 2 - 1（5）  /* 可表示状态的总数 */
};
```

5 连接跟踪里使用了两个全局 spin_lock 锁（nf_conntrack_lock、nf_nat_lock）和一个局部 spin_lock 锁（ct->lock）

5.1 nf_conntrack_lock

5.1.1 ct 从 ct_hash[]表中添加/删除时使用该锁，在 ct_hash 表中查找 ct 时使用 RCU 锁。

5.1.2 ct 从 unconfirmed 链上添加/删除时使用该锁，在该 unconfirmed 链上的 ct 不需要查找。

5.1.3 ct 从 dying 链上添加/删除时使用该锁，在该 dying 链上的 ct 不需要查找。

5.1.4 ct 通过 expect 与 mct 关联时使用该锁，目的是防止 mct 被移动或删除。

5.1.5 expect 从 expect_hash[]表中添加/删除/查找时使用该锁。因为 expect 与 ct 紧密关联，所以共用一把锁。expect 仅在初试化连接时被查找。

5.2 nf_nat_lock

5.2.1 ct 从 nat_bysource[]中添加/删除/查找时使用该锁。nat_bysource[]在初始化连接时被使用。

5.2.2 注册/注销 nf_nat_protos 协议时使用该锁。

5.3 ct->lock

5.3.1 修改某个 ct 的数据时使用该 ct 自己的锁。

6 扩展连接跟踪结构（nf_conn）利用 nf_conntrack_extend.c 文件中的 nf_ct_extend_register(struct nf_ct_ext_type *type)和 nf_ct_extend_unregister(struct nf_ct_ext_type *type)进行扩展，并修改连接跟踪相应代码来利用这部分扩展功能。

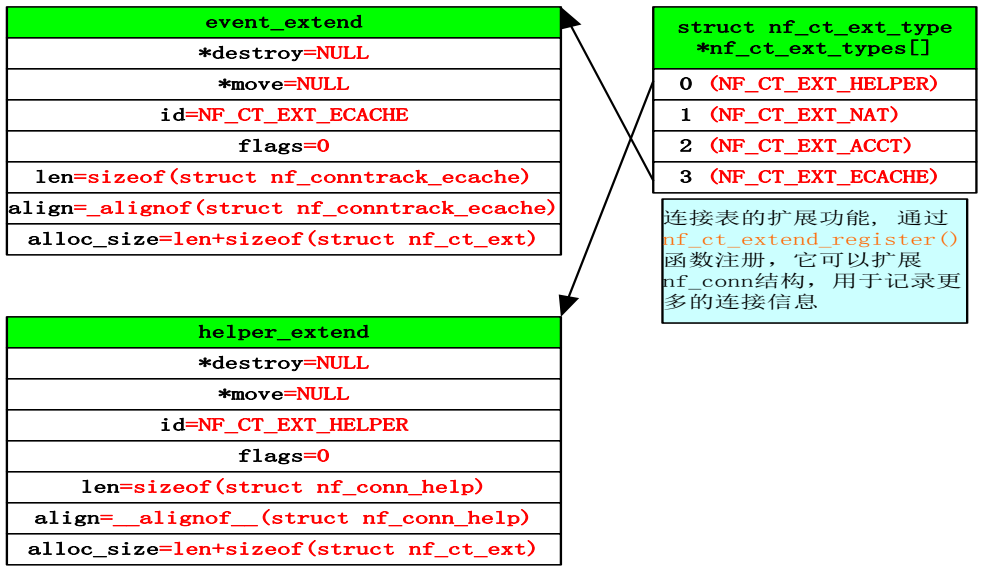

7 处理一个连接的子连接协议，利用 nf_conntrack_helper.c 文件中的 nf_conntrack_helper_register(struct nf_conntrack_helper *me)来注册 nf_conntrack_helper 结构，和 nf_conntrack_expect.c 文件中的 nf_ct_expect_related_report(struct nf_conntrack_expect *expect, u32 pid, int report)来注册 nf_conntrack_expect 结构。

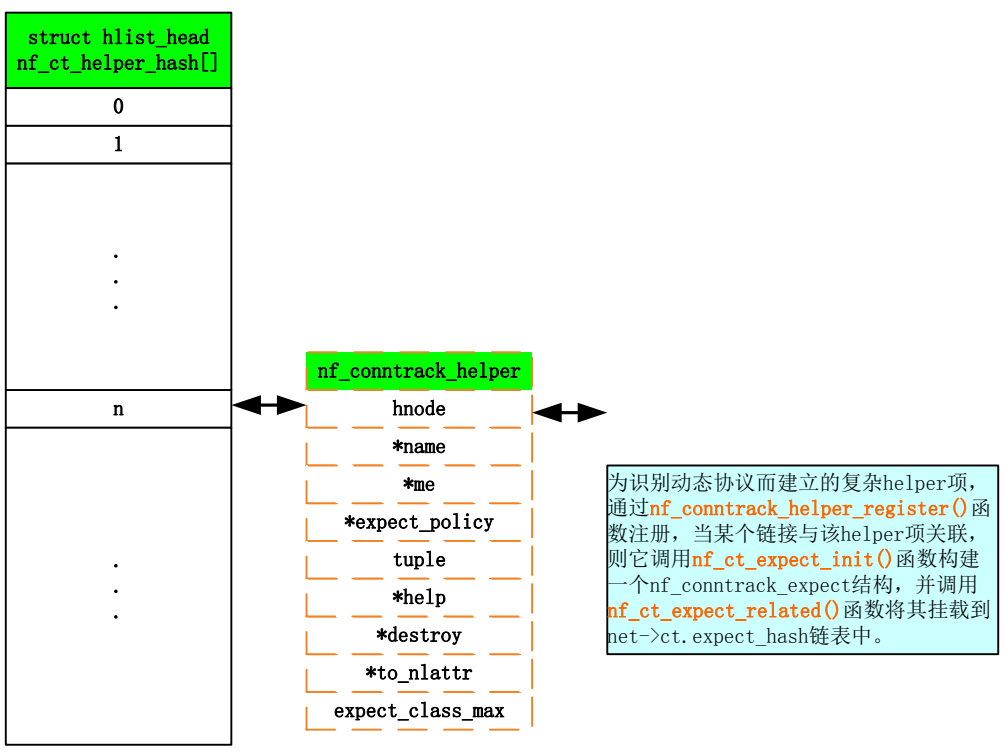

8 三层协议（IPv4/IPv6）利用 nf_conntrack_proto.c 文件中的 nf_conntrack_l3proto_register(struct nf_conntrack_l3proto *proto)和 nf_conntrack_l3proto_unregister(struct nf_conntrack_l3proto *proto)在 nf_ct_l3protos[]数组中注册自己的三层协议处理函数。

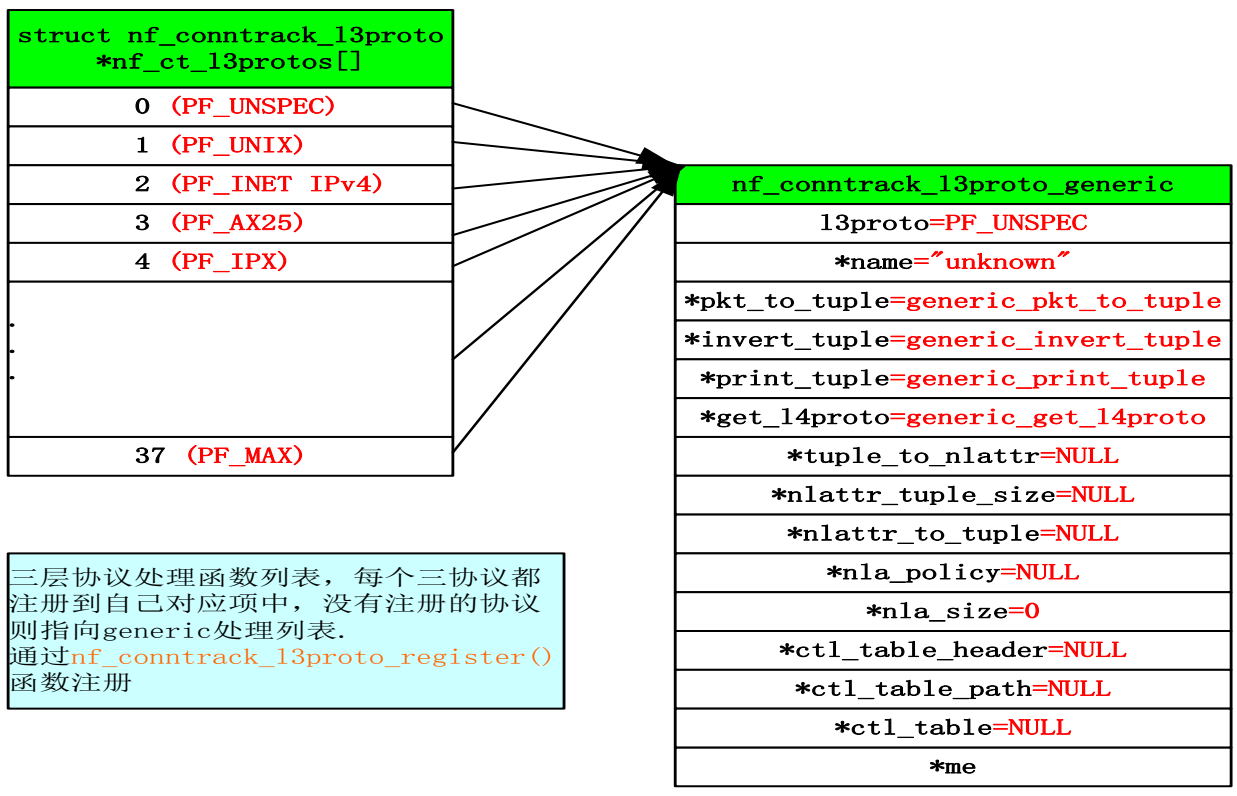

9　四层协议（TCP/UDP）利用 nf_conntrack_proto.c 文件中的 nf_conntrack_l4proto_register(struct nf_conntrack_l4proto *l4proto)和 nf_conntrack_l4proto_unregister(struct nf_conntrack_l4proto *l4proto)在 nf_ct_protos[]数组中注册自己的四层协议处理函数。

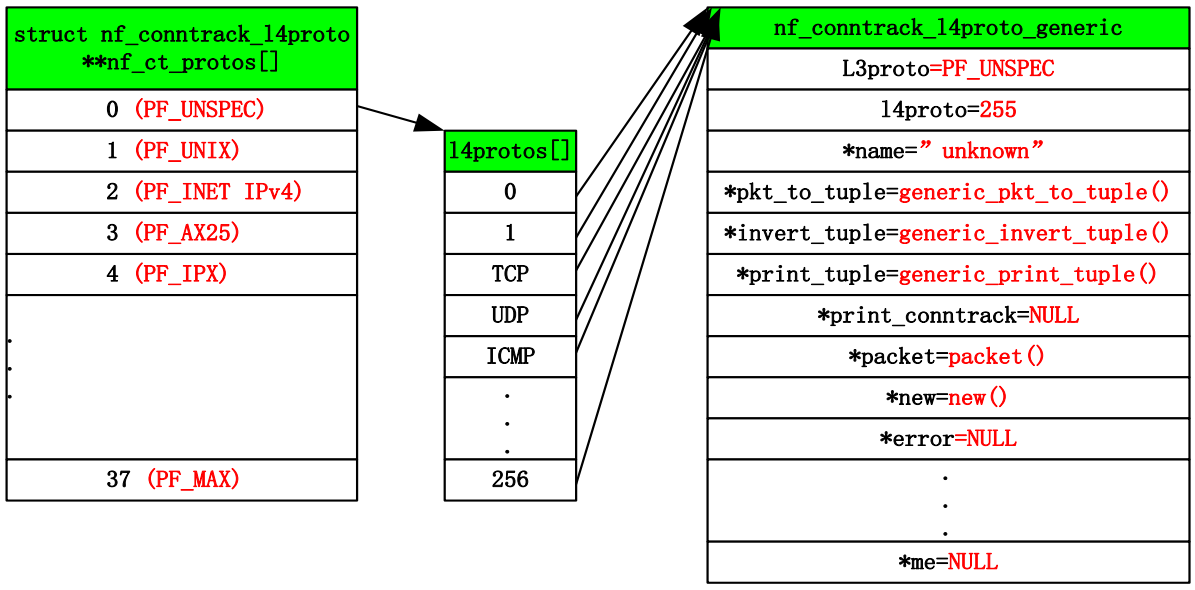

四层协议处理函数列表,四层协议与三层协议相关联。每个四协议都注册到自己对应项中，没有注册的协议则指向generic处理列表
通过nf_conntrack_l4proto_register()函数注册

10　建立连接跟踪结构（nf_conn）利用 nf_conntrack_core.c 文件中的 nf_conntrack_in()函数进行构建的。nf_conntrack_core.c 文件中还包括其它相应的处理函数。

nf_conntrack 的初始化

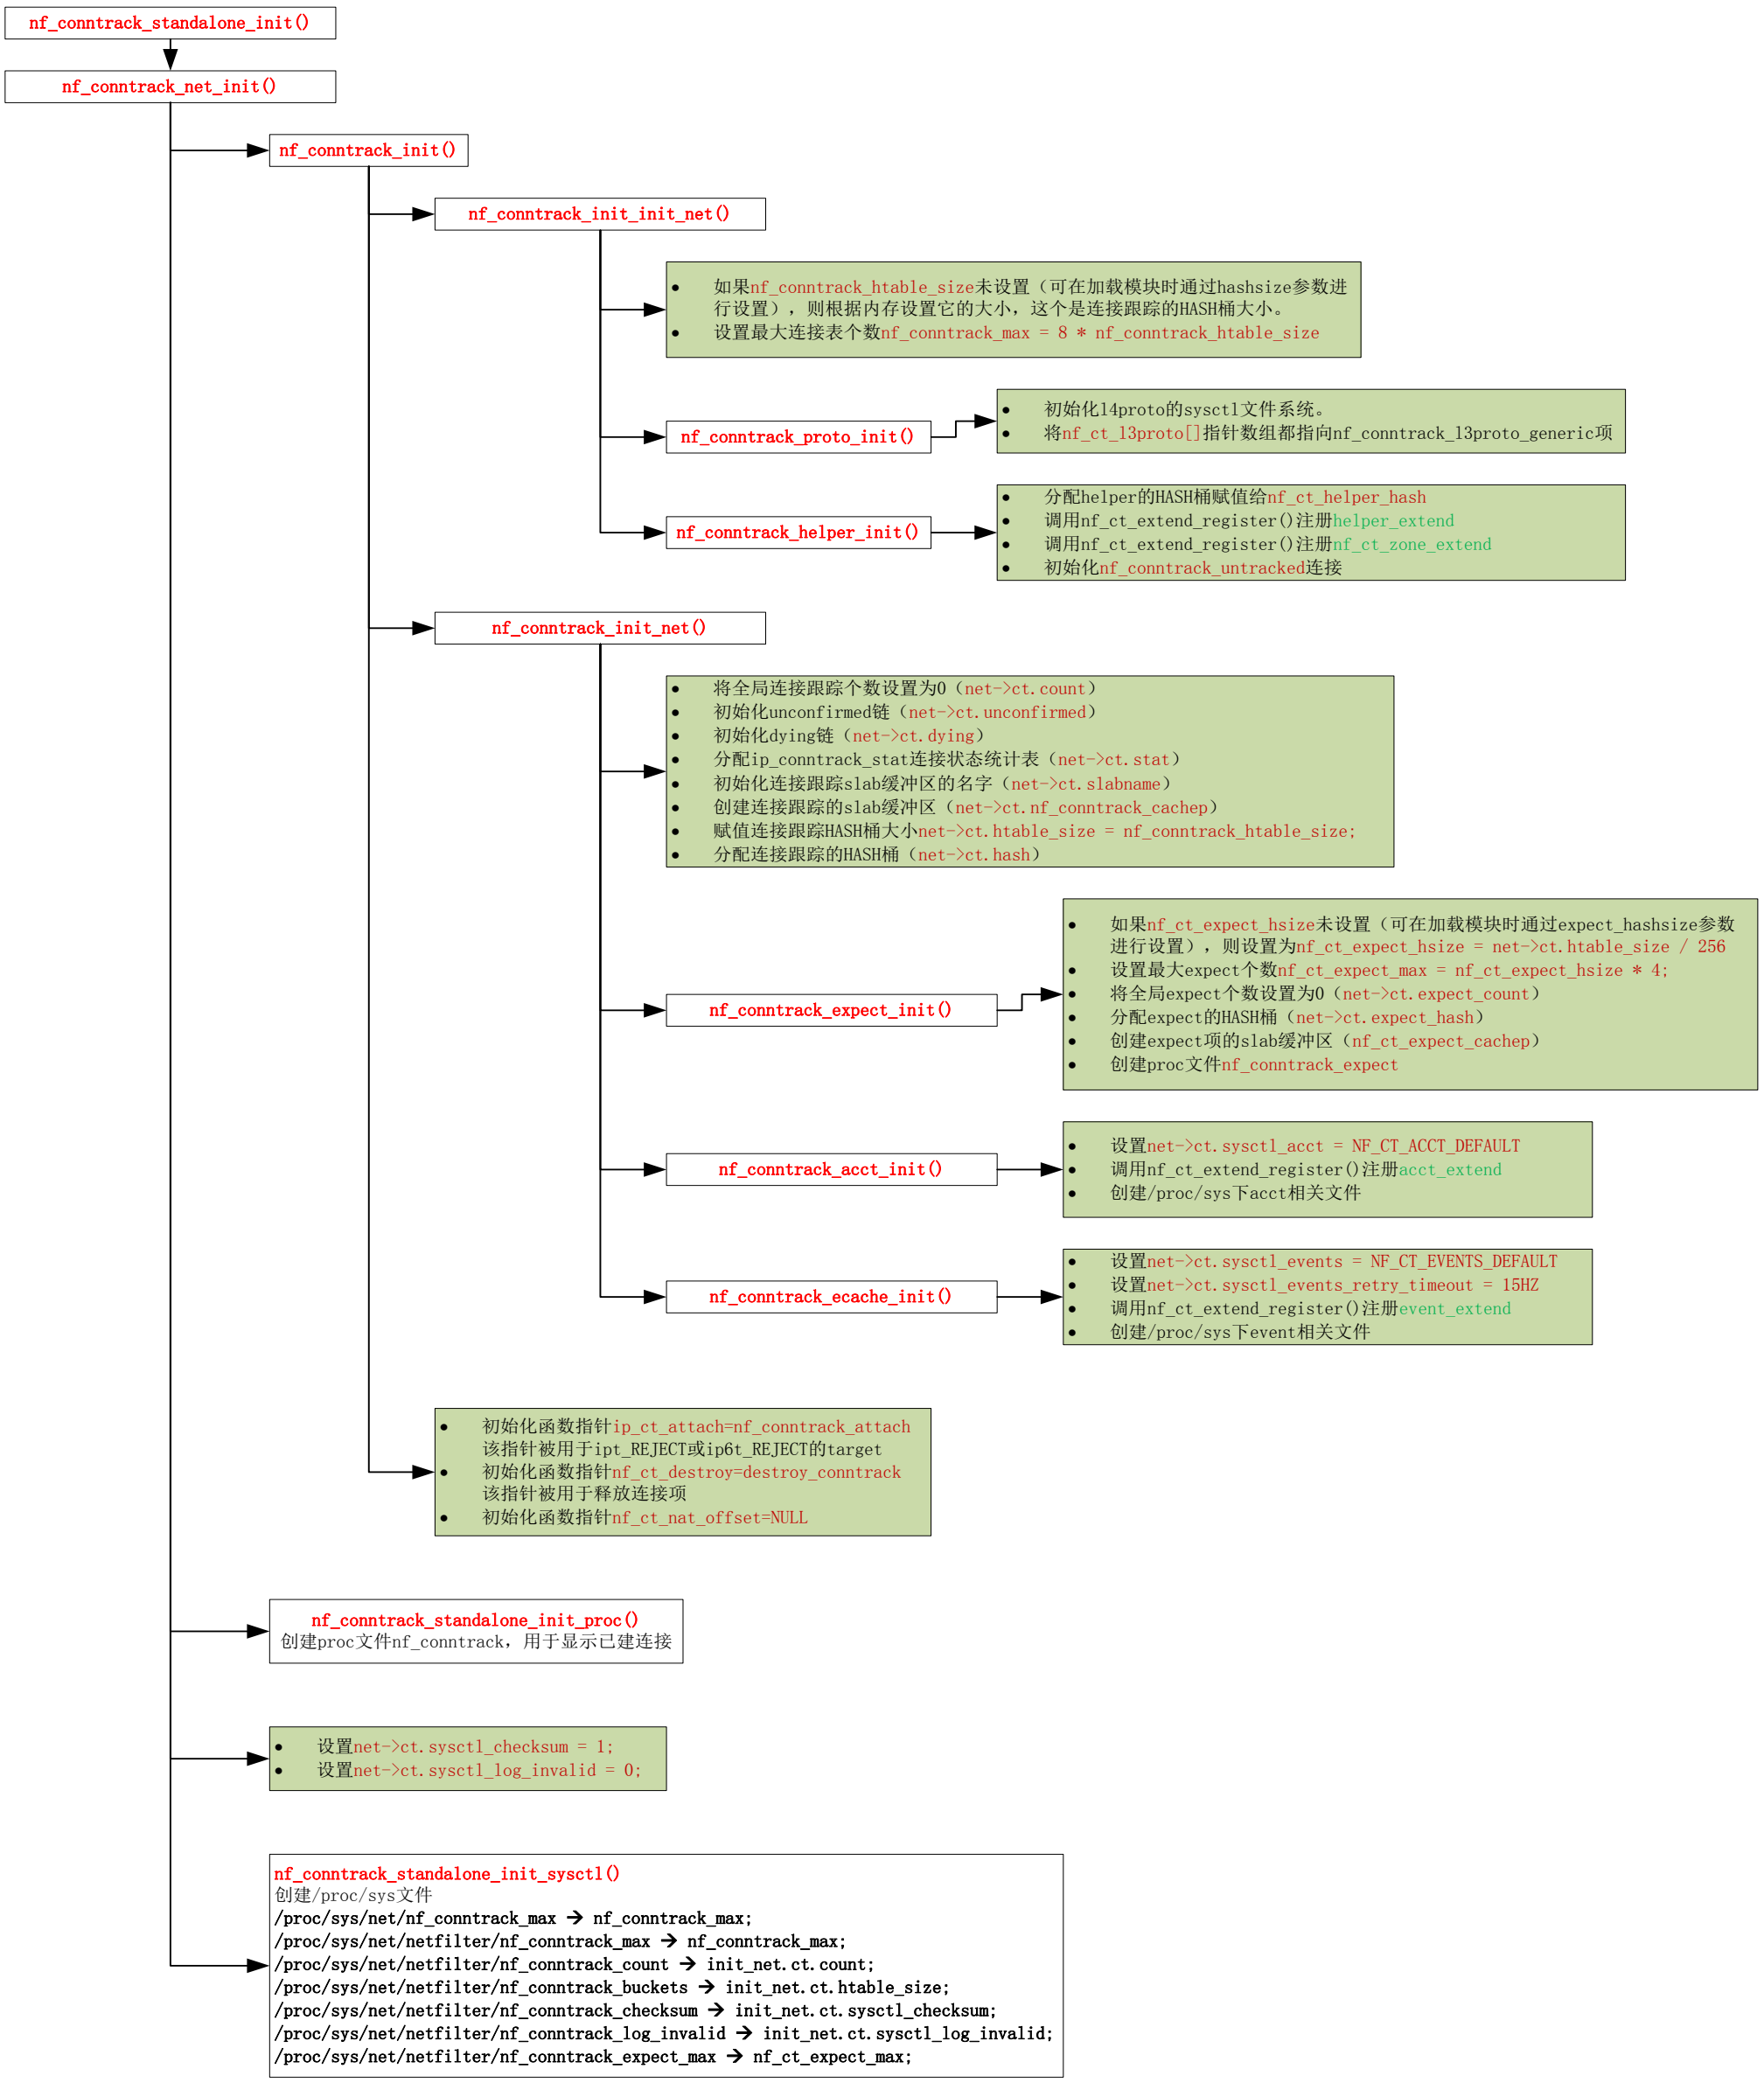

1 nf_conntrack 的初始化，就是初始化上面提到的这些资源，它在内核启动时调用 nf_conntrack_standalone_init()函数进行初始化的。

2 初始化完成后，构建出如下面连接表表现形式中的图所示，只是还没有创建 nf_conn、nf_conntrack_expect、nf_conntrack_helper 项。

3 ct_hash、expect_hash、helper_hash 这三个 HASH 桶大小在初始化时就已确定，后面不能再更改。其中 ct_hash、expect_hash 可在加载 nf_conntrack.ko 模块时通过参数 hashsize 和 expect_hashsize 进行设定，而 helper_hash 不能通过参数修改，它的默认值是 page/sizeof(helper_hash)。

4 nf_conn 和 nf_conntrack_expect 都有最大个数限制。nf_conn 通过全局变量 nf_conntrack_max 限制，可通过/proc/sys/net/netfilter/nf_conntrack_max 文件在运行时修改。nf_conntrack_expect 通过全局变量 nf_ct_expect_max 限制，可通过/proc/sys/net/netfilter/ nf_conntrack_expect_max 文件在运行时修改。nf_conntrack_helper 没有最大数限制，因为这个是通过注册不同协议的模块添加的，大小取决于动态协议跟踪模块的多少，一般不会很大。

连接表的表现形式

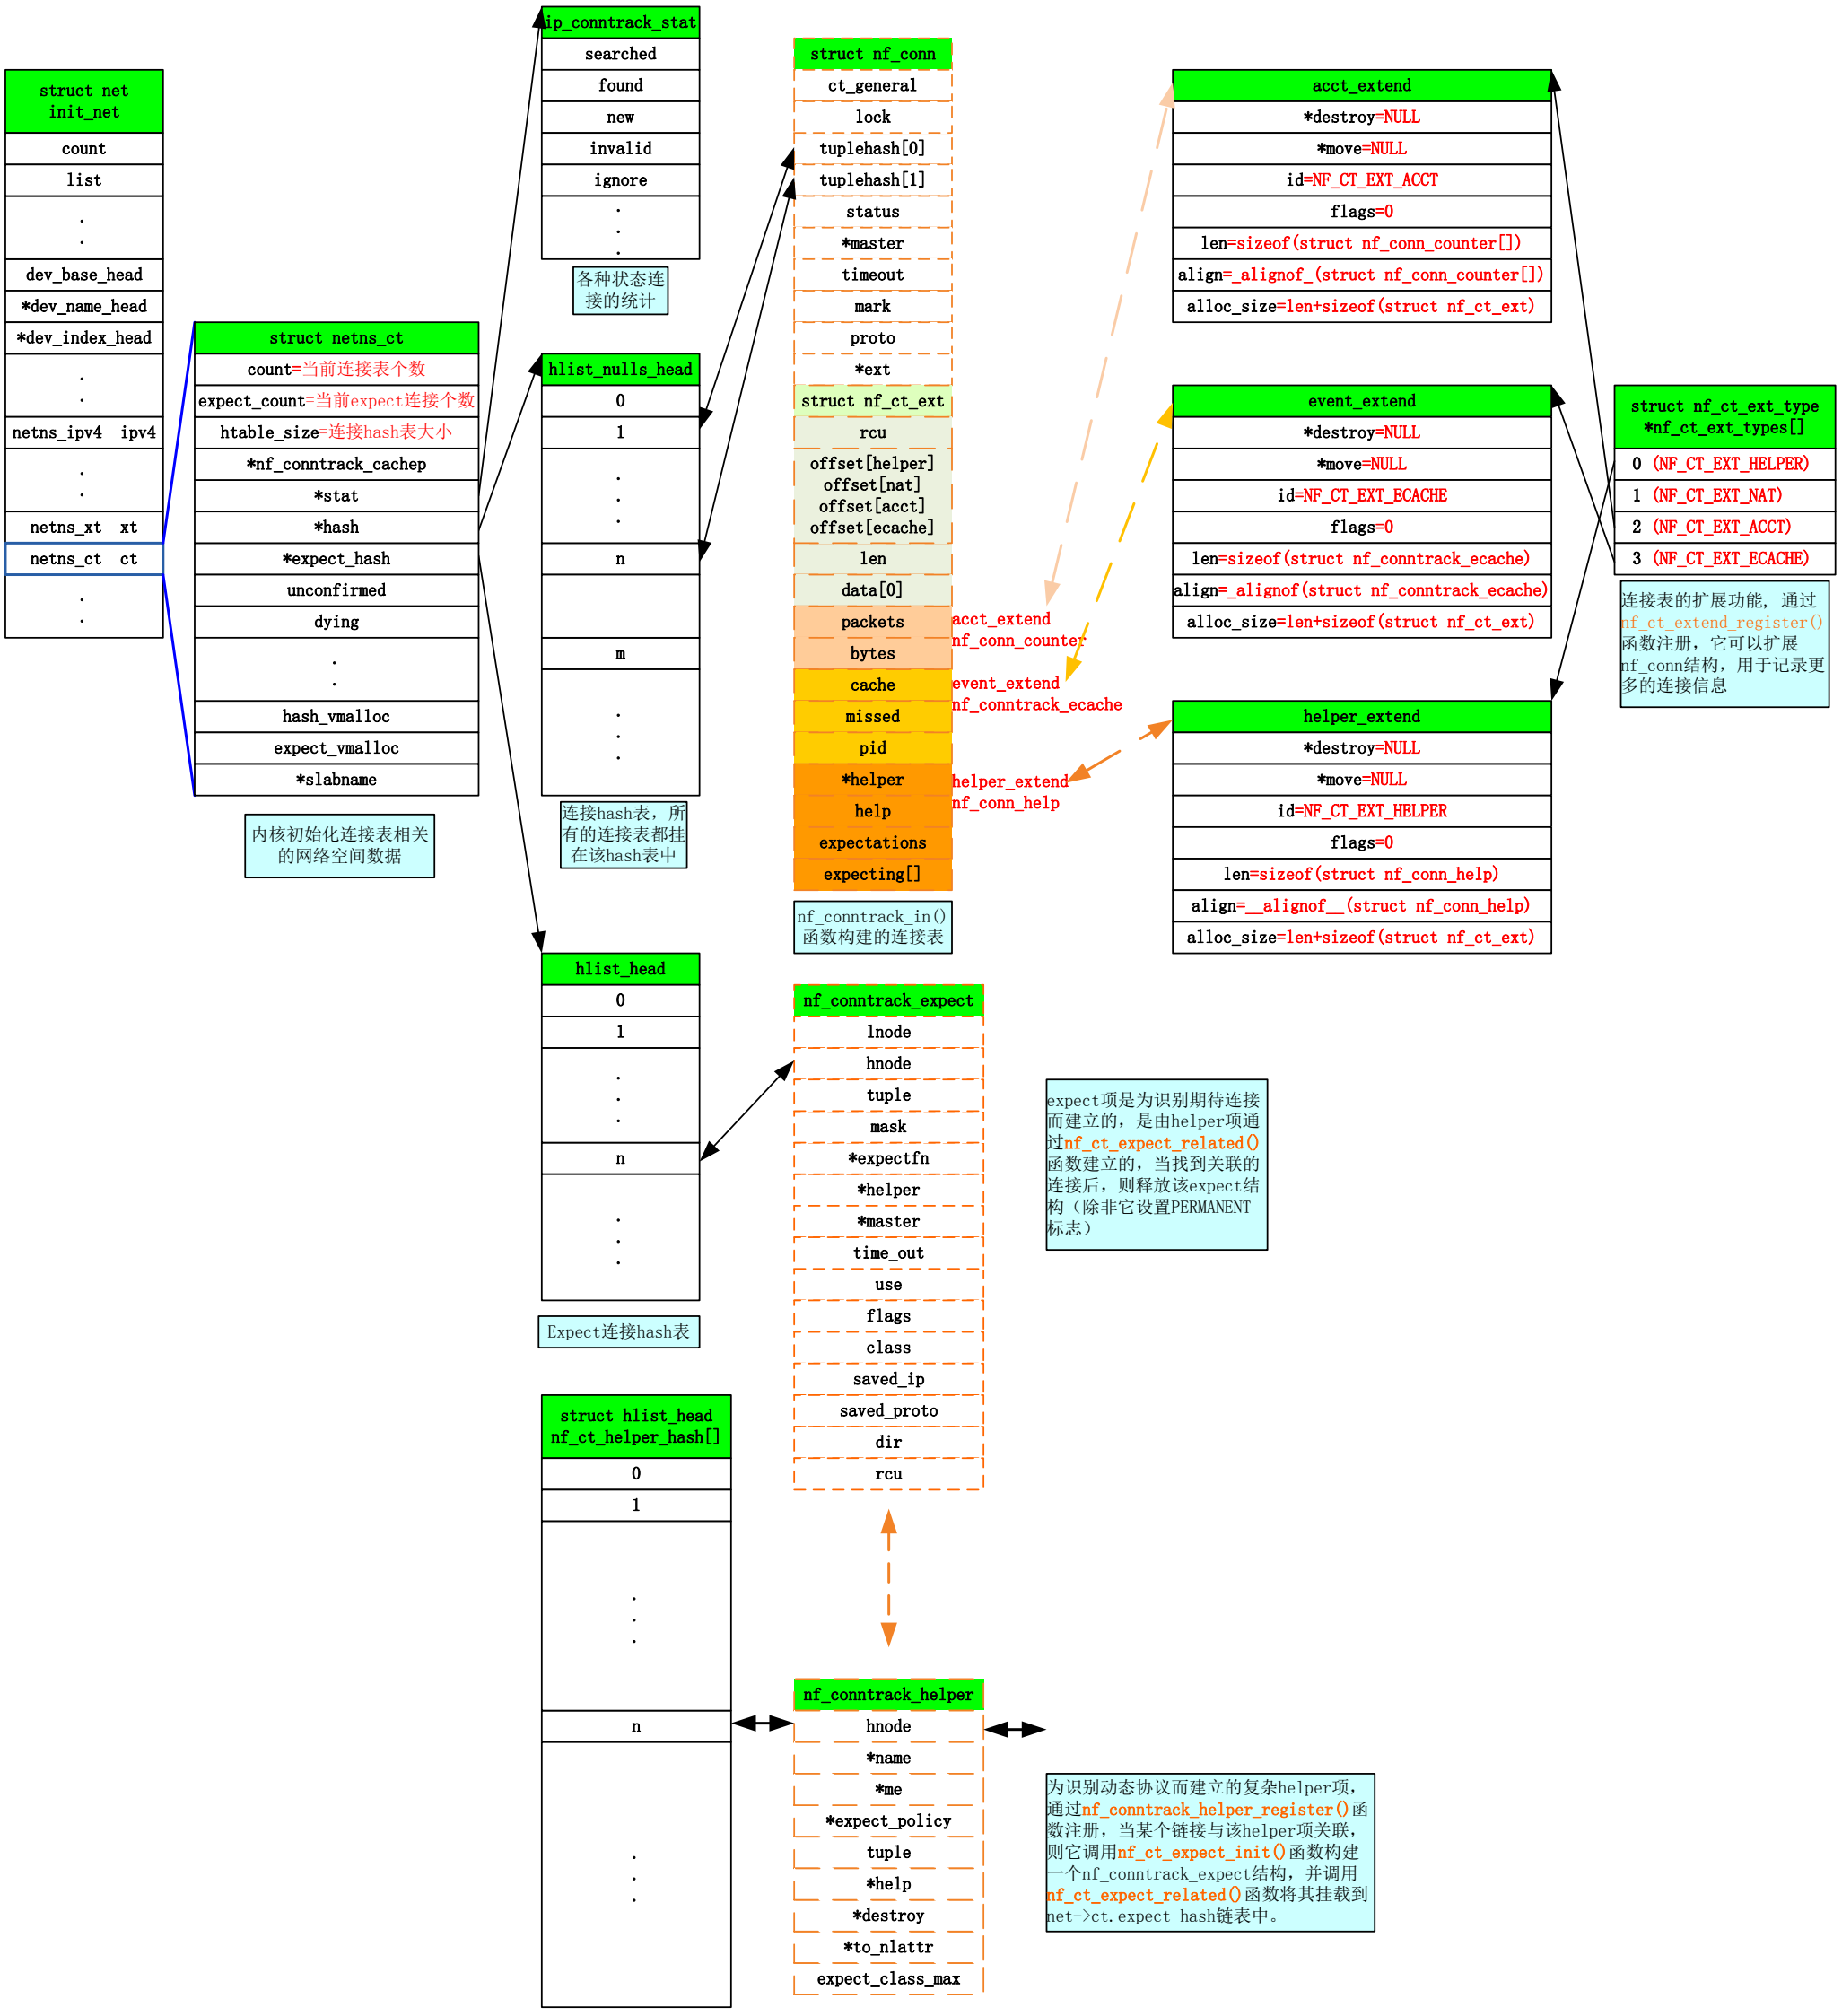
struct net init_net
count
list
dev_base_head
*dev_name_head
*dev_index_head
netns_ipv4 ipv4
netns_xt xt
netns_ct ct
struct netns_ct
count=当前连接表个数
expect_count=当前expect连接个数
htable_size=连接hash表大小
*nf_conntrack_cachep
*stat
*hash
*expect_hash
unconfirmed
dying
hash_vmalloc
expect_vmalloc
*slabname
内核初始化连接表相关的网络空间数据
ip_conntrack_stat
searched
found
new
invalid
ignore
各种状态连接的统计
hlist_nulls_head
0
1
n
m
连接hash表，所有的连接表都挂在该hash表中
struct nf_conn
ct_general
lock
tuplehash[0]
tuplehash[1]
status
*master
timeout
mark
proto
*ext
struct nf_ct_ext
rcu
offset[helper]
offset[nat]
offset[acct]
offset[ecache]
len
data[0]
packets
bytes
cache
missed
pid
*helper
help
expectations
expecting[]
acct_extend
nf_conn_counter
event_extend
nf_conntrack_ecache
helper_extend
nf_conn_help
nf_conntrack_in()函数构建的连接表
acct_extend
*destroy=NULL
*move=NULL
id=NF_CT_EXT_ACCT
flags=0
len=sizeof(struct nf_conn_counter[])
align=_alignof_(struct nf_conn_counter[])
alloc_size=len+sizeof(struct nf_ct_ext)
event_extend
*destroy=NULL
*move=NULL
id=NF_CT_EXT_ECACHE
flags=0
len=sizeof(struct nf_conntrack_ecache)
align=_alignof(struct nf_conntrack_ecache)
alloc_size=len+sizeof(struct nf_ct_ext)
helper_extend
*destroy=NULL
*move=NULL
id=NF_CT_EXT_HELPER
flags=0
len=sizeof(struct nf_conn_help)
align=__alignof__(struct nf_conn_help)
alloc_size=len+sizeof(struct nf_ct_ext)
struct nf_ct_ext_type *nf_ct_ext_types[]
0 (NF_CT_EXT_HELPER)
1 (NF_CT_EXT_NAT)
2 (NF_CT_EXT_ACCT)
3 (NF_CT_EXT_ECACHE)
连接表的扩展功能，通过nf_ct_extend_register()函数注册，它可以扩展nf_conn结构，用于记录更多的连接信息
hlist_head
0
1
n
Expect连接hash表
nf_conntrack_expect
lnode
hnode
tuple
mask
*expectfn
*helper
*master
time_out
use
flags
class
saved_ip
saved_proto
dir
rcu
expect项是为识别期待连接而建立的，是由helper项通过nf_ct_expect_related()函数建立的，当找到关联的连接后，则释放该expect结构（除非它设置PERMANENT标志）
struct hlist_head nf_ct_helper_hash[]
0
1
n
nf_conntrack_helper
hnode
*name
*me
*expect_policy
tuple
*help
*destroy
*to_nlattr
expect_class_max
为识别动态协议而建立的复杂helper项，通过nf_conntrack_helper_register()函数注册，当某个链接与该helper项关联，则它调用nf_ct_expect_init()函数构建一个nf_conntrack_expect结构，并调用nf_ct_expect_related()函数将其挂载到net->ct.expect_hash链表中。

连接表和动态协议的表现形式

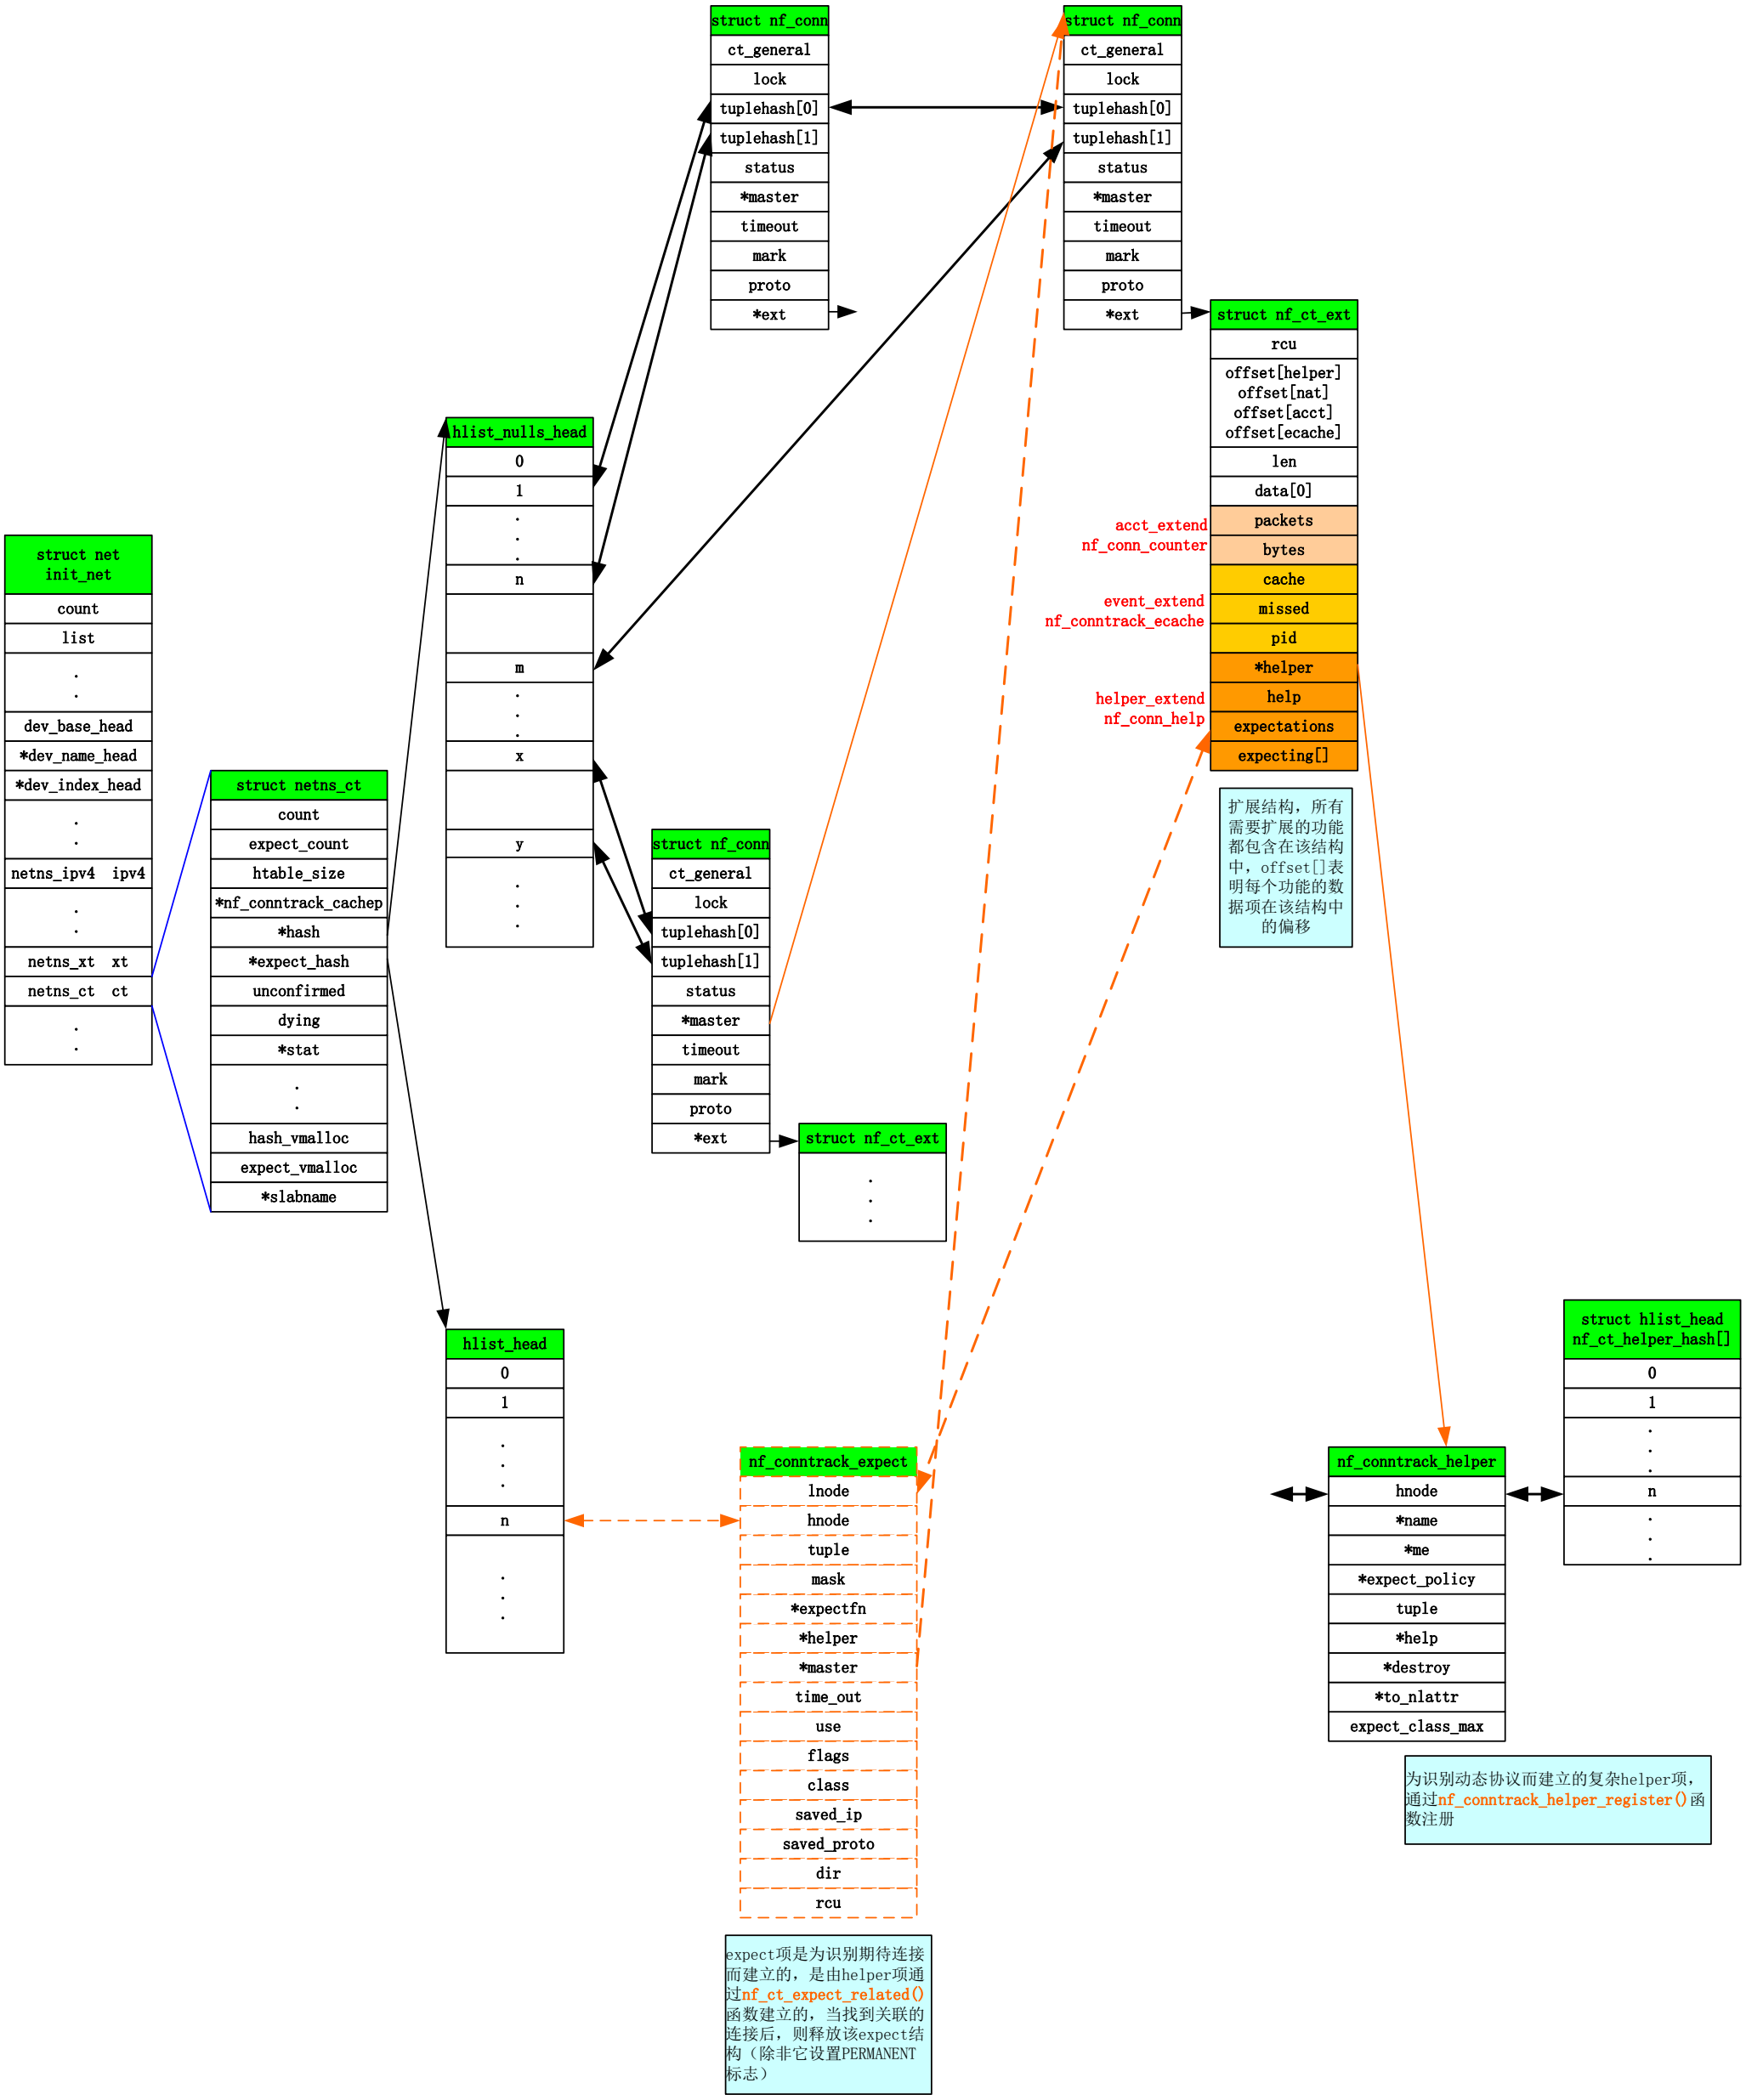

IPv4 利用 nf_conntrack 进行链接跟踪

IPv4 连接跟踪的初始化

1　Ipv4 协议注册了自己的 3 层协议 IPv4 协议，和 IPv4 相关的三个 4 层协议 TCP、UDP、ICMP。

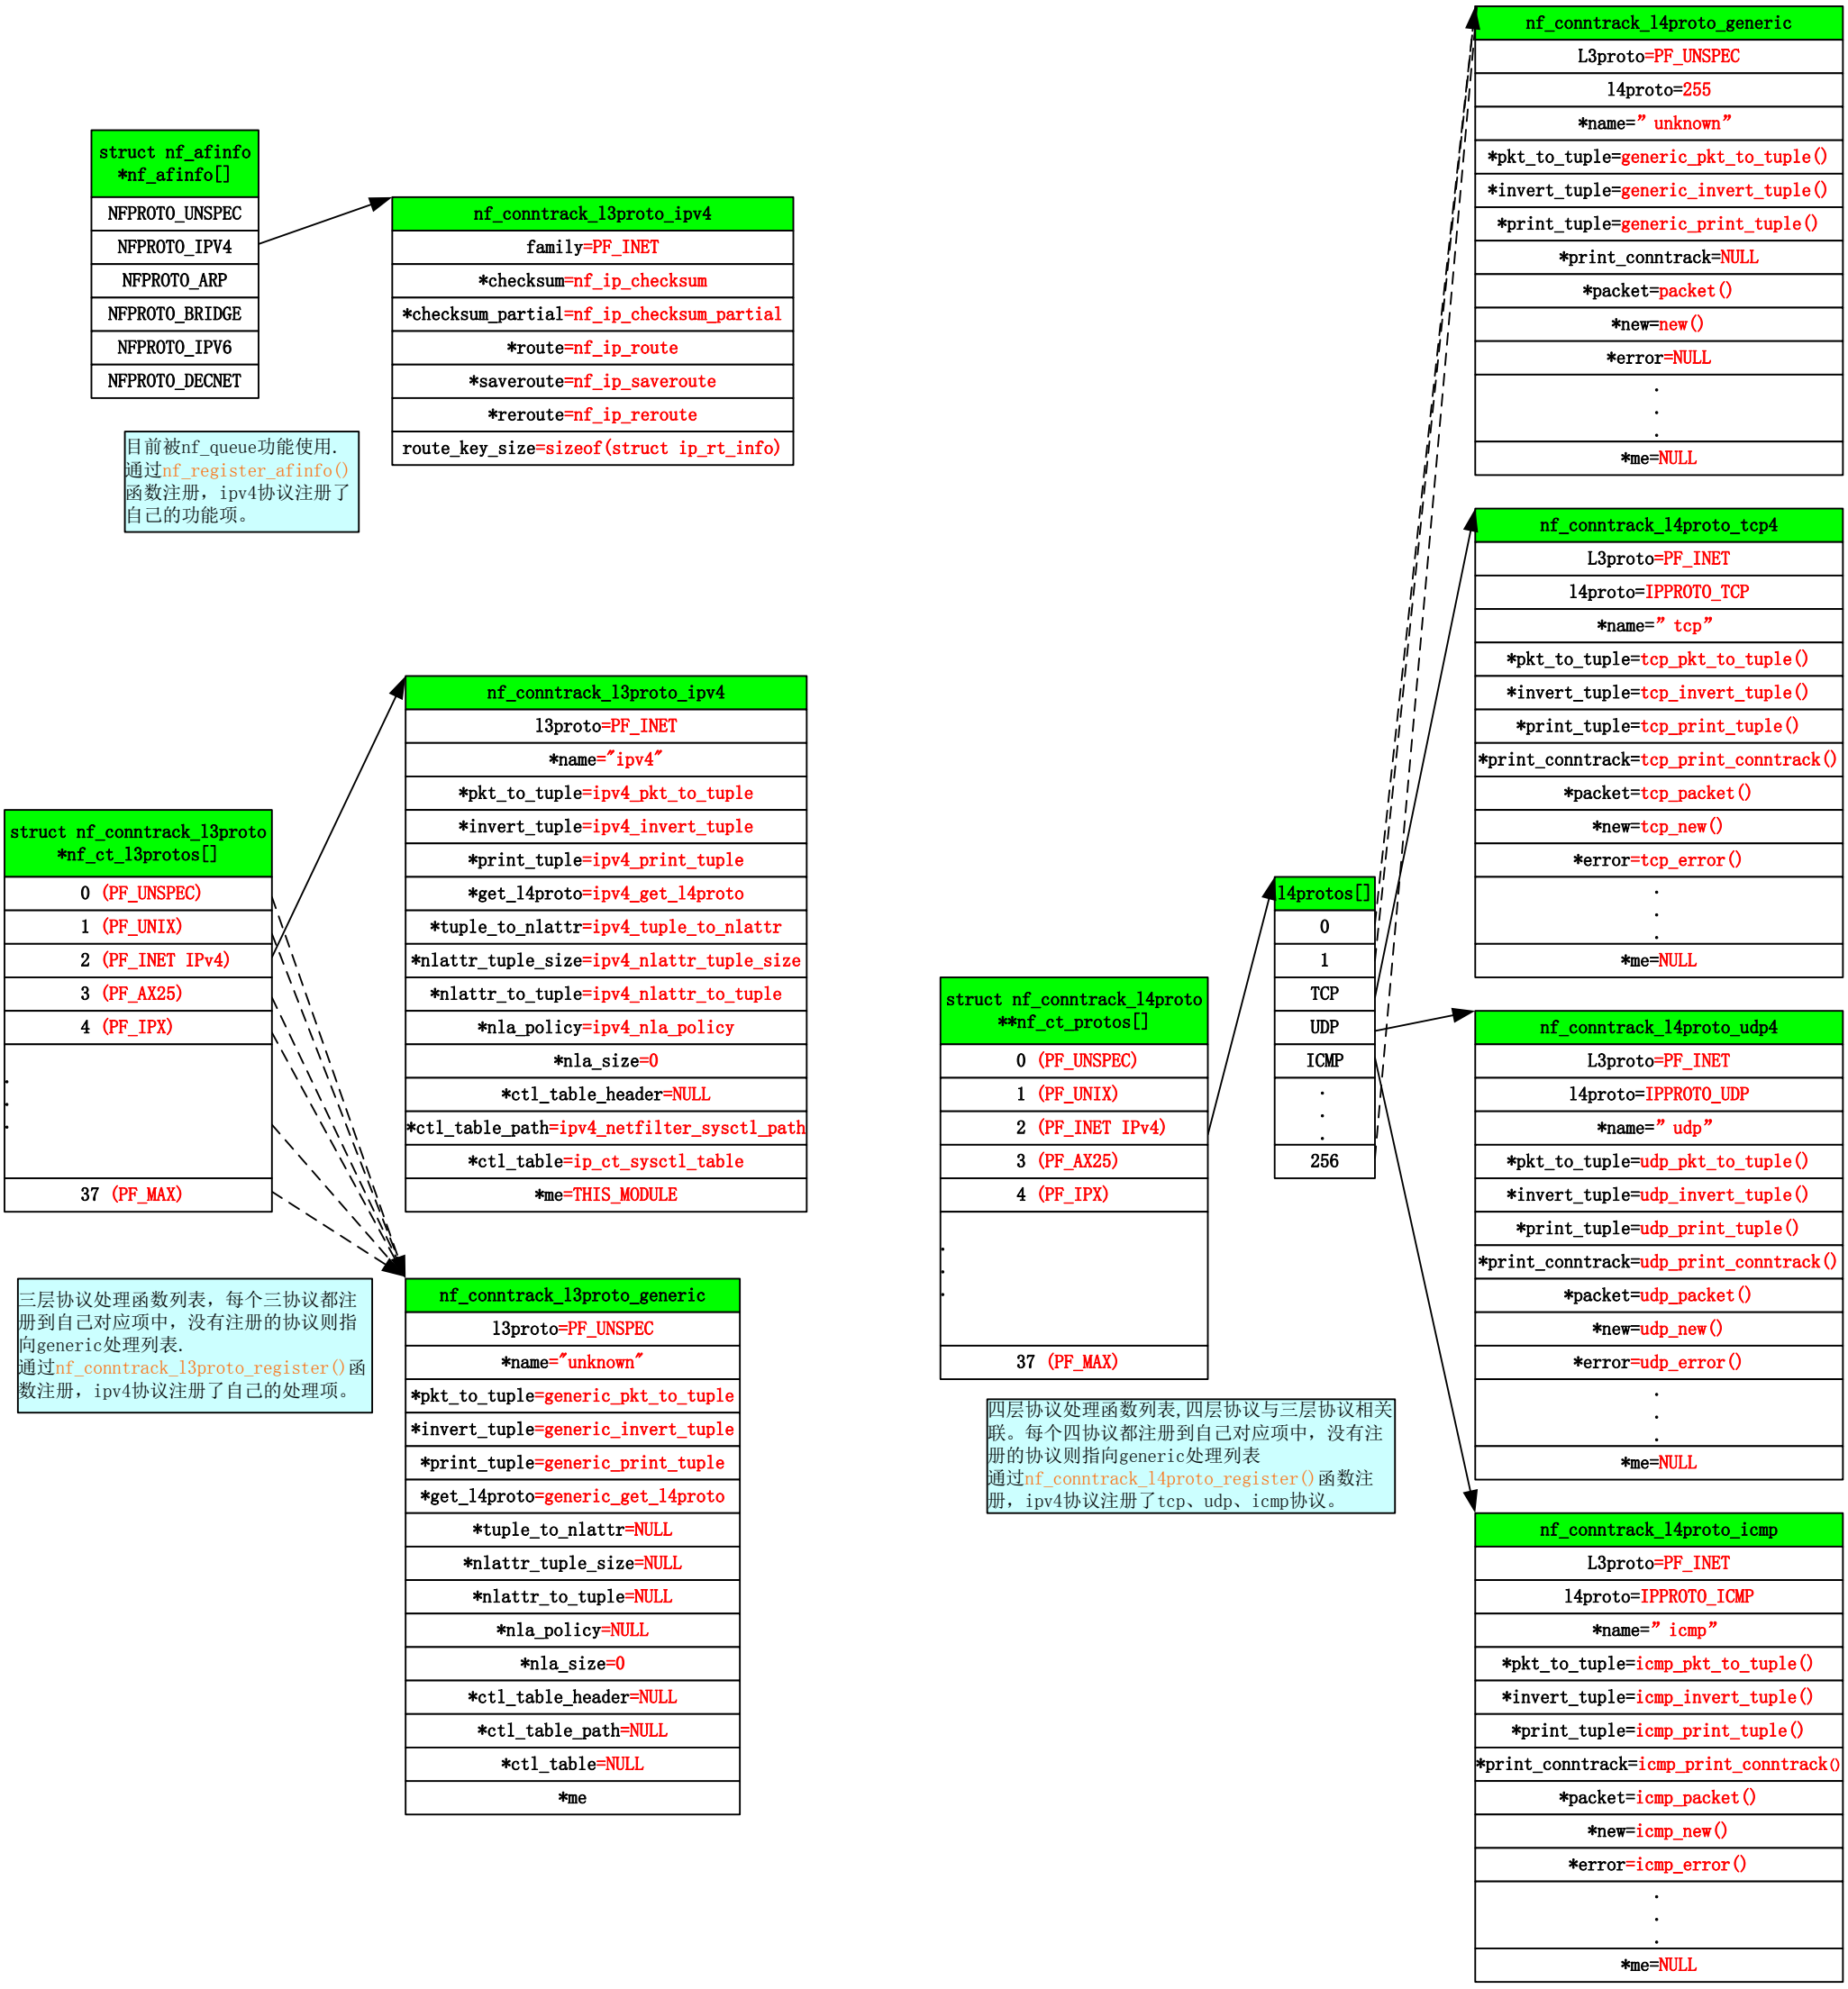

2　在 netfilter 中利用 nf_register_hook(struct nf_hook_ops *reg)、nf_unregister_hook(struct nf_hook_ops *reg)函数注册自己的钩子项，调用 nf_conntrack_in()函数来建立相应连接。

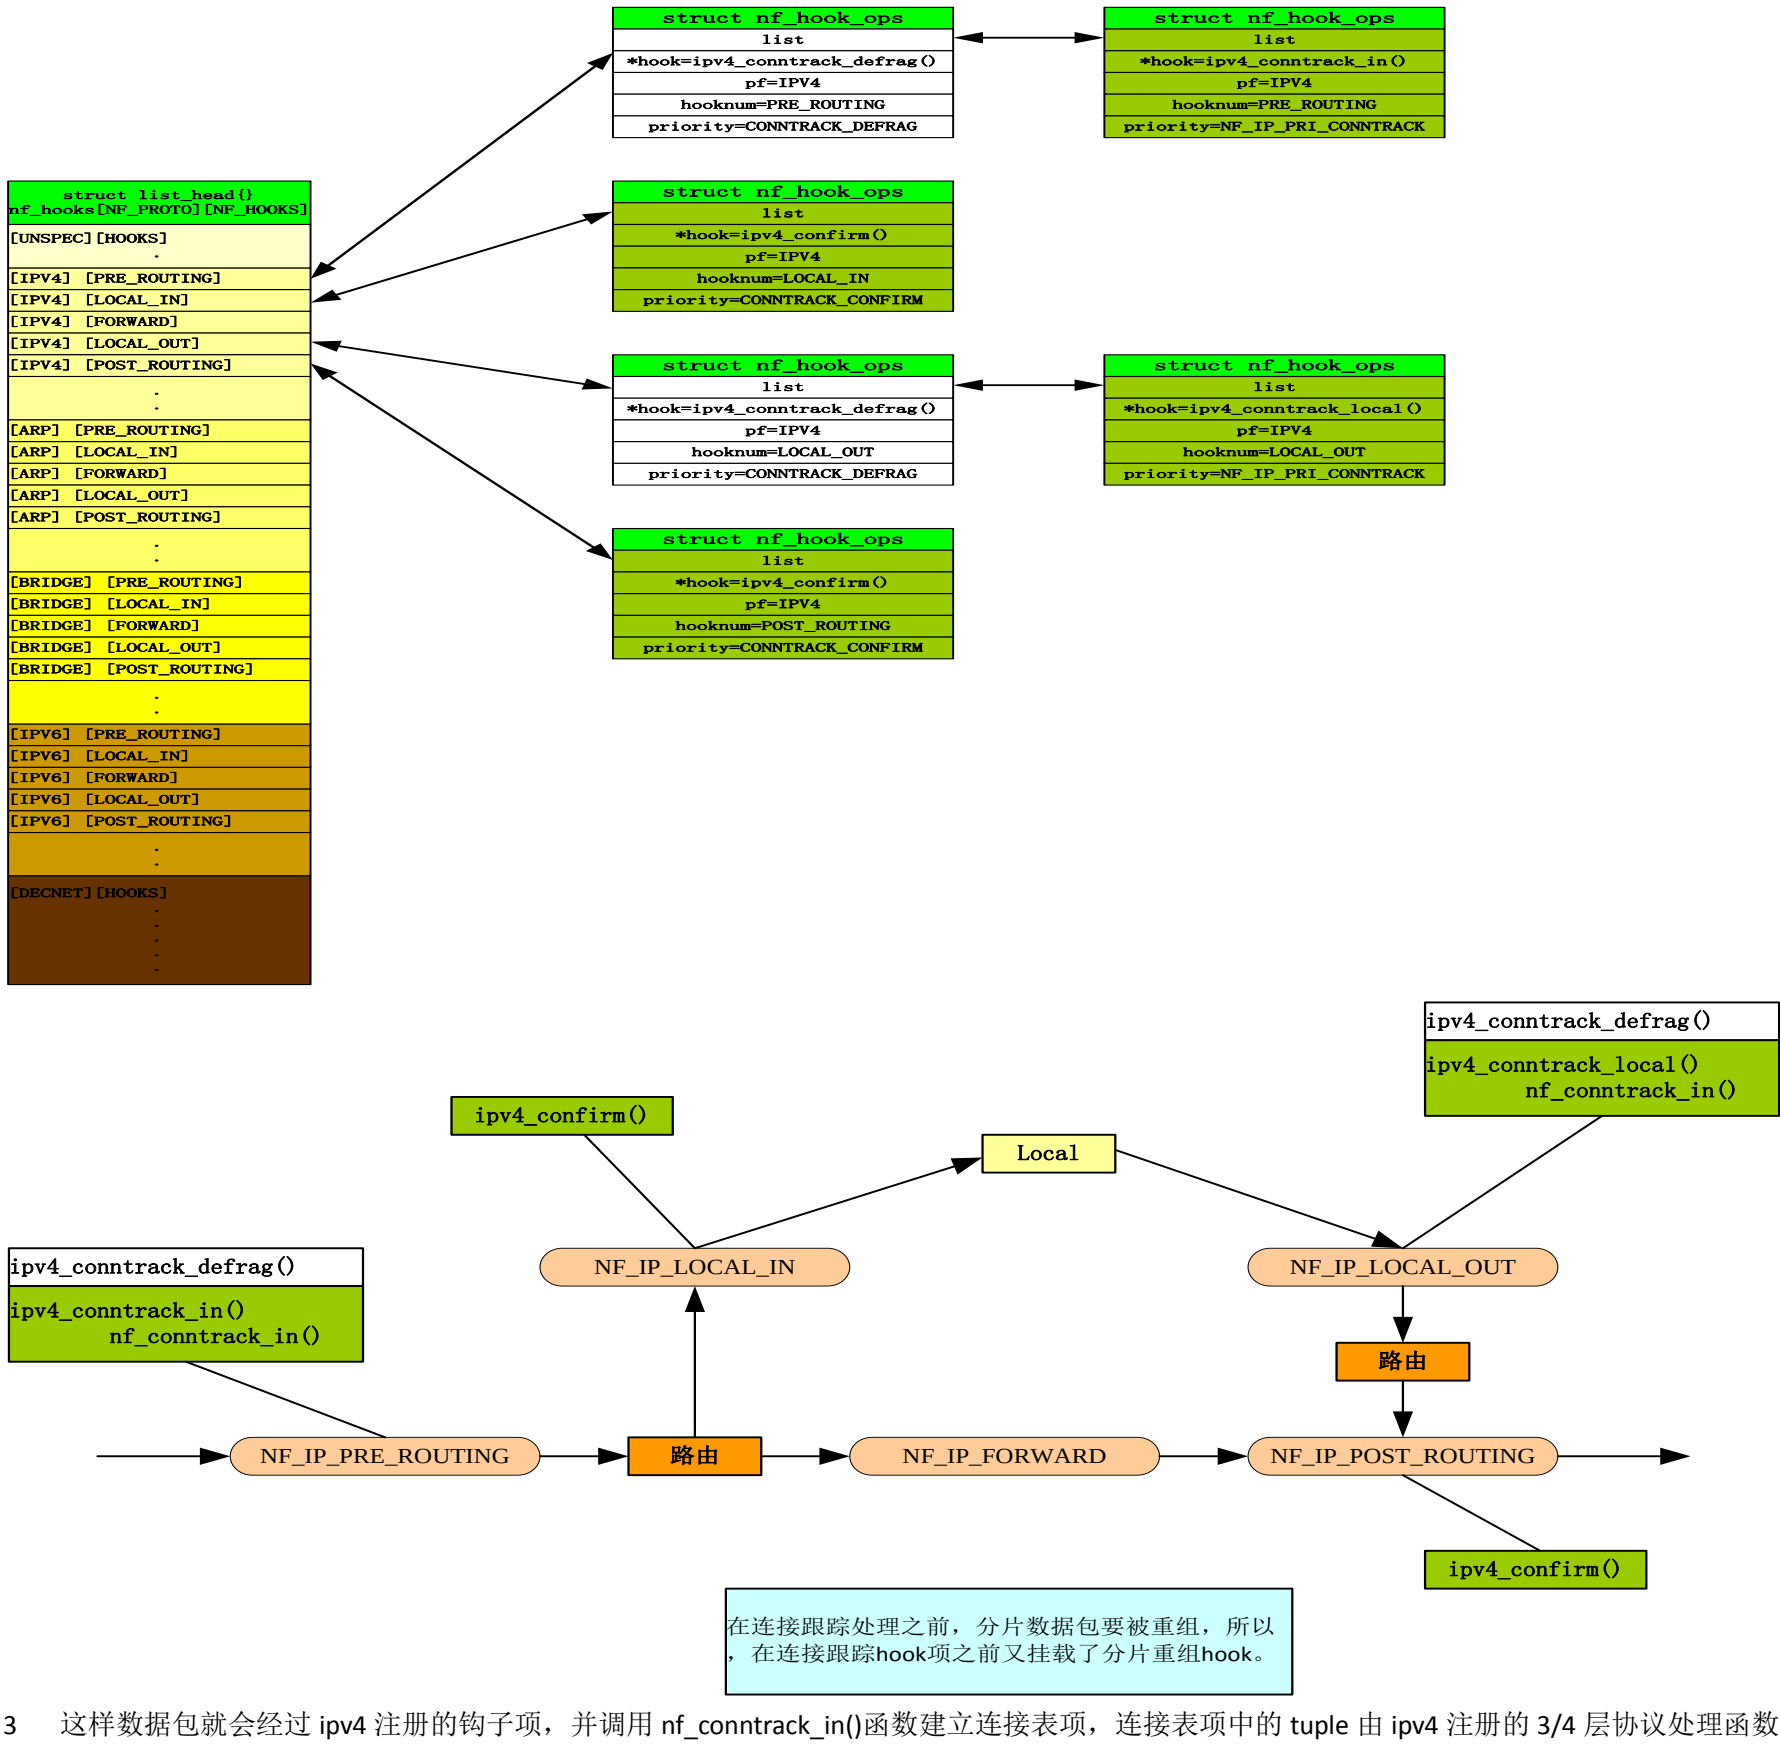

3 这样数据包就会经过 ipv4 注册的钩子项，并调用 nf_conntrack_in()函数建立连接表项，连接表项中的 tuple 由 ipv4 注册的 3/4 层协议处理函数构建。

3.1 ipv4_conntrack_in() 挂载在 NF_IP_PRE_ROUTING 点上。该函数主要功能是创建链接，即创建 struct nf_conn 结构，同时填充 struct nf_conn 中的一些必要的信息，例如链接状态、引用计数、helper 结构等。

3.2 ipv4_confirm() 挂载在 NF_IP_POST_ROUTING 和 NF_IP_LOCAL_IN 点上。该函数主要功能是确认一个链接。对于一个新链接，在 ipv4_conntrack_in()函数中只是创建了 struct nf_conn 结构，但并没有将该结构挂载到链接跟踪的 Hash 表中，因为此时还不能确定该链接是否会被 NF_IP_FORWARD 点上的钩子函数过滤掉，所以将挂载到 Hash 表的工作放到了 ipv4_confirm()函数中。同时，子链接的 helper 功能也是在该函数中实现的。

3.3 ipv4_conntrack_local() 挂载在 NF_IP_LOCAL_OUT 点上。该函数功能与 ipv4_conntrack_in()函数基本相同，但其用来处理本机主动向外发起的链接。

4 nf_conntrack_ipv4_compat_init() --> register_pernet_subsys() --> ip_conntrack_net_init() 创建/proc 文件 ip_conntrack 和 ip_conntrack_expect

IPv4 连接跟踪的处理流程

1 如上图所示，连链接跟踪主要由三个函数来完成，即 ipv4_conntrack_in()，ipv4_confirm()与 ipv4_conntrack_local()。其中 ipv4_conntrack_in()与 ipv4_conntrack_local()都是通过调用函数 nf_conntrack_in()来实现的，所以下面我们主要关注 nf_conntrack_in()与 ipv4_confirm()这两个函数。nf_conntrack_in()函数主要完成创建链接、添加链接的扩展结构(例如 helper, acct 结构)、设置链接状态等。ipv4_confirm()函数主要负责确认链接(即将链接挂入到正式的链接表中)、执行 helper 函数、启动链接超时定时器等。

2 另外还有一个定时器函数 death_by_timeout(), 该函数负责链接到期时删除该链接。

nf_conntrack_in

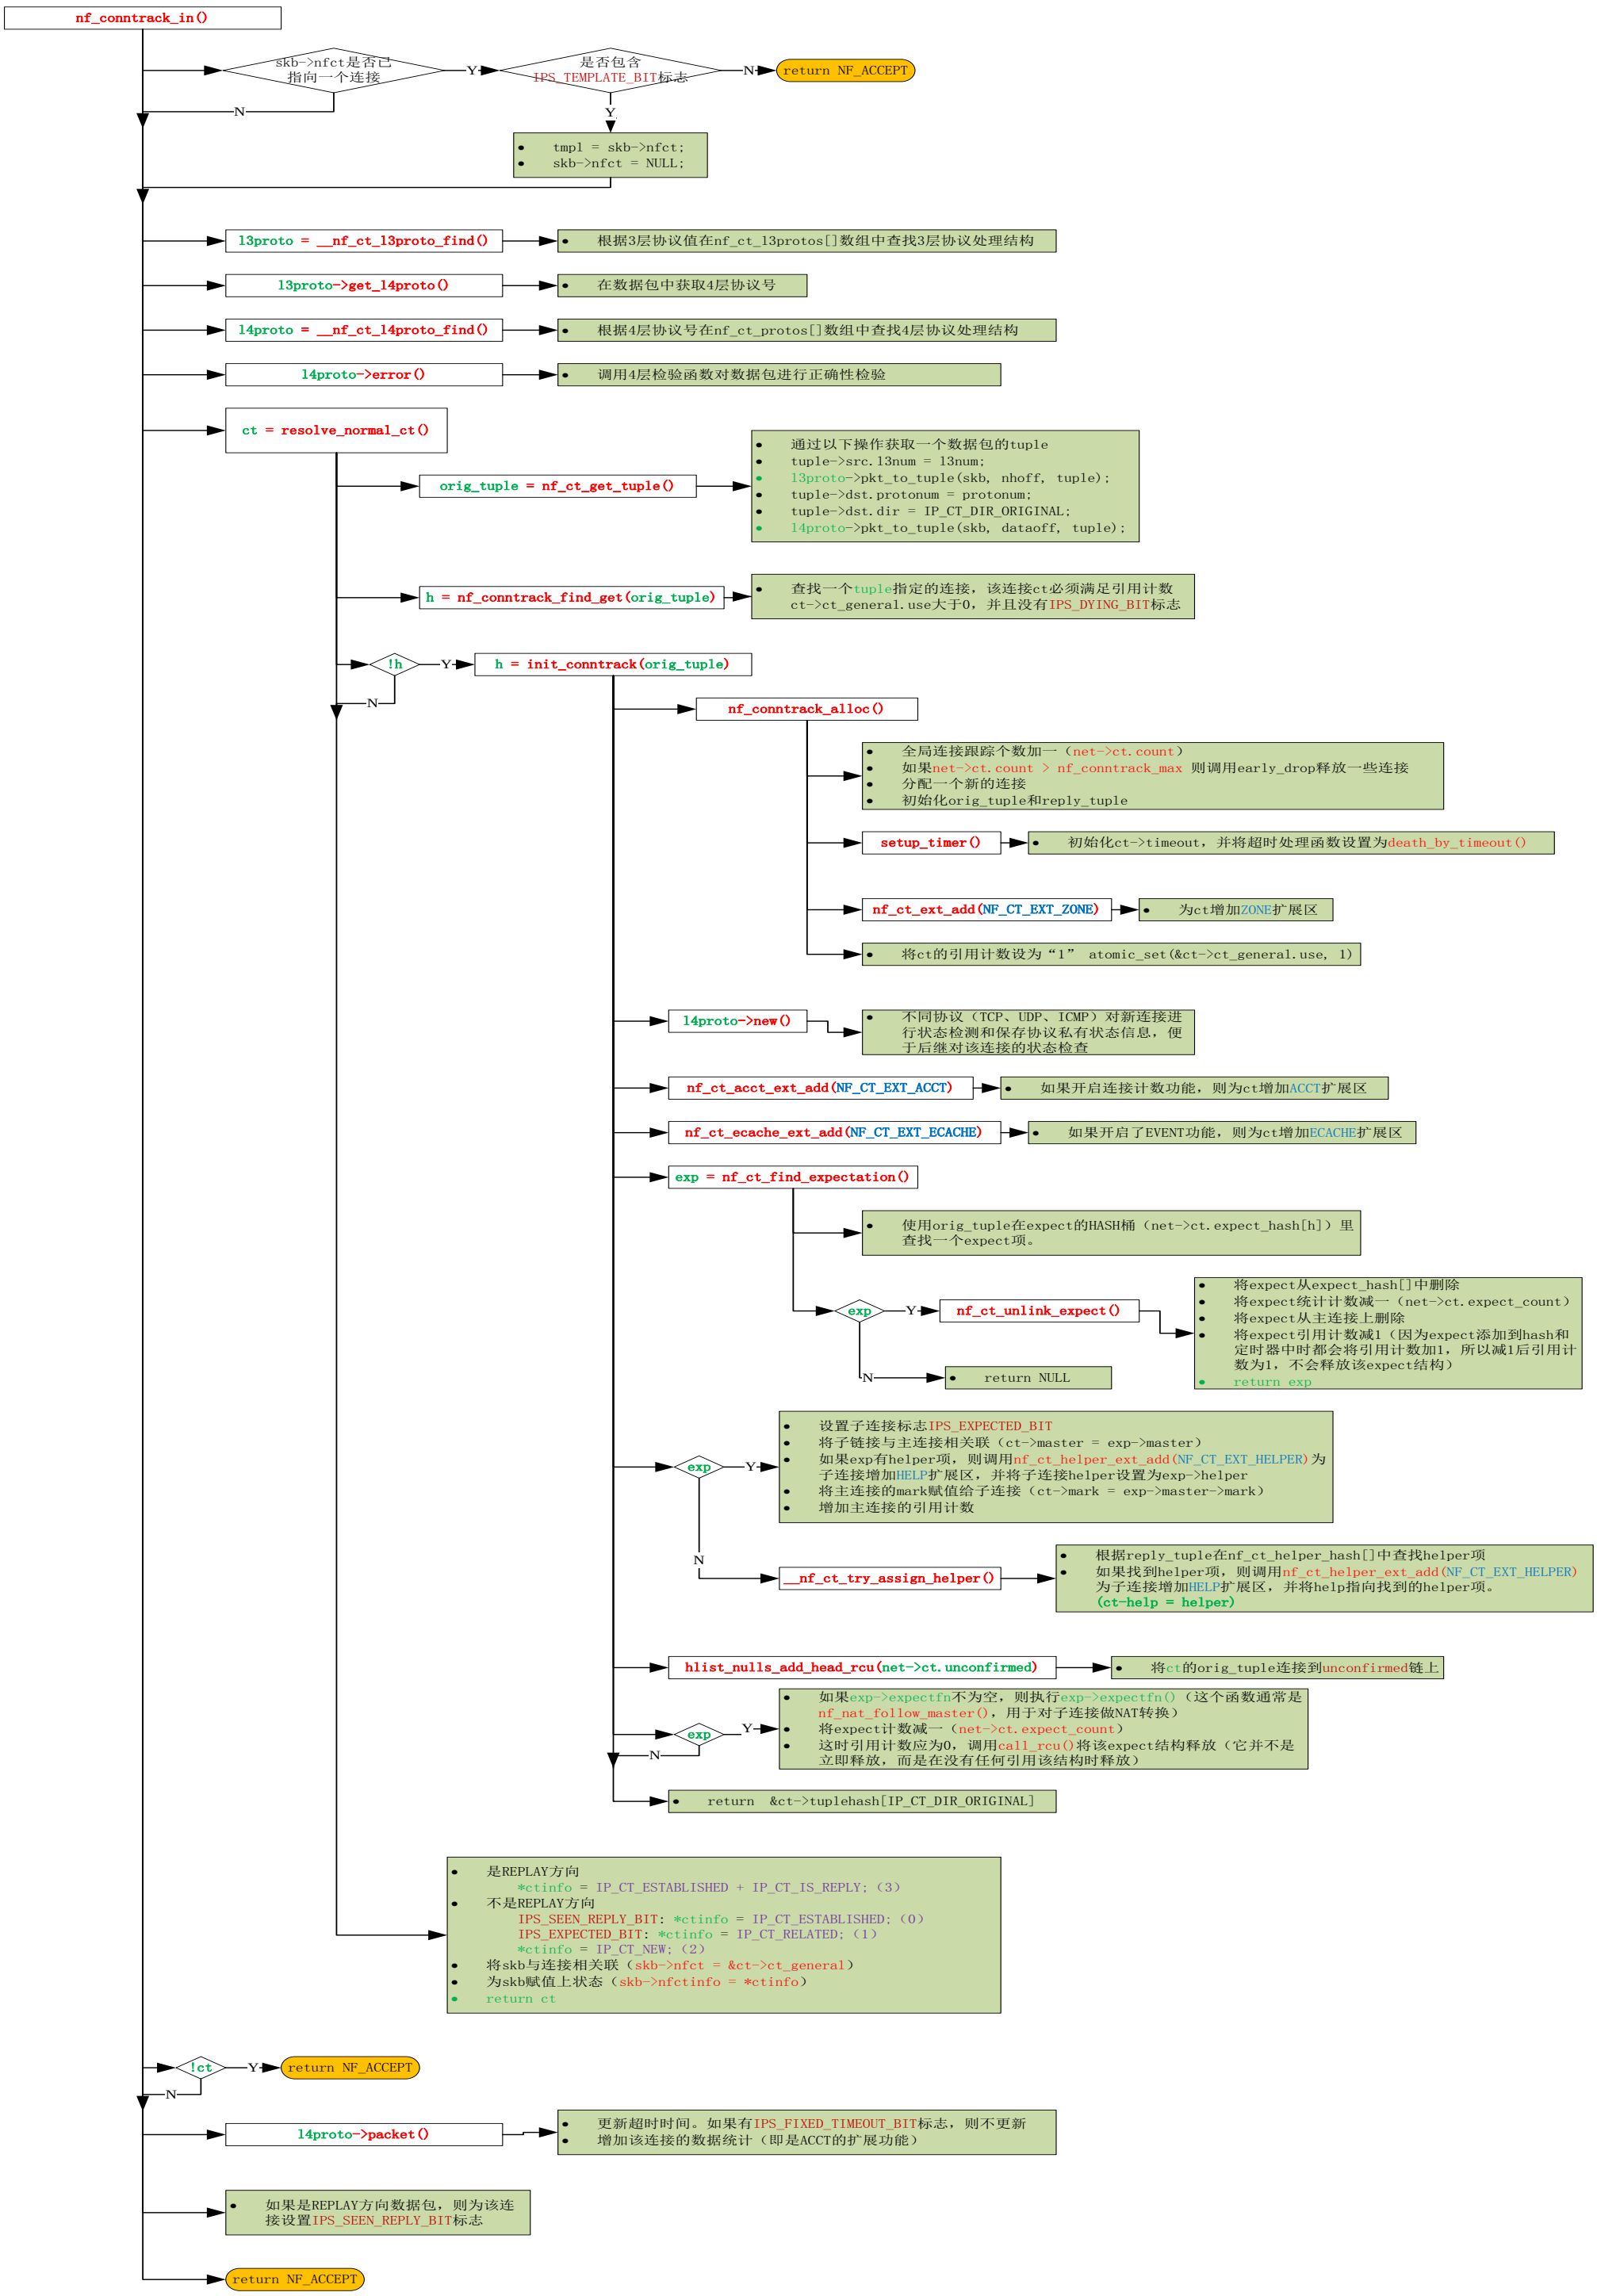

ipv4_confirm

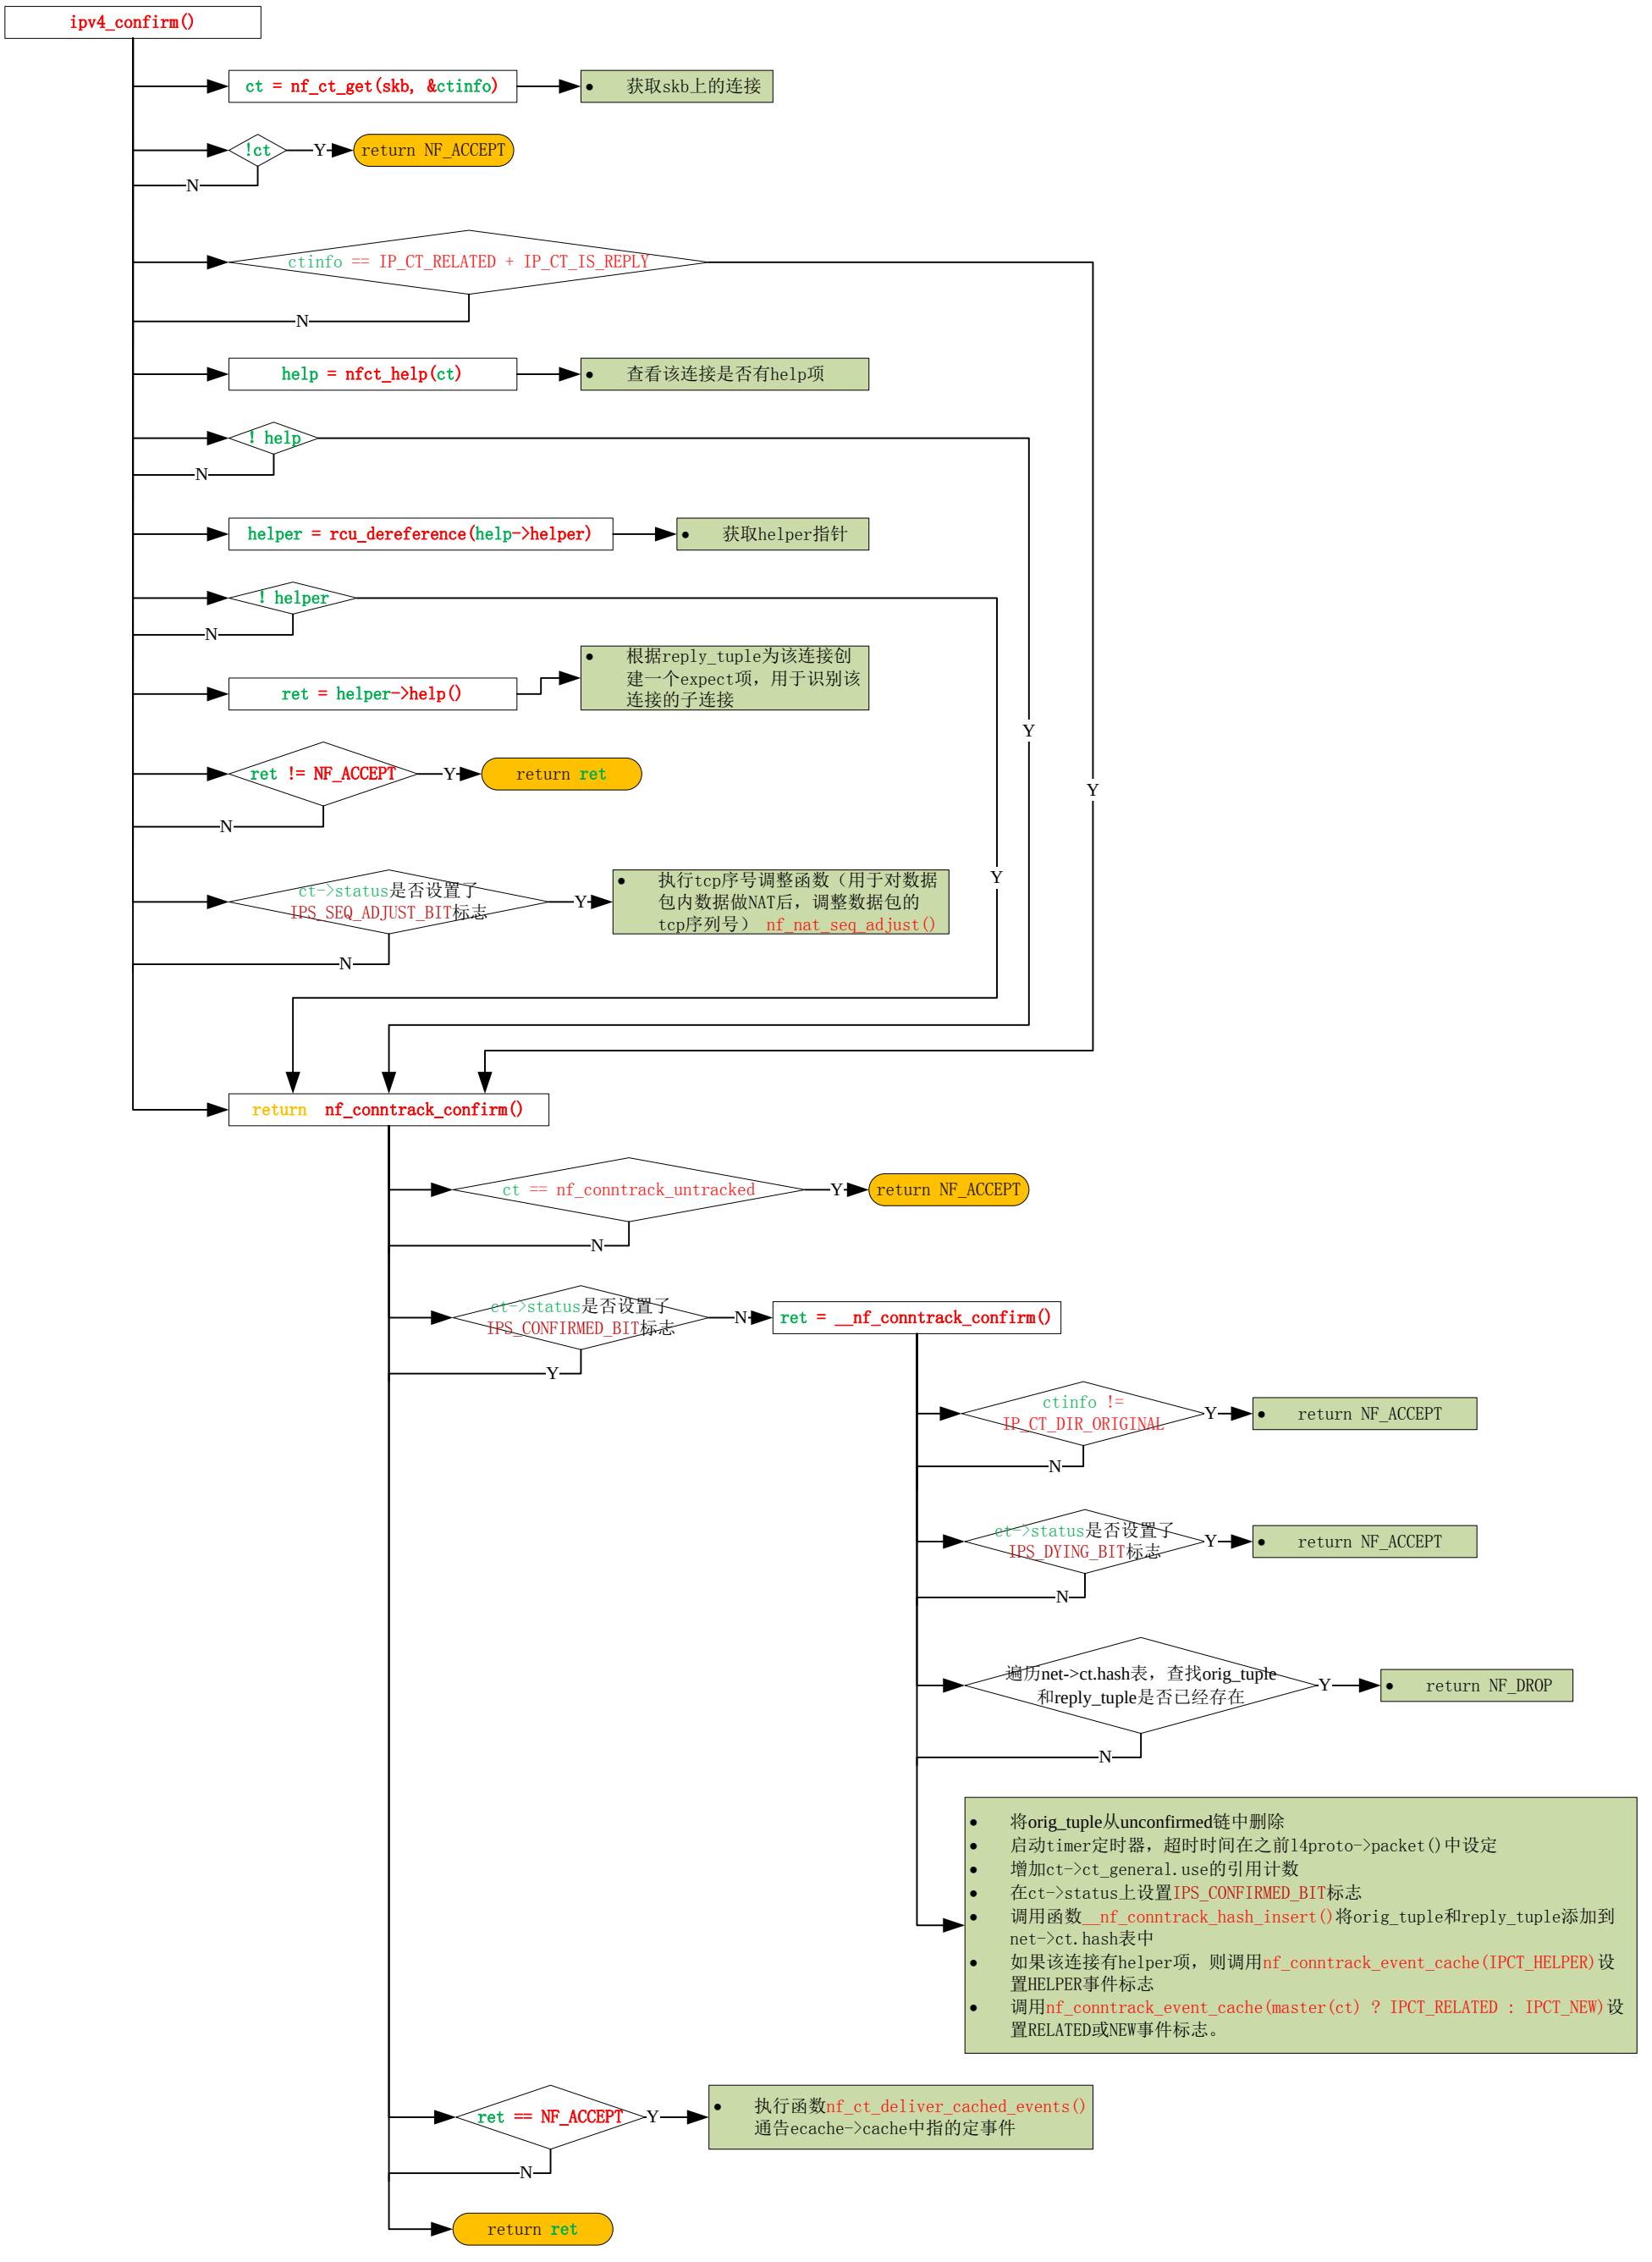

death_by_timeout

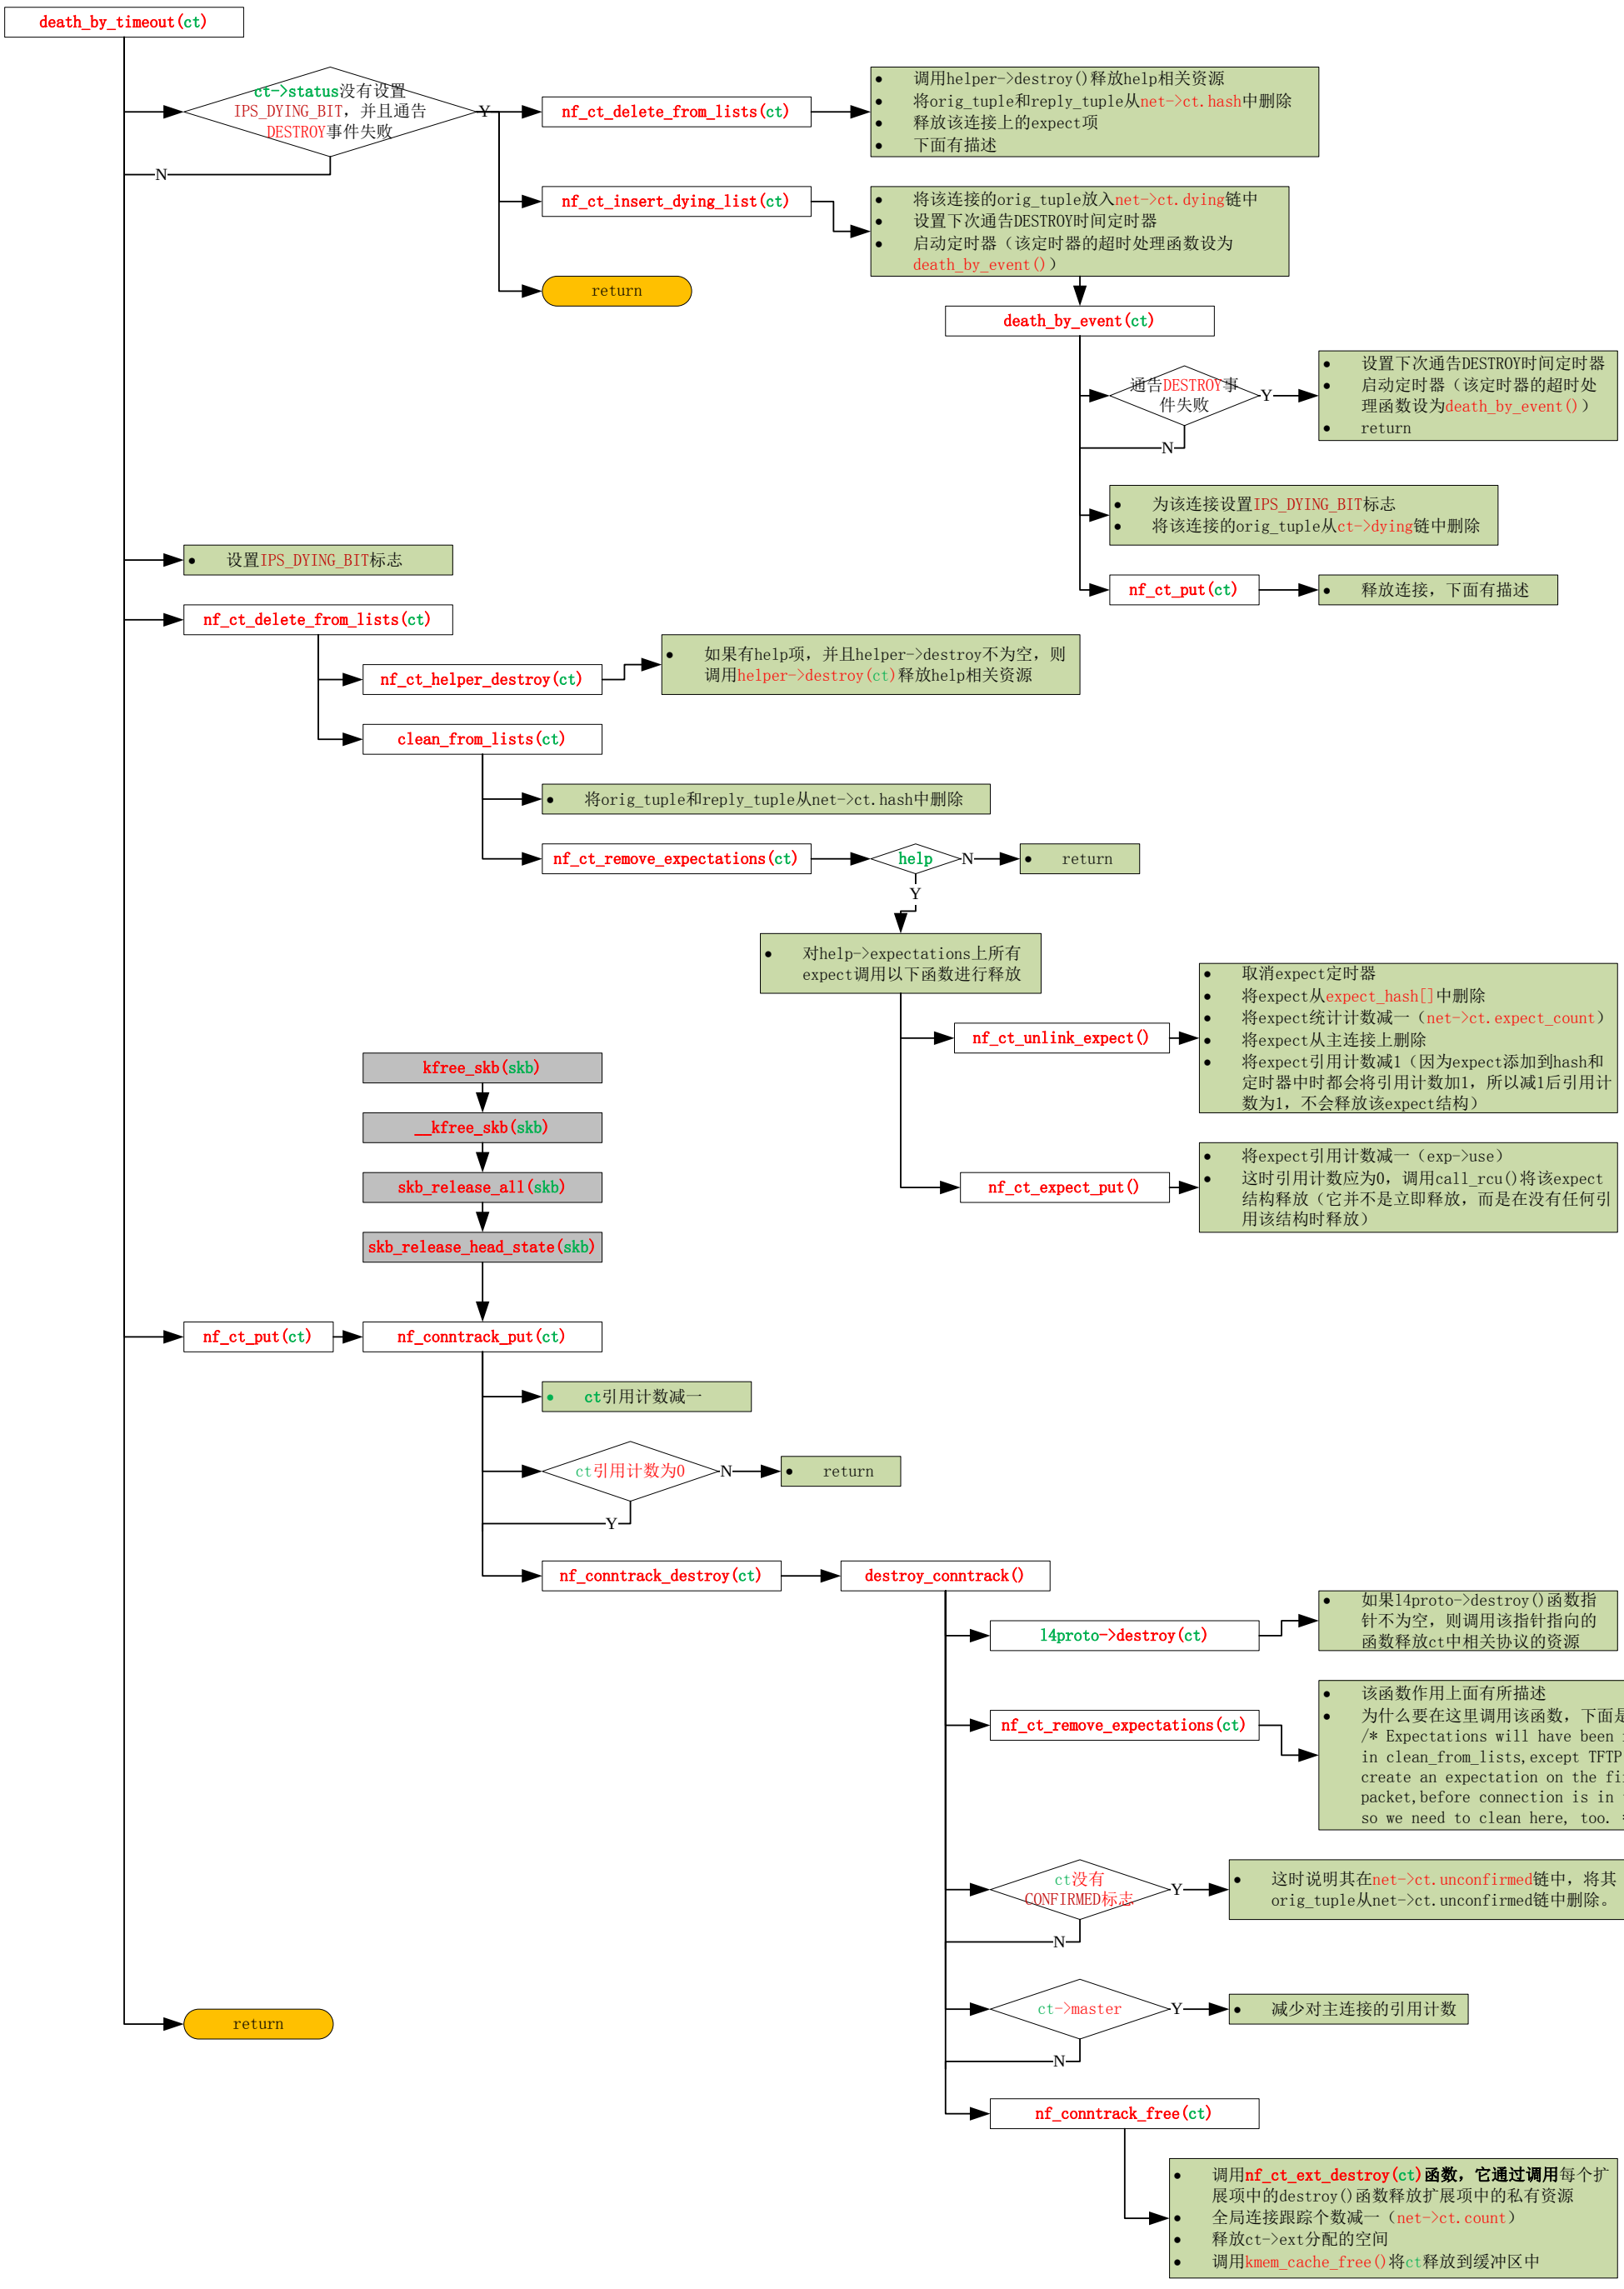

IPv4 利用 nf_conntrack 进行 NAT 转换

IPv4-NAT 初始化的资源

1　NAT 功能的连接跟踪部分初始化，通过函数 nf_nat_init()

1.1　调用 nf_ct_extend_register() 注册一个连接跟踪的扩展功能。

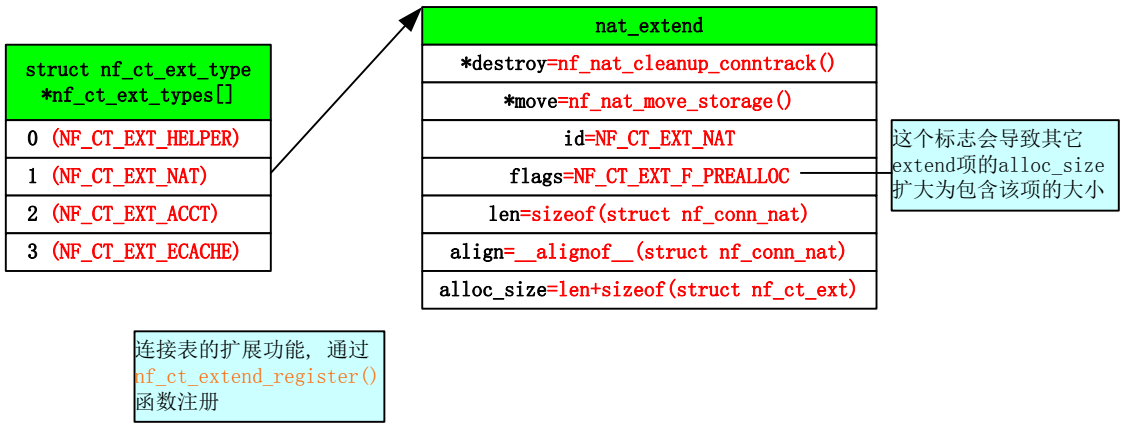

1.2　调用 register_pernet_subsys() --> nf_nat_net_init() 创建 net->ipv4.nat_bysource 的 HASH 表，大小等于 net->ct.htable_size。

1.3　初始化 nf_nat_protos[]数组，为 TCP、UDP、ICMP 协议指定专用处理结构，其它协议都指向默认处理结构。

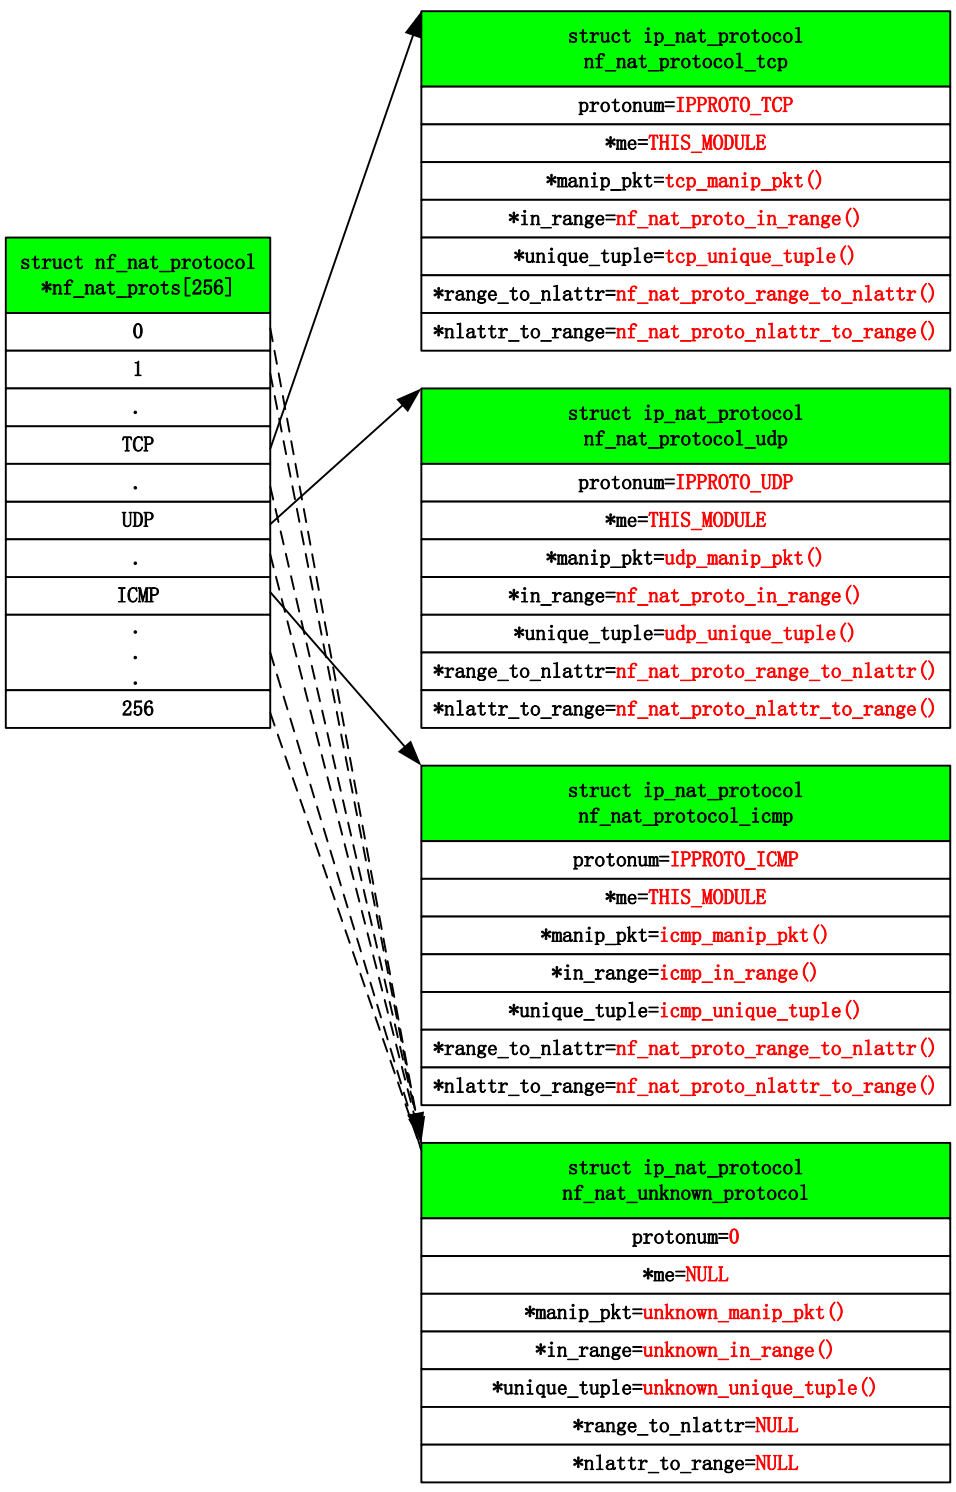

1.4　为 nf_conntrack_untracked 连接设置 IPS_NAT_DONE_MASK 标志。

1.5　将 NAT 模块的全局变量 l3proto 指向 IPV4 协议的 nf_conntrack_l3proto 结构。

1.6　设置全局指针 nf_nat_seq_adjust_hook 指向 nf_nat_seq_adjust()函数。

1.7　设置全局指针 nfnetlink_parse_nat_setup_hook 指向 nfnetlink_parse_nat_setup()函数。

1.8　设置全局指针 nf_ct_nat_offset 指向 nf_nat_get_offset()函数。

2　NAT 功能的 iptables 部分初始化，通过函数 nf_nat_standalone_init()

2.1　调用 nf_nat_rule_init() --> nf_nat_rule_net_init()在 iptables 中注册一个 NAT 表（通过 ipt_register_table()函数）

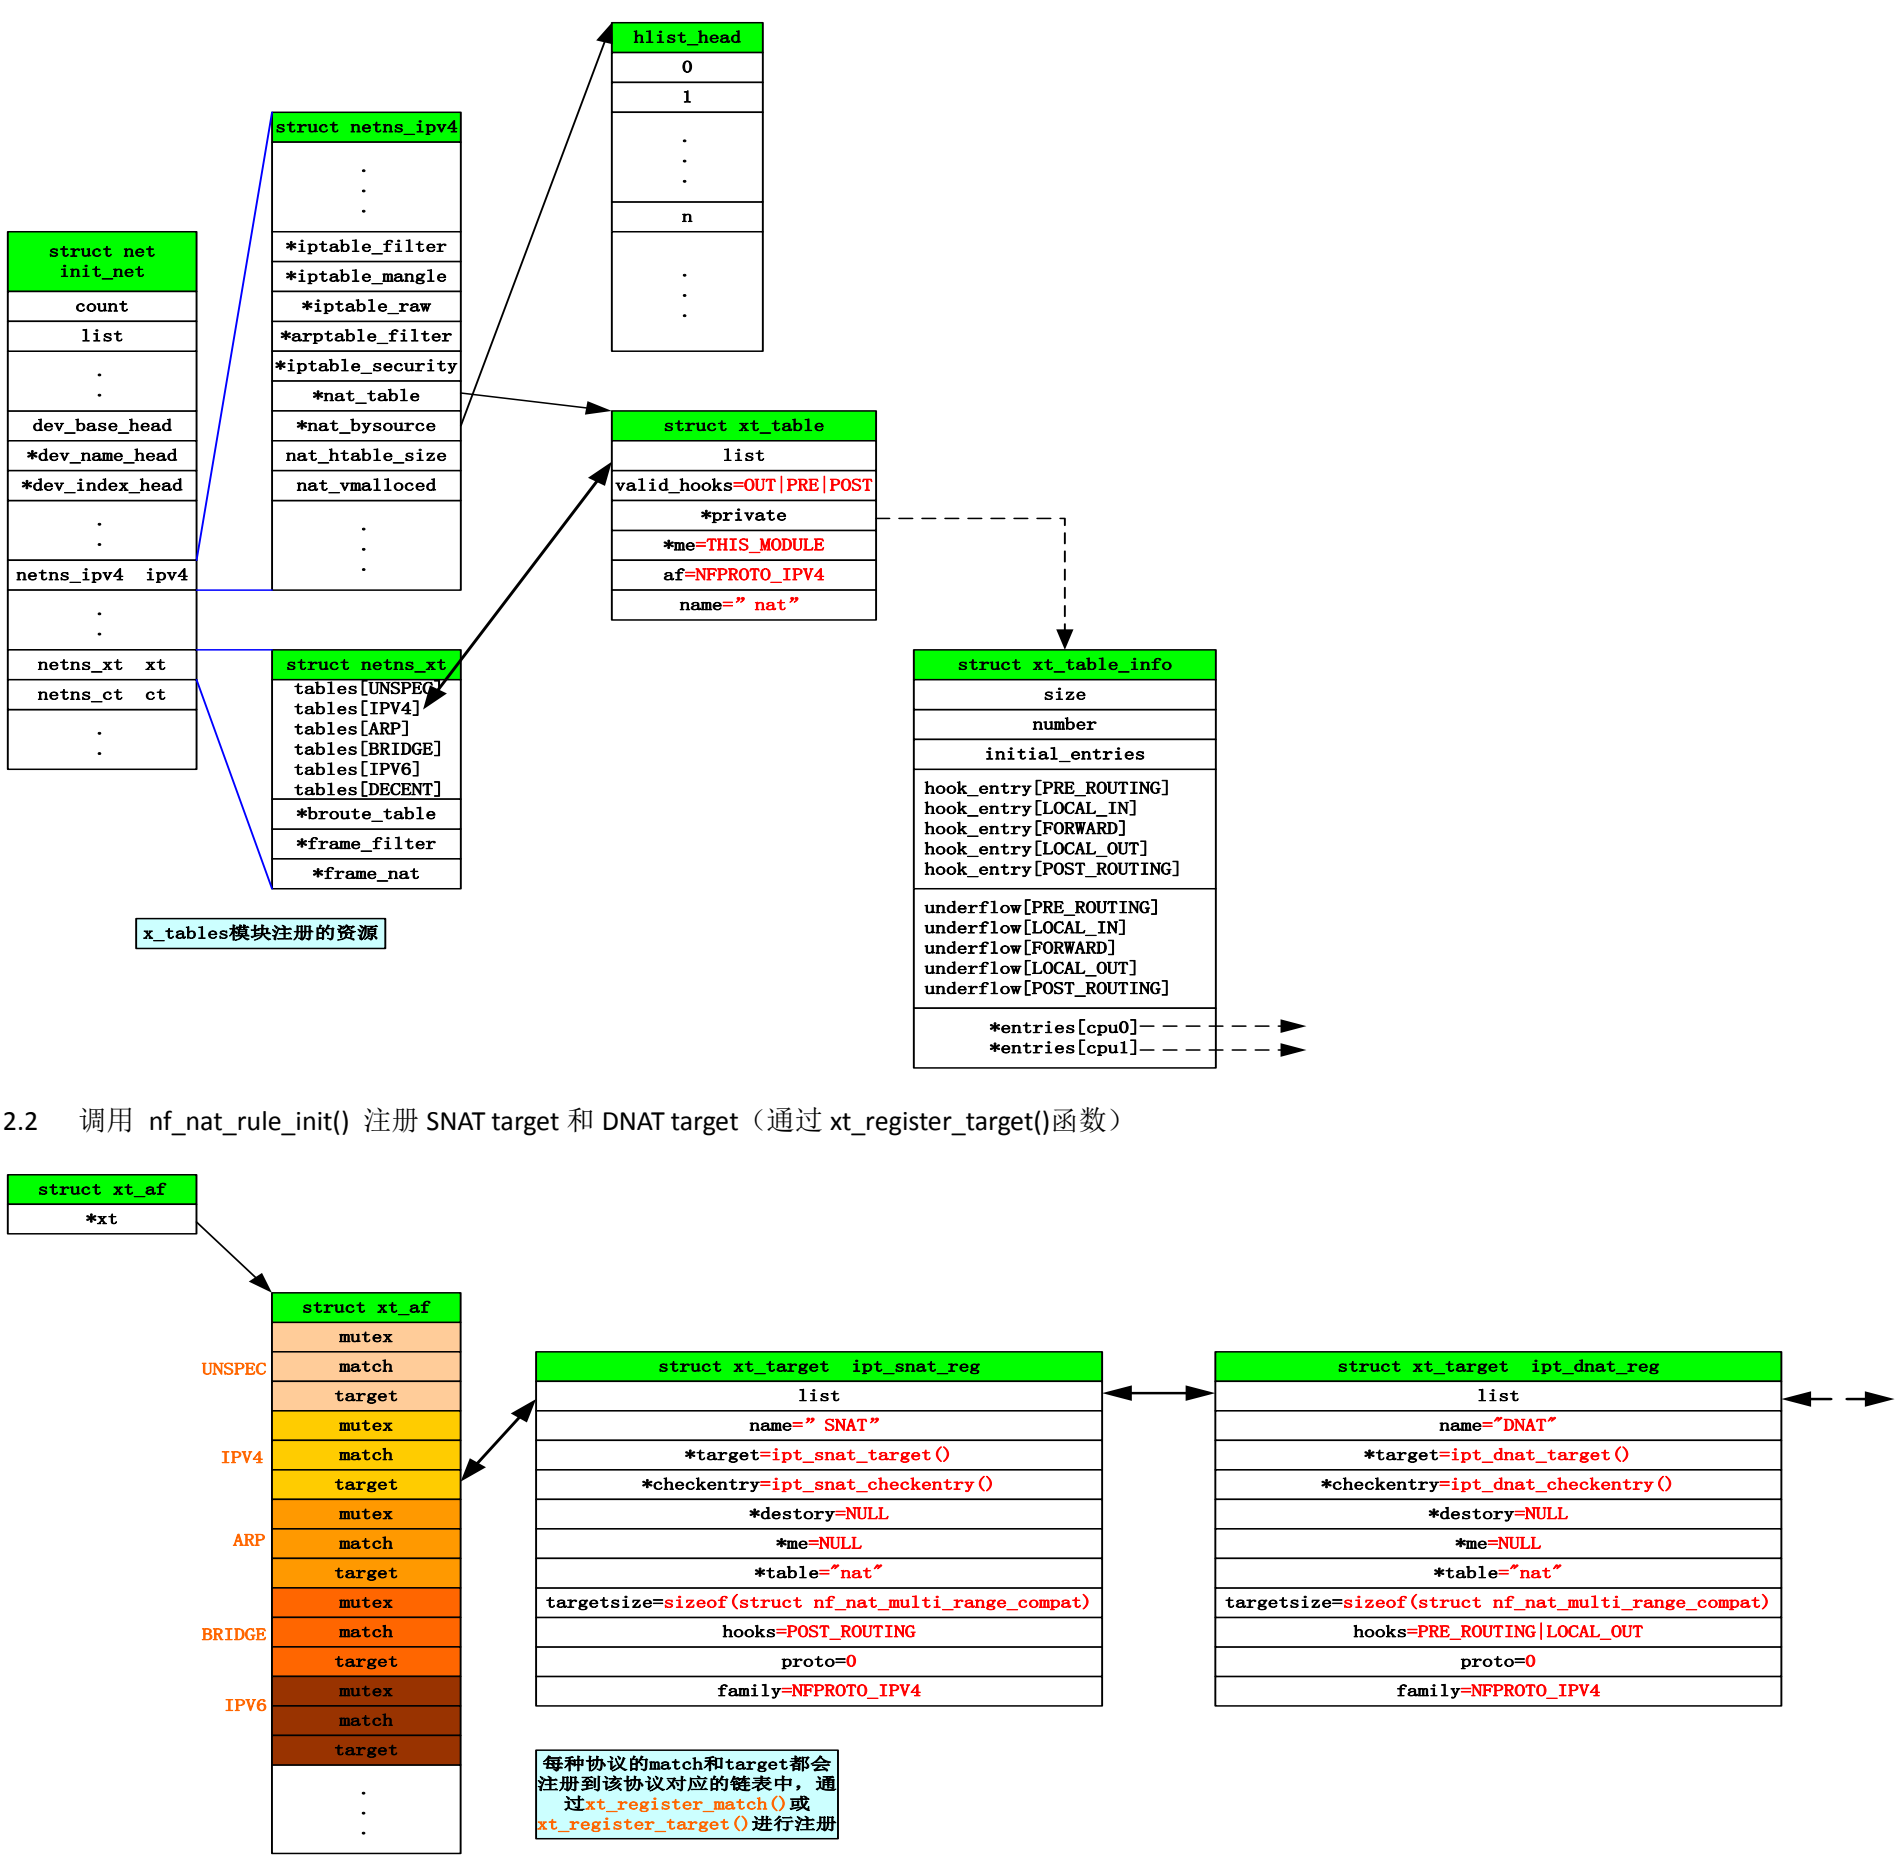

2.2 调用 nf_nat_rule_init() 注册 SNAT target 和 DNAT target（通过 xt_register_target()函数）

2.3 调用 nf_register_hooks() 挂载 NAT 的 HOOK 函数

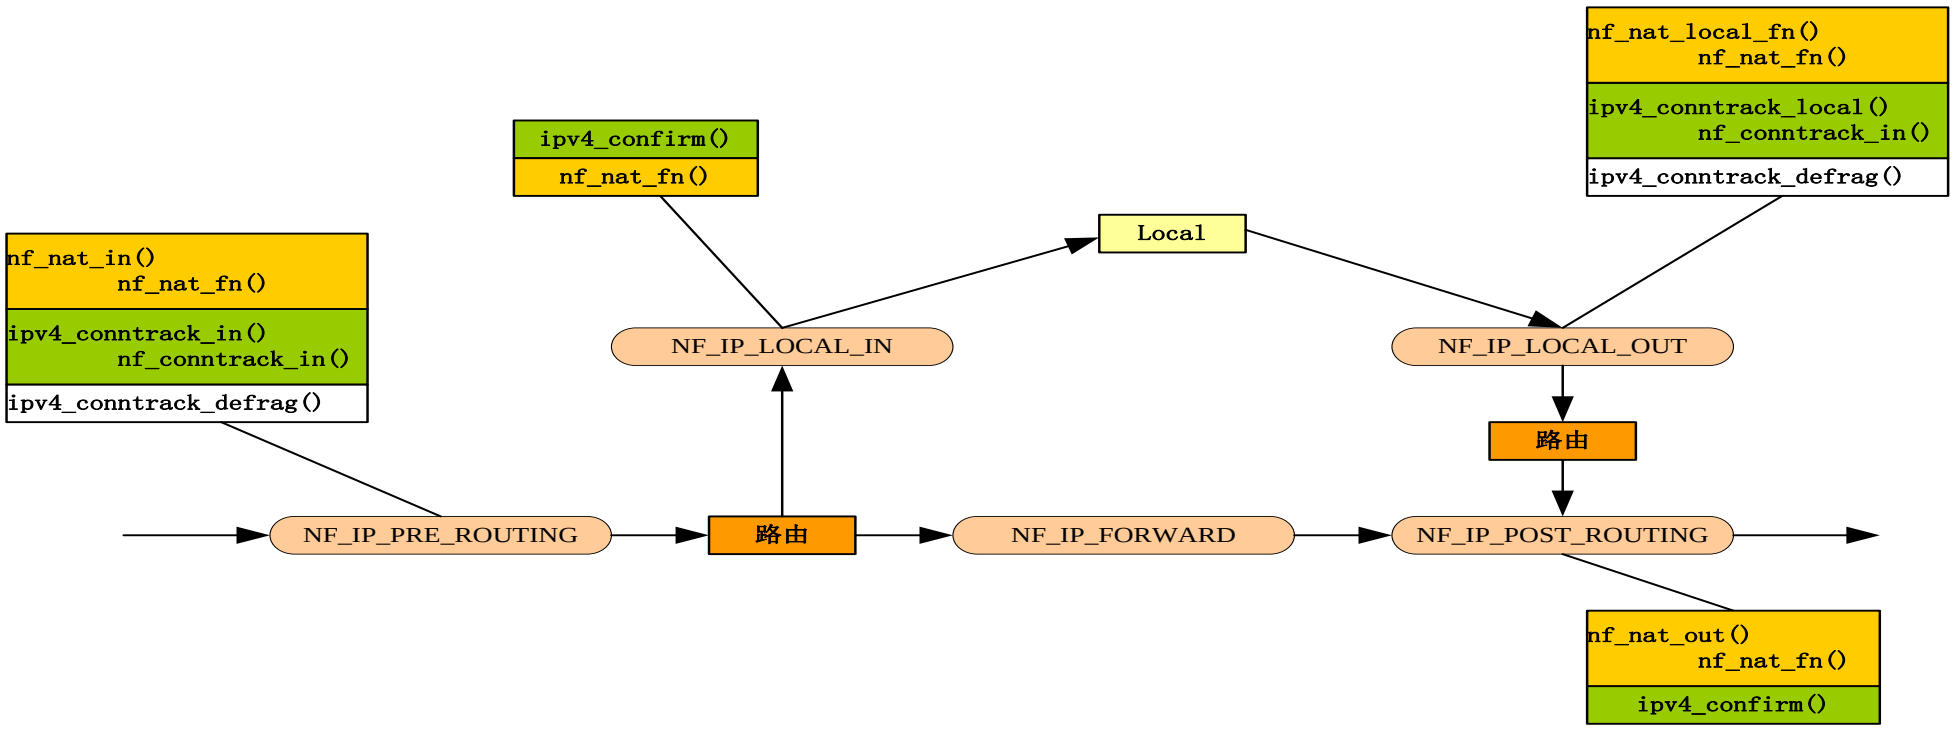

IPv4-NAT 处理流程

nf_nat_fn

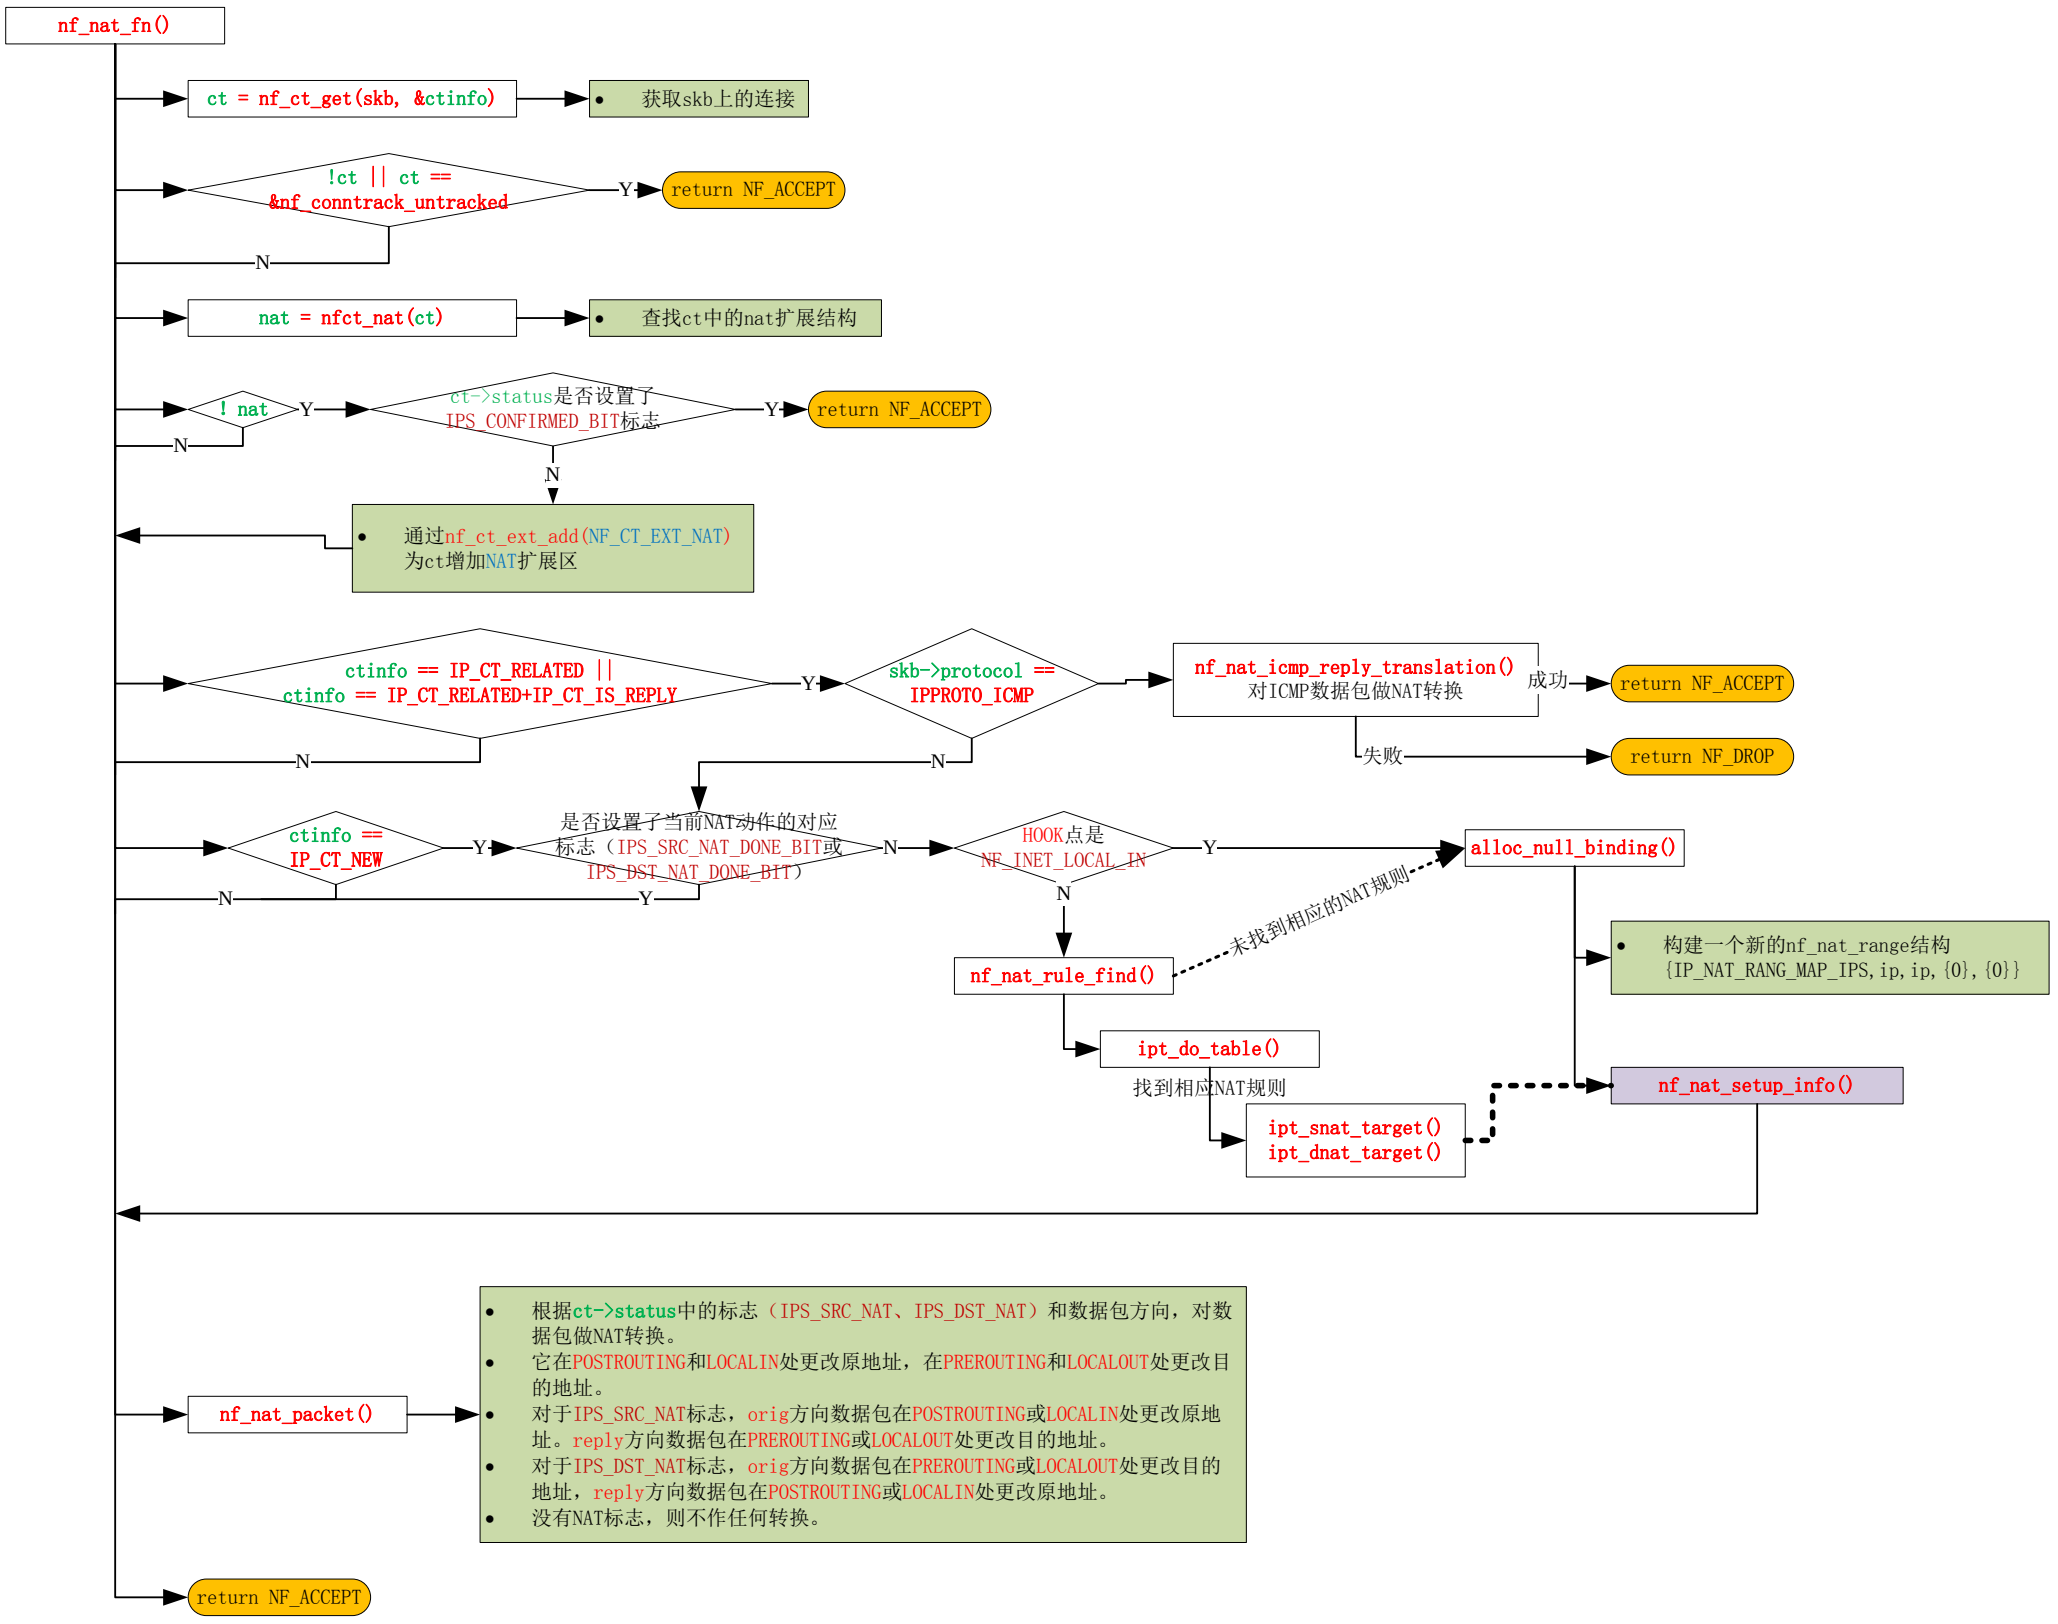

nf_nat_setup_info

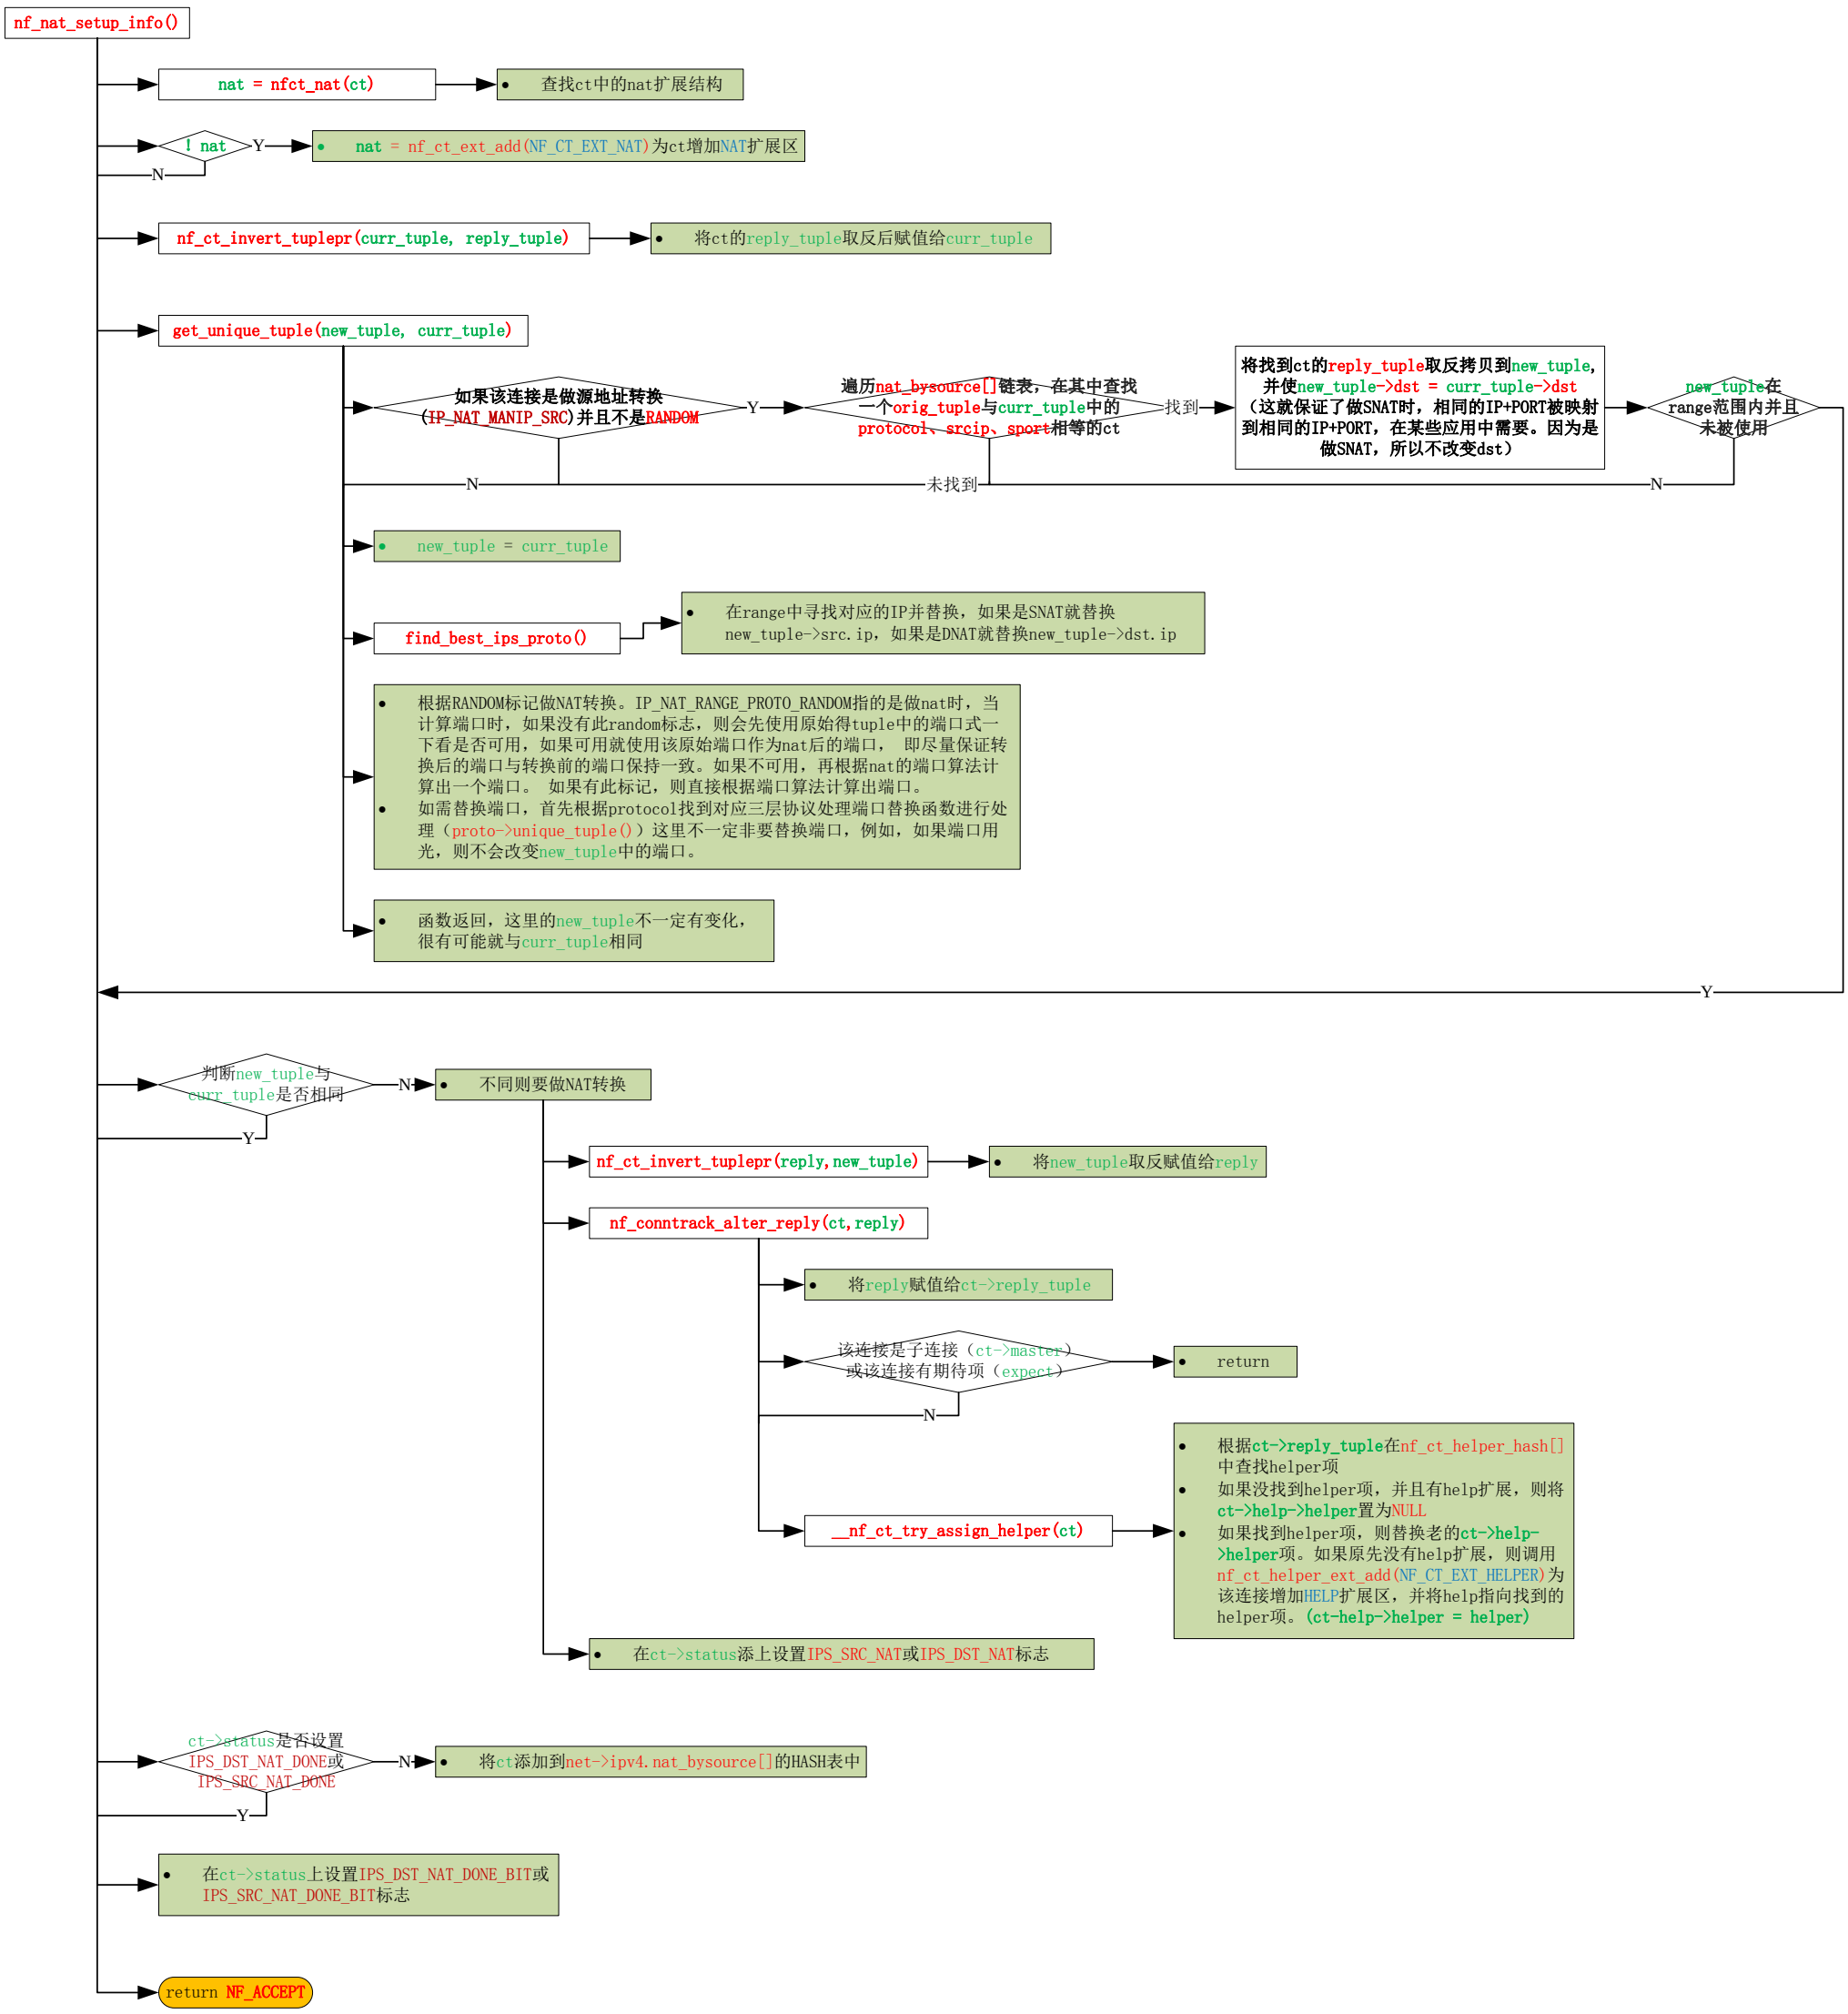

1 每个 ct 在第一个包就会做好 snat 与 dnat, nat 的信息全放在 reply tuple 中，orig tuple 不会被改变。一旦第一个包建立好 nat 信息后，后续再也不会修改 tuple 内容了。

2 orig tuple 中的地址信息与 reply tuple 中的地址信息就是原始数据包的信息。例如对 A->B 数据包同时做 snat 与 dnat，PREROUTING 处 B 被 dnat 到 D，POSTROUTING 处 A 被 snat 到 C。则 ct 的内容是: A->B | D->C, A->B 说明了 orig 方向上数据包刚到达墙时的地址内容，D->C 说明 reply 方向上数据包刚到达墙时的地址内容。

3 在代码中有很多!dir 操作，原理是: 当为了反向的数据包做事情的时候就取反向 tuple 的数据，这样才能保证 NAT 后的 tuple 信息被正确使用。

4 bysource 链中链接了所有 CT（做过 NAT 和未做过 NAT），通过 ct->nat->bysource，HASH 值的计算使用的是 CT 的 orig tuple。其作用是，当为一个新连接做 SNAT，需要得到地址映射时，首先对该链进行查找，查找此源 IP、协议和端口号是否已经做过了映射。如果做过的话，就需要在 SNAT 转换时，映射为相同的源 IP 和端口号。为什么要这么做呢？因为对于 UDP 来说，有些协议可能会用相同端口和同一主机不同的端口（或不同的主机）进行通信。此时，由于目的地不同，原来已有的映射不可使用，需要一个新的连接。但为了保证通信的的正确性，此时，就要映射为相同的源 IP 和端口号。其实就是为 NAT 的打洞服务的。所以 bysource 就是以源 IP、协议和端口号为 hash 值的一个表，这样在做 snat 时保证相同的 ip+port 影射到相同的 ip+port。

5 IP_NAT_RANGE_PROTO_RANDOM 指的是做 nat 时，当计算端口时，如果没有此 random 标志，则会先使用原始得 tuple 中的端口试一下看是否可用，如果可用就使用该原始端口作为 nat 后的端口， 即尽量保证转换后的端口与转换前的端口保持一致。如果不可用，再根据 nat 的端口算法计算出一个端口。 如果有此标记，则直接根据端口算法计算出端口。

6 第一个包之后，ct 的两个方向的 tuple 内容就固定了，所有的 nat 操作都必须在第一个包就完成。所以 daddr = &ct->tuplehash[!dir].tuple.dst.u3;会有这样的操作。

7 IPS_SRC_NAT 与 IPS_DST_NAT，如果被设置，表示经过了 NAT，并且 ct 中的 tuple 被做过 SNAT 或 DNAT。

8 数据包永远都是在 PREROUTING 链做目的地址和目的端口转换，在 POSTROUTING 链做原地址和原端口转换。是否要做 NAT 转换则要根数据包方向（dir）和 NAT 标志（IPS_SRC_NAT 或 IPS_DST_NAT）来判断。
PREROUTING 链，数据包是 original 方向，并且连接上设置 IPS_DST_NAT 标志，或数据包是 reply 方向，并且连接上设置 IPS_SRC_NAT 标志，则做 DNAT 转换。
POSTROUTING 链，数据包是 original 方向，并且连接上设置 IPS_SRC_NAT 标志，或数据包是 reply 方向，并且连接上设置 IPS_DST_NAT 标志，则做 SNAT 转换。

9 IPS_DST_NAT_DONE_BIT 与 IPS_SRC_NAT_DONE_BIT，表示该 ct 进入过 NAT 模块，已经进行了源或者目的 NAT 判断，但并不表示 ct 中的 tuple 被修改过。

10 源目的 nat 都是在第一个包就判断完成的，假设先添加了原 nat 策略，第一个包通过，这时又添加了目的 nat，第二个包近来时是不会匹配目的 nat 的 。

11 对于一个 ct，nf_nat_setup_info 函数最多只能进入 2 次，第一次 DNAT，第二次 SNAT。在 nf_nat_follow_master 函数中，第一次 SNAT，第二次 DNAT。

IPv4 动态协议的识别和 NAT 转换

动态协议 expect 结构的建立

动态协议 NAT 处理流程图

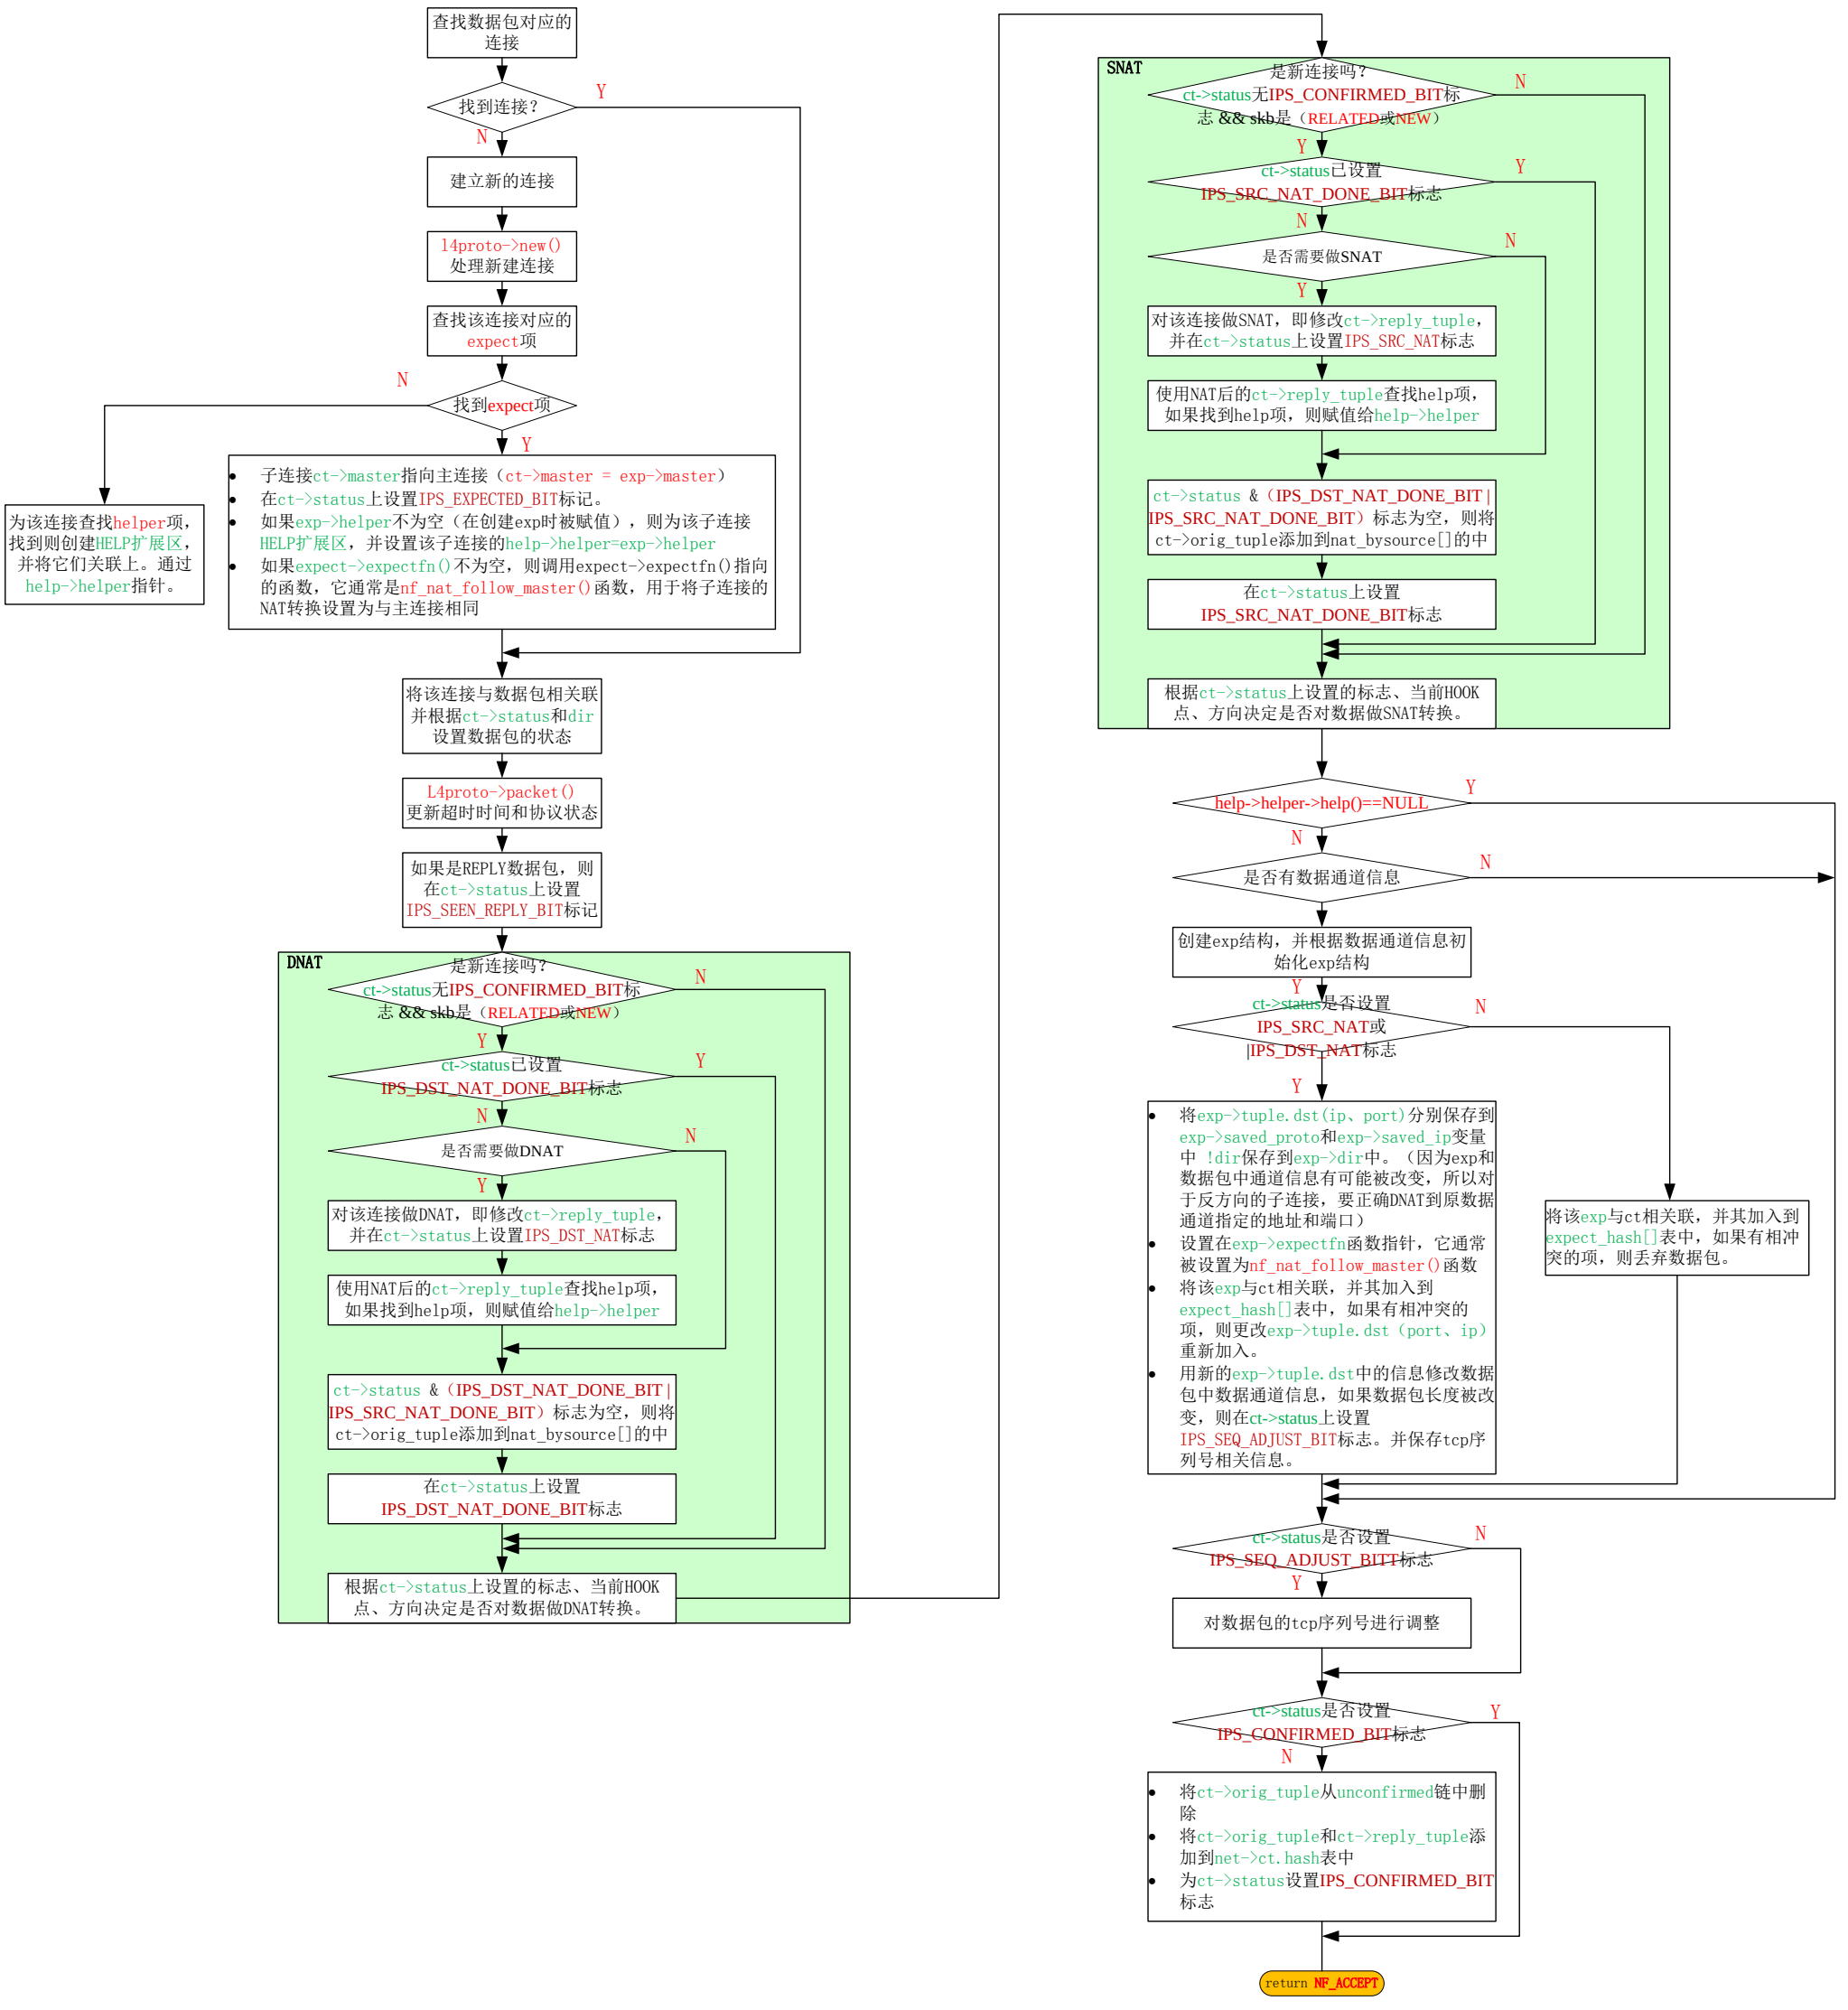

1 无子连接

1.1 一个 ct 用于跟踪一个连接的双方向数据，ct->orig_tuple 用于跟踪初始方向数据，ct->reply_tuple 用于跟踪应答方向数据。当根据初始方向数据构建 ct->orig_tuple 时，同时要构建出 ct->reply_tuple，用于识别同一连接上应答方向数据。

1.2 如果初始方向的数据在通过防火墙后被做了 NAT 转换，为识别出 NAT 数据的应答数据包，则对 ct->reply_tuple 也要做 NAT 转换。同时 ct 上做好相应 NAT 标记。

1.3 所以，上面的信息在初始方向第一个数据包通过后，就要求全部建立好，并且不再改变。

1.4 一个连接上不同方向的数据，都有相对应的 tuple（orig_tuple 和 reply_tuple），所以该连接后续数据都将被识别出来。如果 ct 上有 NAT 标记，则根据要去往方向（即另一个方向）的 tuple 对数据包做 NAT 转换。所以会有 ct->tuplehash[!dir].tuple 这样的操作。

2 有子连接

2.1 子连接是由主连接构建的 expect 项识别出来的。

2.2 help 用于构建 expect 项，它期待哪个方向的连接，则用那个方向的 tuple 和数据包中数据通道信息构建 expect 项。例如期待和当前数据包相反方向的连接，则用相反方向的 tuple 中的信息（ct->tuplehash[!dir].tuple）。调用 help 时，NAT 转换都已完成（tuple 中都包含有正确的识别各自方向的信息），所以这时所使用的信息都是正确和所期望的信息。

2.3 如果子连接还可能有子连接，则构建 expect 项时，初始化一个 helper 结构，并赋值给 expect->helper 指针。

2.4 如果该连接已被做了 NAT 转换，则对数据包中数据通道信息也要做 NAT 转换。这个工作是在 help 中完成的。同时，为保证子连接与主连接做相同的 NAT，要为 expect->expectfn()指针初始化一个函数，用于对子连接做 NAT 转换。

2.5 在新建一个连接时，如果匹配上某个 expect 项，则说明该连接是子连接。这时要根据 expect 项中信息对子连接做下面两件事：

2.5.1 如果 expect->helper 指针不为空，则为该子连接关联 expect 指定的 help 项。

2.5.2 如果 expect->expectfn()指针不为空，这调用指针指向的函数，对子连接做 NAT 转换。这样后面 NAT 模块就会根据子连接中信息对子连接数据做 NAT 转换。

包过滤规则

Xtables 提供的资源

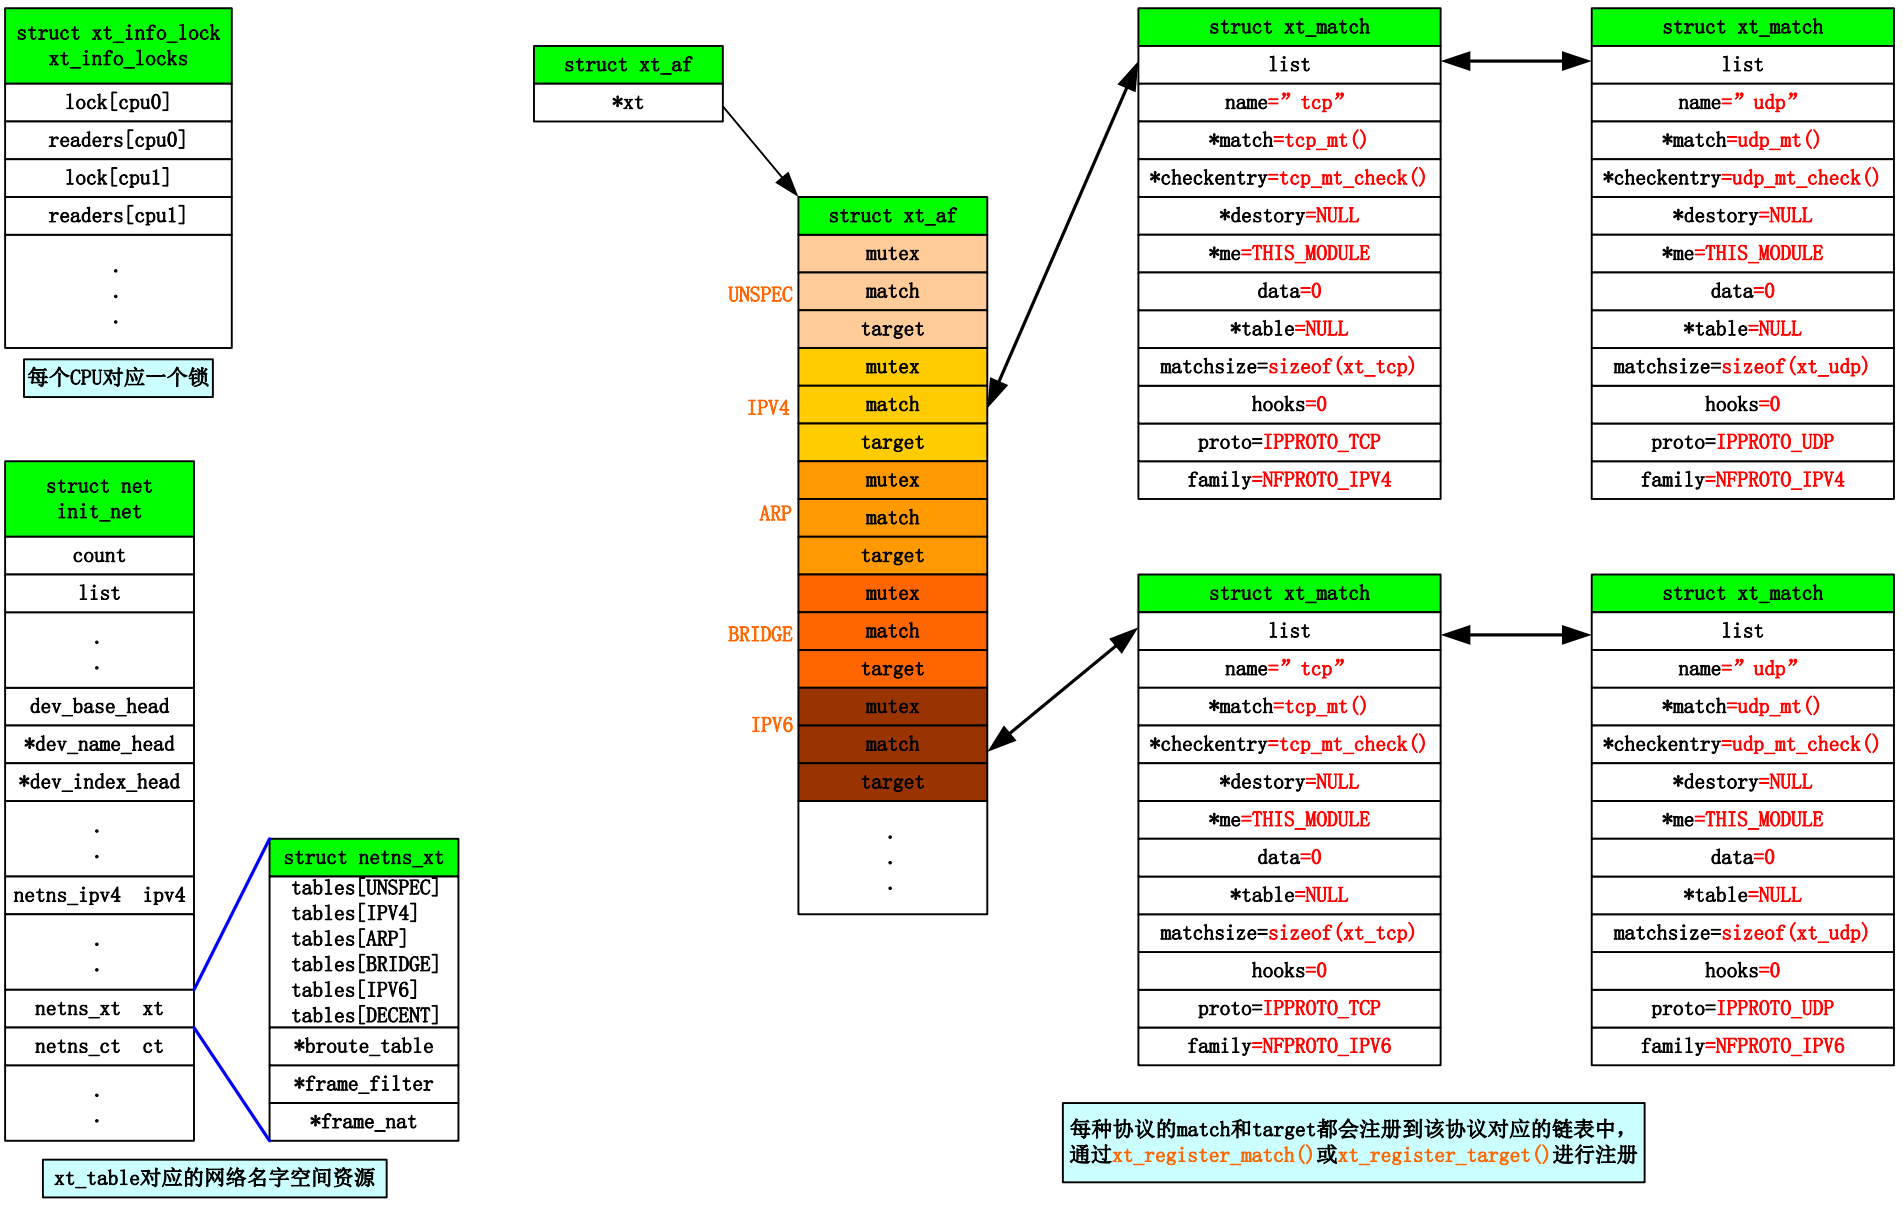

1 struct xt_af xt[]结构数组

该数组用于挂载各个协议的 match 和 target 资源。由于写者（添加、删除）和读者（查找）都是在内核空间进程上下文执行，所以它们只需要用 xt[n].mutex 信号量进行互斥。读者（查找）在将规则关联上一个 match 或 target 时会增加它们所在模块的引用计数，在它释放这个引用计数之前该模块是不会被卸载的，所以另外一个读者（规则匹配）在软中断中可以放心的使用，不需加任何锁。

1.1 xt_register_match(struct xt_match *match)与 xt_unregister_match(struct xt_match *match)

用于在 xt[]数组上挂载对应协议的 match，由于它们都是在内核空间的进程上下文被使用，所以它们使用 mutex_lock(&xt[af].mutex)信号量进行加锁和解锁。（写者）

1.2 xt_register_target(struct xt_target *target)与 xt_unregister_target(struct xt_target *target)

用于在 xt[]数组上挂载对应协议的 target，由于它们都是在内核空间的进程上下文被使用，所以它们使用 mutex_lock(&xt[af].mutex)信号量进行加锁和解锁。（写者）

1.3 struct xt_match *xt_find_match(u8 af, const char *name, u8 revision)与 struct xt_target *xt_find_target(u8 af, const char *name, u8 revision)

用于在 xt[]数组中查找对应协议的 match 或 target 与对应规则相关联，并增加 match 和 target 所在模块的引用计数。由于它们都是在内核空间的进程上下文被使用，所以它们使用 mutex_lock(&xt[af].mutex)信号量进行加锁和解锁。同时内核在软中断中进行规则匹时配，它引用规则关联的 match 和 target 是安全的，因为 match 和 target 所在模块由于引用计数是不会被释放的。（读者）

1.4 由于有一个读者是在软中断的中，并且有多个 CPU 同时使用，是否需要其它保护。答：不需要。因为如果软中断中引用的规则使用了某个 match 或 target，则拥有该 match 和 target 模块的引用计数会被加 1，该模块将不会被卸载（这也就要求在调用 xt_unregister_match()或 xt_unregister_target()时必须先判断它们所在模块的引用计数，通常它们被放在模块注销函数中）。如果引用计数为 0，则说明没有规则引用该 match 或 target，则在软中断中也不会使用它。

2 net.xt.tables[]网络命名空间协议链表

该命名空间协议链表用于将不同协议的 table 表挂到对应协议链表中。

写者（添加、删除）table 表都在内核空间进程上下文执行，又由于它需要检查该表与注册的 target、match 名字不冲突，所以他们只需要用 xt[n].mutex 信号。

读者在软中断中通过 HOOK 引用这些表，所以在写者（添加、删除）之前一定要保证没有读者在操作。添加表操作一定要先通过 xt_register_table()添加一个表，然后再通过 xt_hook_link()使 HOOK 能够引用这些表；删除表操作一定要先通过 xt_hook_unlink()去掉 HOOK 对表的引用，然后再通过 xt_unregister_table()删除一个表。

2.1 struct xt_table *xt_register_table(struct net *net, const struct xt_table *input_table, struct xt_table_info *bootstrap, struct xt_table_info *newinfo)

主要是复制 input_table 到 table 表，并将 newinfo（由调用该函数模块提供的私有数据 xt_table_info）与该表的 table->private 指针相关联，然后根据该表指定的协议挂入对应的 net.xt.table[table->af]链表中。它使用 xt[n].mutex 信号进行加锁（如上所述）。

2.2 void *xt_unregister_table(struct xt_table *table)

主要是将 table 从 net.xt.table[table->af]链表中取下来，并返回 table->private 指针指向的 xt_table_info 数据。它使用 xt[n].mutex 信号进行加锁（如上所述）。

2.3 struct nf_hook_ops *xt_hook_link(const struct xt_table *table, nf_hookfn *fn)与 void xt_hook_unlink(const struct xt_table *table, struct nf_hook_ops *ops)

主要是利用 xt_table 结构和钩子函数构造出 nf_hook_ops 钩子项，然后调用 nf_register_hooks()或 nf_unregisgter_hooks()函数来注册或注销 ipv4 协议对应点的钩子函数，这两个函数主要用在内核空间的进程上下文。由于 nf_regisgter_hooks()已提供了保护，所以它们不需要任何形式的锁保护。

Iptables 利用 Xtable 初始化 filter 表的结构图

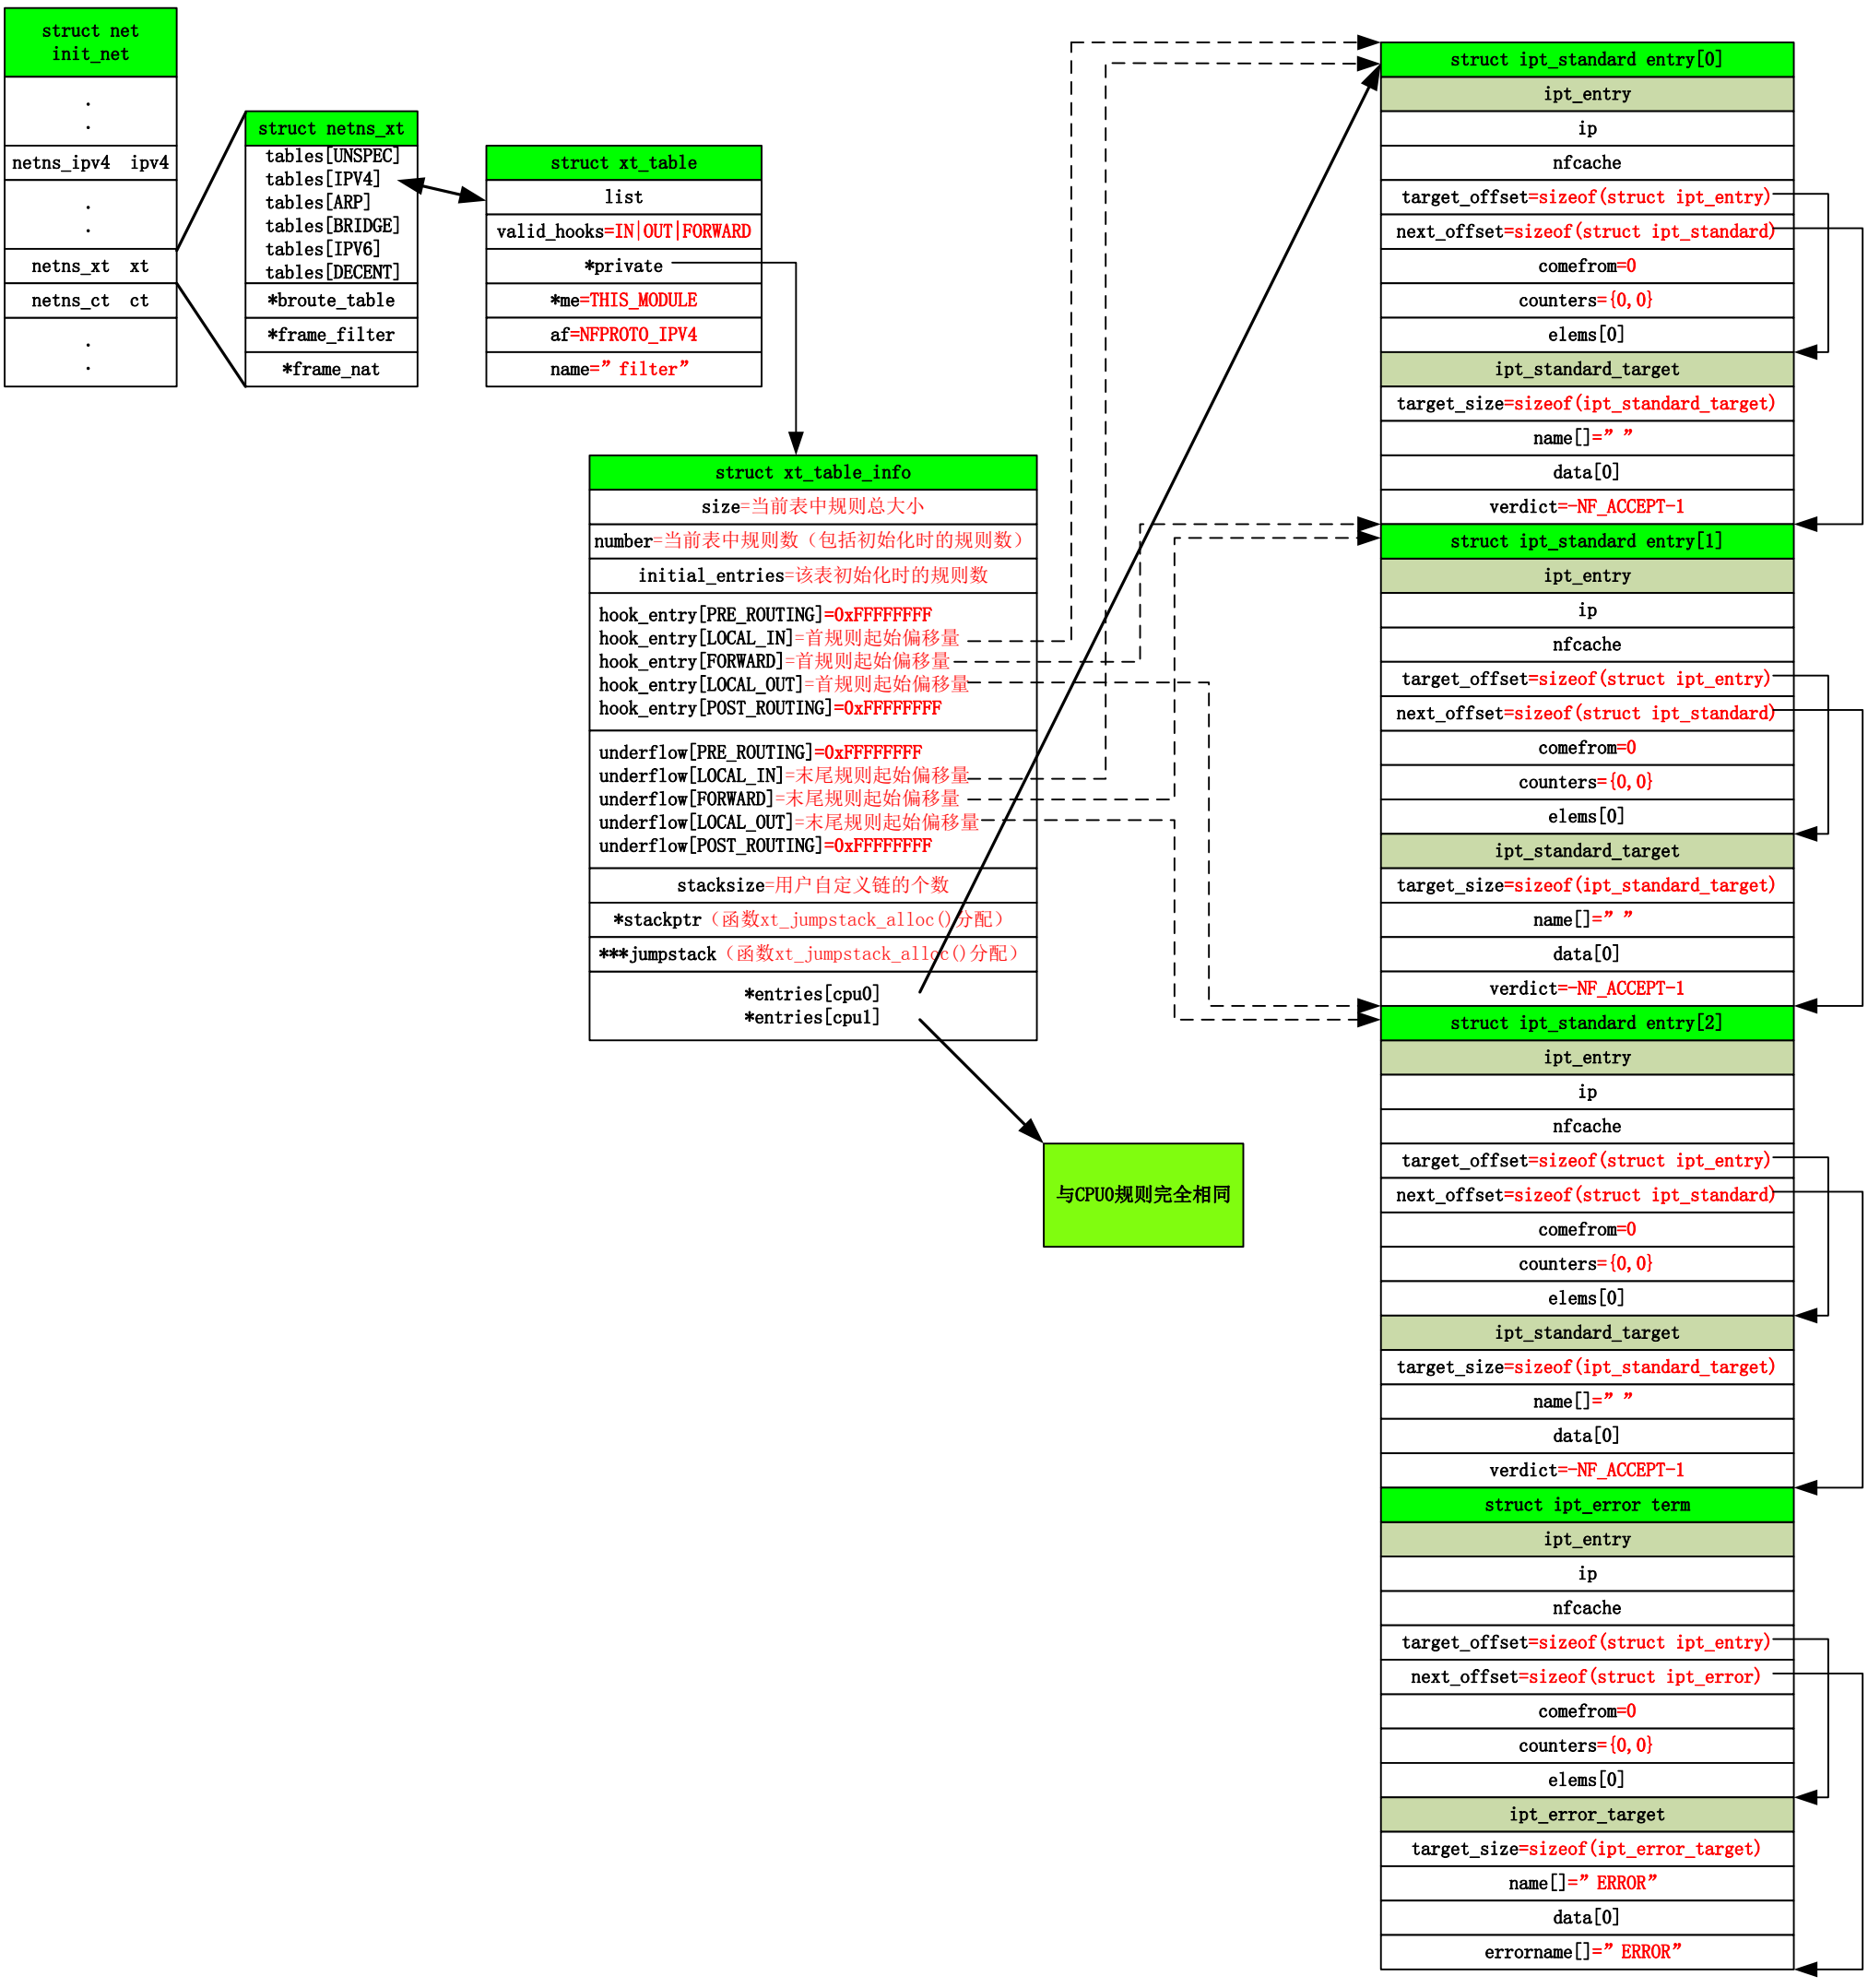

1 struct xt_table *ipt_register_table(struct net *net, const struct xt_table *table, const struct ipt_replace *repl)（注册并初始化一个表，然后调用 xt_hook_link()引用该表）
该函数是 iptables 为 filter、nat、mangle 模块提供用于注册相应表结构的接口。它根据当前表要被挂入的 HOOK 点来构建上图所示的 xt_table_info 初始规则表，并调用 xt_register_table()函数将 filter 表的 xt_table 和 xt_table_info 结构挂入 net.xt.table[IPV4]链表中。（上图是 iptables_filter 模块调用该函数注册的结构图）
注册完一个表后，就可以通过 xt_hook_link()函数注册一个 HOOK 点来使用这个表中的规则处理数据包。

2 void ipt_unregister_table(struct net *net, struct xt_table *table)（注销一个表，要在 xt_hook_unlink()之后使用）
该函数是 iptables 为 filter、nat、mangle 模块提供用于注销相应表结构的接口。它调用 xt_unregister_table()将 xt_table 从对应协议链表中取下并释放，然后将返回的 xt_table_info 结构中的规则逐一释放（同时也会释放规则引用的 match 和 target 模块的引用计数），最后释放 xt_table_info 结构。
为保证释放 table 表时没有其它读者，所以在调用该函数之前要先调用 xt_hook_unlink()函数注销在 HOOK 点挂入的处理函数，保证没有其它 CPU 会再引用到该表。

3 struct xt_info_lock xt_info_locks[CPU]（用于保证读取修改表中规则的锁，每个 CPU 一个锁）

3.1 struct xt_table *xt_find_table_lock(struct net *net, u_int8_t af, const char *name)
查找 name 指定的表，使用 xt[af].mutex 加锁，保证只有一个写者处理该表。并增加表所在模块的引用计数，防止该表被错误释放。

3.2 void xt_table_unlock(struct xt_table *table)

与 xt_find_table_lock()配对使用，释放 xt[table->af].mutex 锁。

3.3 static inline void xt_info_rdlock_bh(void) 或 static inline void xt_info_rdunlock_bh(void)

获取或释放本 CPU 的 xt_info_locks[cpu]锁。这个锁主要是用于防止正被使用的规则表（xt_table_info 结构）被释放。（它与 get_counters()进行互斥）

3.4 static inline void xt_info_wrlock(unsigned int cpu) 或 static inline void xt_info_wrunlock(unsigned int cpu)

获取指定 CPU 的 xt_info_locks[cpu]锁。它主要在 get_counters()中被调用，用于获取所有 CPU 的写锁，保证所有 CPU 都已完成了对规则表的引用。

3.5 static void get_counters(const struct xt_table_info *t, struct xt_counters counters[])

它可以保证其它 CPU 都已完成了一次对表中所有规则的引用。因为它要对所有其它 CPU 调用 xt_info_wrlock(cpu)函数来获取其它 CPU 的 xt_info_lock，而其它 CPU 在读取表中规则时，要通过 xt_info_rdlock_bh 获取各自的 xt_info_lock 锁，所有当它获取完所有其它 CPU 的 xt_info_lock 锁后，就表示其它 CPU 都已完成了对表中规则的引用。这就说明了为什么在 do_replace 中调用完 get_counters()后能够安全的释放旧的 xt_table_info 结构。

4 static int get_info(struct net *net, void __user *user, const int *len, int compat) （读取表中信息）

该函数是用户使用 iptables 命令操作表中规则时，用于获取表中信息的接口。它使用 xt_find_table_lock()和 xt_table_unlock()保证没有其它人操作该表。

5 static int get_entries(struct net *net, struct ipt_get_entries __user *uptr, const int *len)（读取表中规则）

该函数是用户使用 iptables 命令操作表中规则时，用于获取表中规则的接口。它使用 xt_find_table_lock()和 xt_table_unlock()保证没有其它人操作该表。

6 unsigned int ipt_do_table(struct sk_buff *skb, unsigned int hook, const struct net_device *in, const struct net_device *out, struct xt_table *table) （读取表中规则）

该函数是 iptables 为 filter、nat、mangle 模块提供用于对数据包匹配各表中规则的接口。它根据表对应的 xt_table_info 结构中的信息，找到相应的规则，对数据包进行逐一匹配。为保证所引用表中的规则（xt_table_info）不被其它写者释放，同时又不影响到其它读者，使用 xt_info_rdlock_bh()和 xt_info_rdunlock_bh()来加锁和解锁。

7 static int do_replace(struct net *net, const void __user *user, unsigned int len) （修改表中规则）

该函数是 iptables 为 filter、nat、mangle 模块提供用于在对应表中下规则的接口。它根据用户传递过来的规则，构建一个新的 xt_table_info 结构和规则，并将它们与对应表的 xt_table->private 相关联。它通过 xt_find_table_lock()和 xt_table_unlock()保证当前只有一个写者在操作该表。通过 local_bh_disable()和 local_bh_enable()保证更换 table->private 指向新的 xt_table_info 结构时不被打断。通过 get_counters()保证所有其它 CPU 都不再使用旧的 xt_table_info 结构，安全释放旧的 xt_table_info 结构。

7.1 static int translate_table(struct net *net, struct xt_table_info *newinfo, void *entry0, const struct ipt_replace *repl)

根据 ipt_replace 结构构建一个 xt_table_info 结构，并做一些必要的检查（链是否环路等），同时将表中的规则与相应的 match 和 target 相关联。

7.2 struct xt_table_info *xt_replace_table(struct xt_table *table, unsigned int num_counters, struct xt_table_info *newinfo, int *error)

为 newinfo 调用 xt_jumpstack_alloc(struct xt_table_info *i)初始化 stack 相关数据，然后使 table->private 指向 newinfo，并返回 oldinfo。

8 总结：

8.1 为每个 CPU 建立一个规则集的原因：是为了在更新规则计数时避免加写锁，每个 CPU 只更新自己规则集中的规则计数。用户上下文通过 write_lock_bh()来阻止本地 CPU 和其它 CPU 访问或修改这个规则集，这样它就可以读取或更新规则集了。

8.2 为每个 CPU 建立一个读写锁（xt_info_locks[CPU]）的原因：由于每个 CPU 一个规则集（它们在更新计数器时也只需使用读锁），当用户更新规则或获取规则计数时（它是计算所有 CPU 规则集的计数），就要通过 write_lock_bh()阻止本地 CPU 和其它 CPU 访问或修改这个规则集，这就使其它 CPU 都等待这个锁而无法工作。通过使用 xt_info_locks[CPU]多 CPU 锁，每计算一个 CPU 规则集计数时，就只对该 CPU 加写锁，从而减少对其它 CPU 的影响。

Iptables 利用 Xtables 构建的组织形式

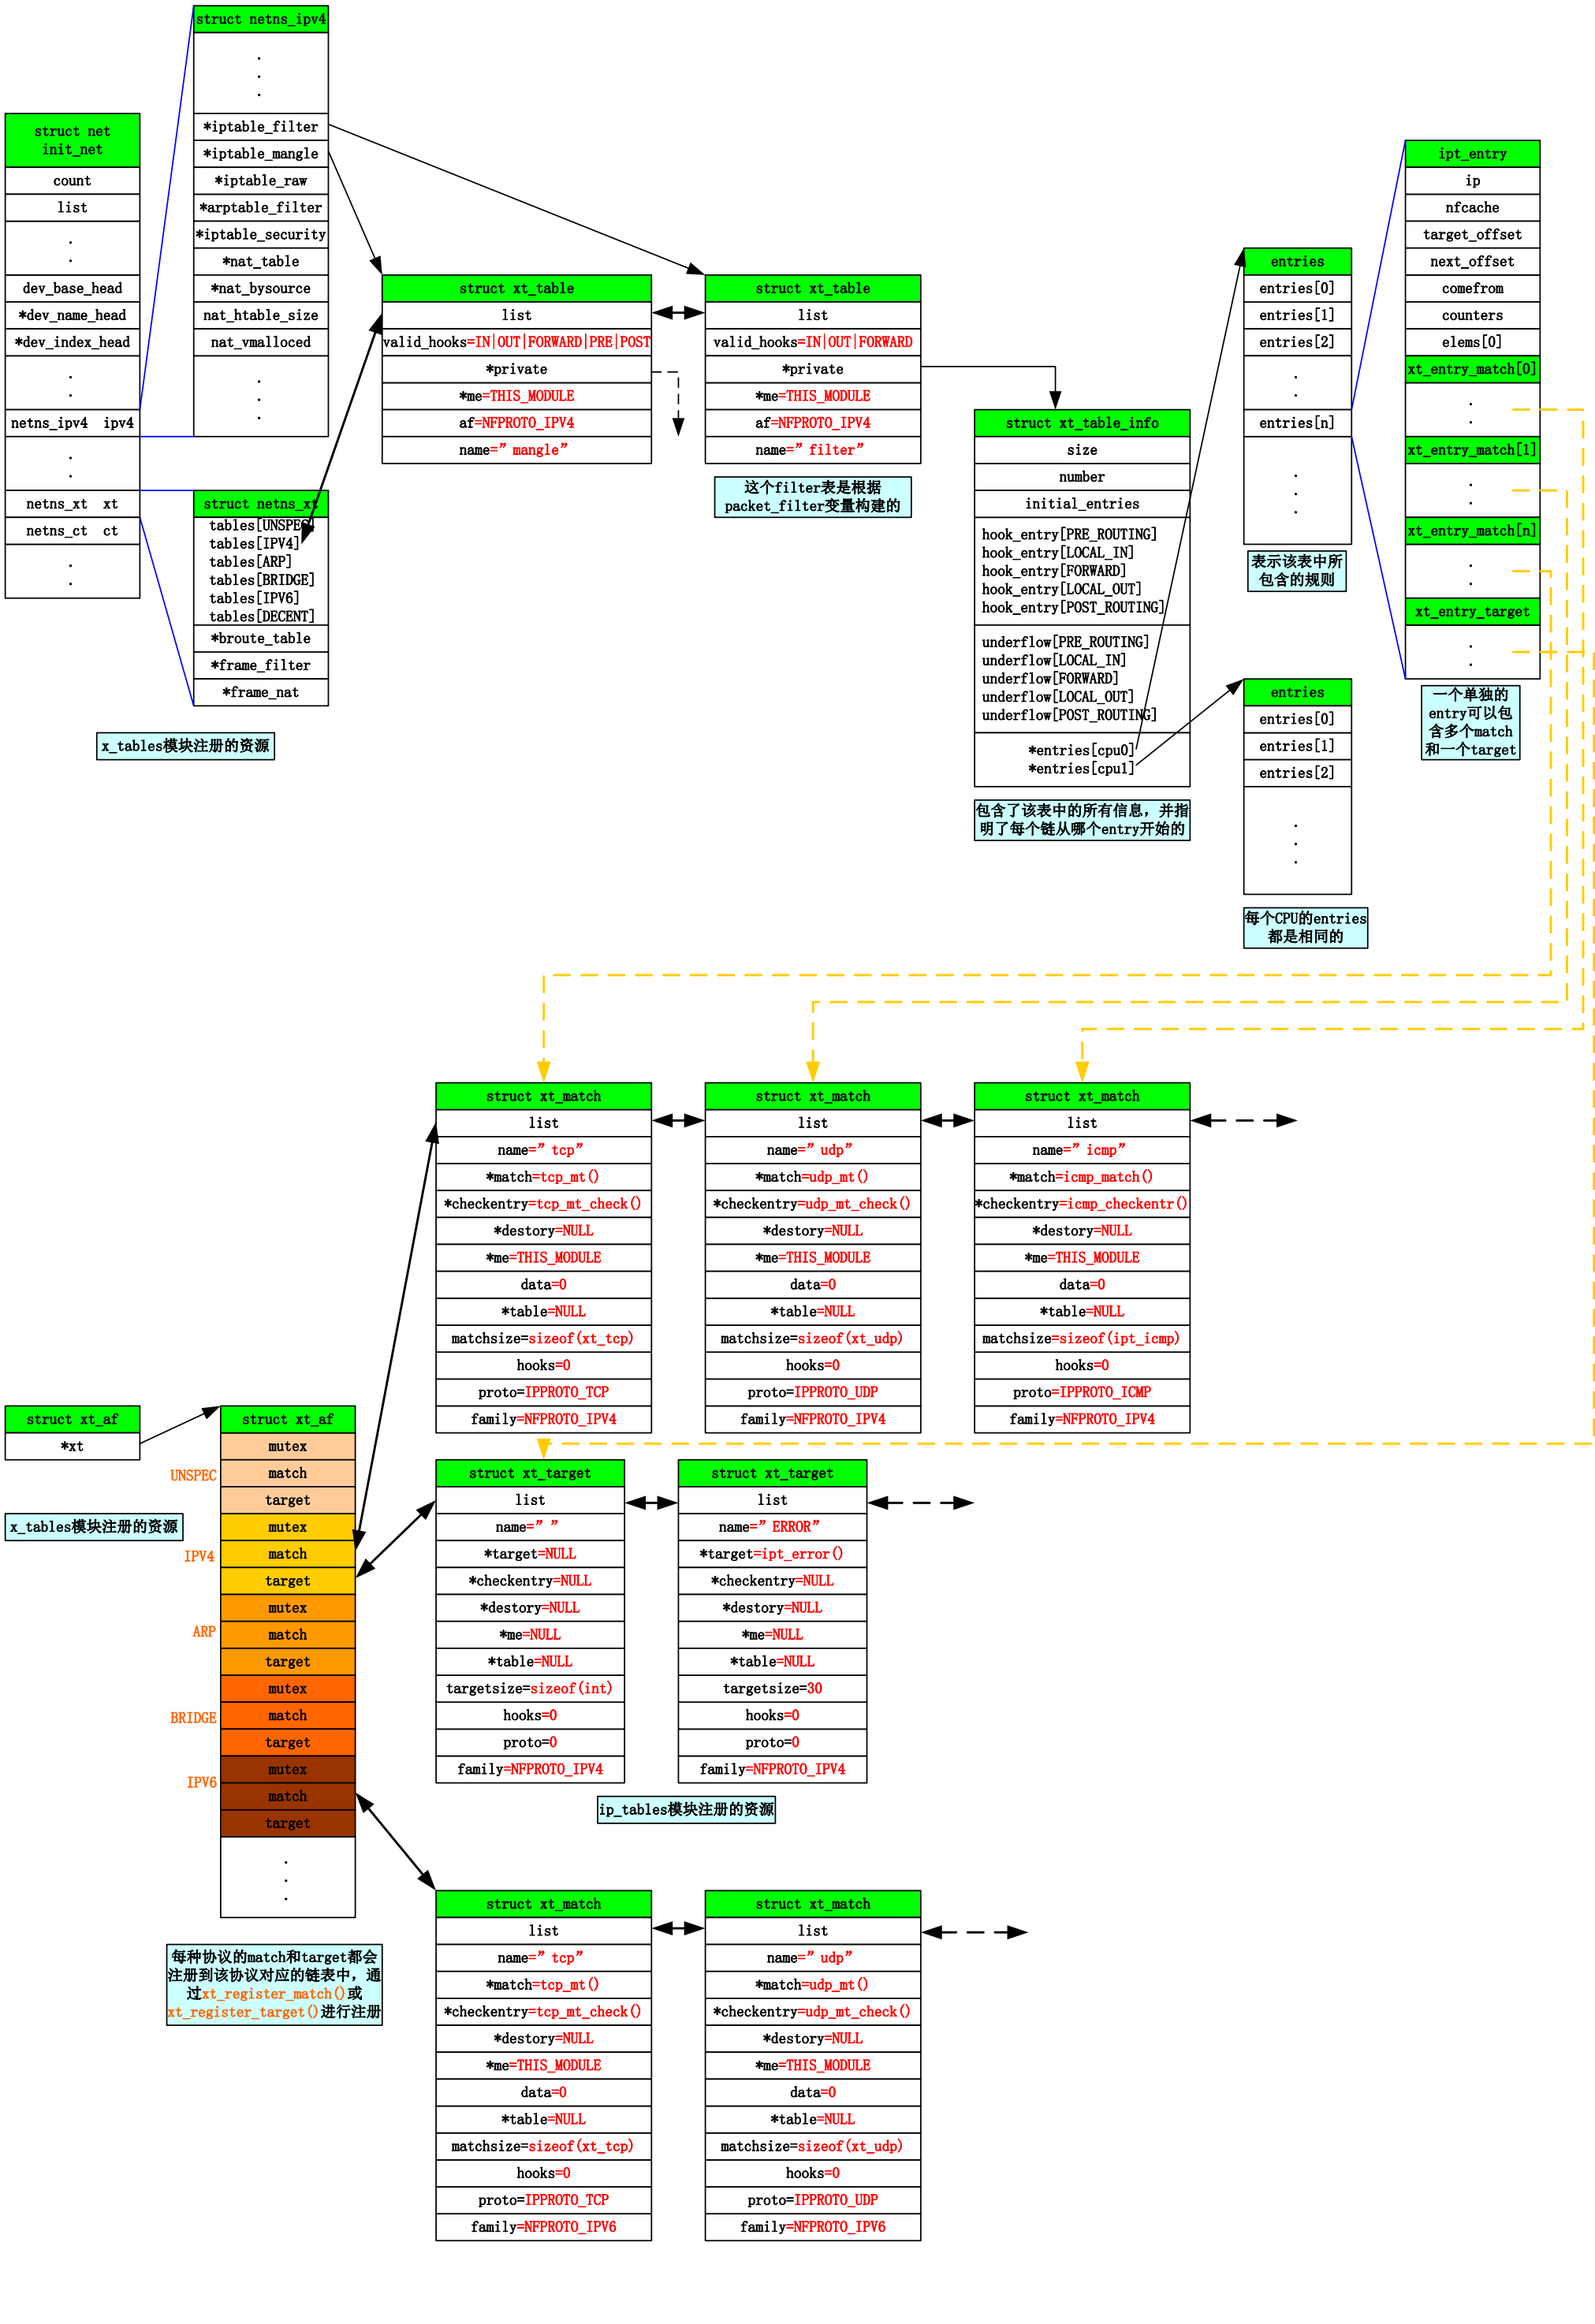

Iptable 用户态的资源

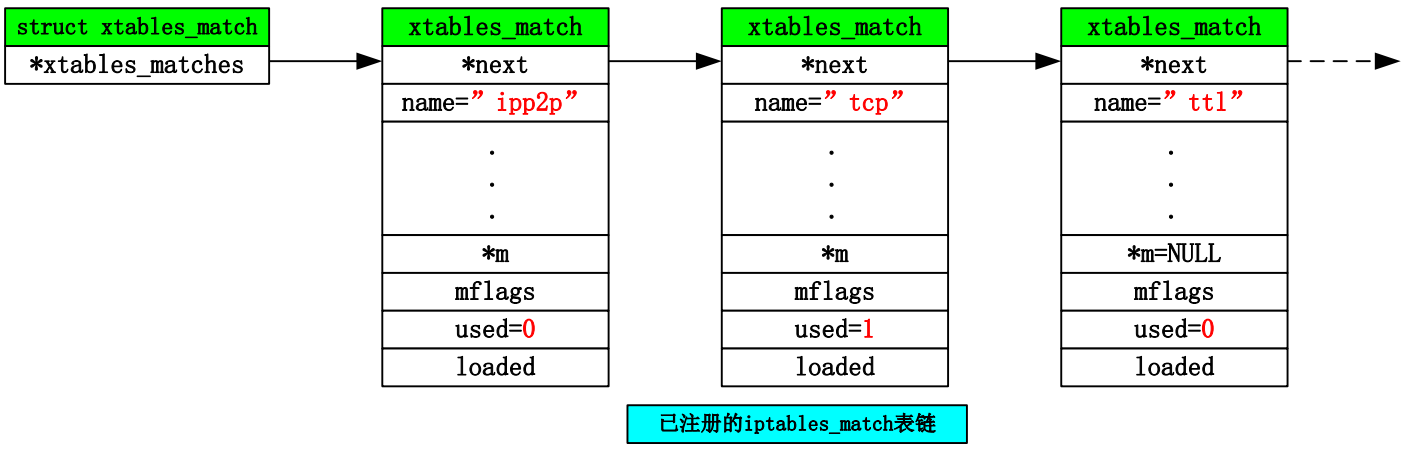

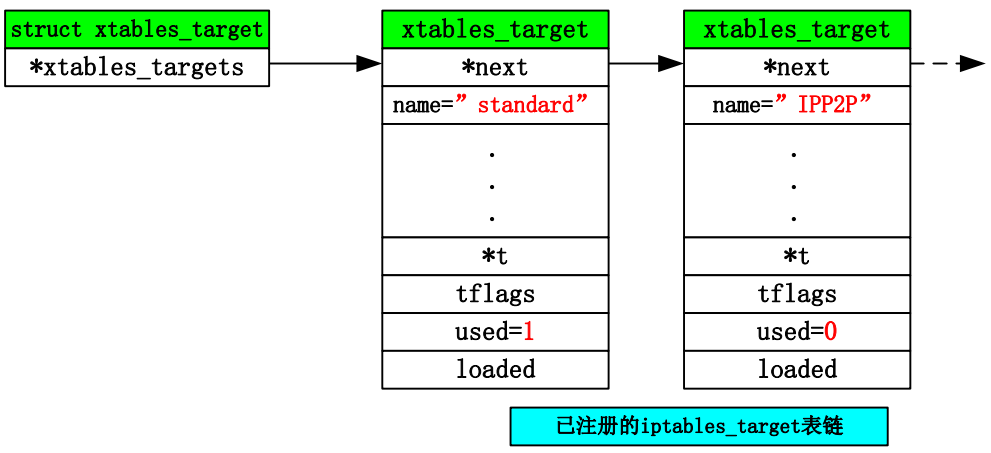

1. 用户态的 iptables 包含许多 match 和 target 资源，它们都以链表的形式进行组织。
2. 可以使用 xtables_register_match()和 xtables_register_target()函数扩展 match 与 target 资源。

一条 iptables 规则是如何组织的

Iptables -t filter -A FORWARD -s 192.168.1.1 -d 192.168.2.1 -i eth0 -o eth1 -p tcp --dport 80 -j ACCEPT

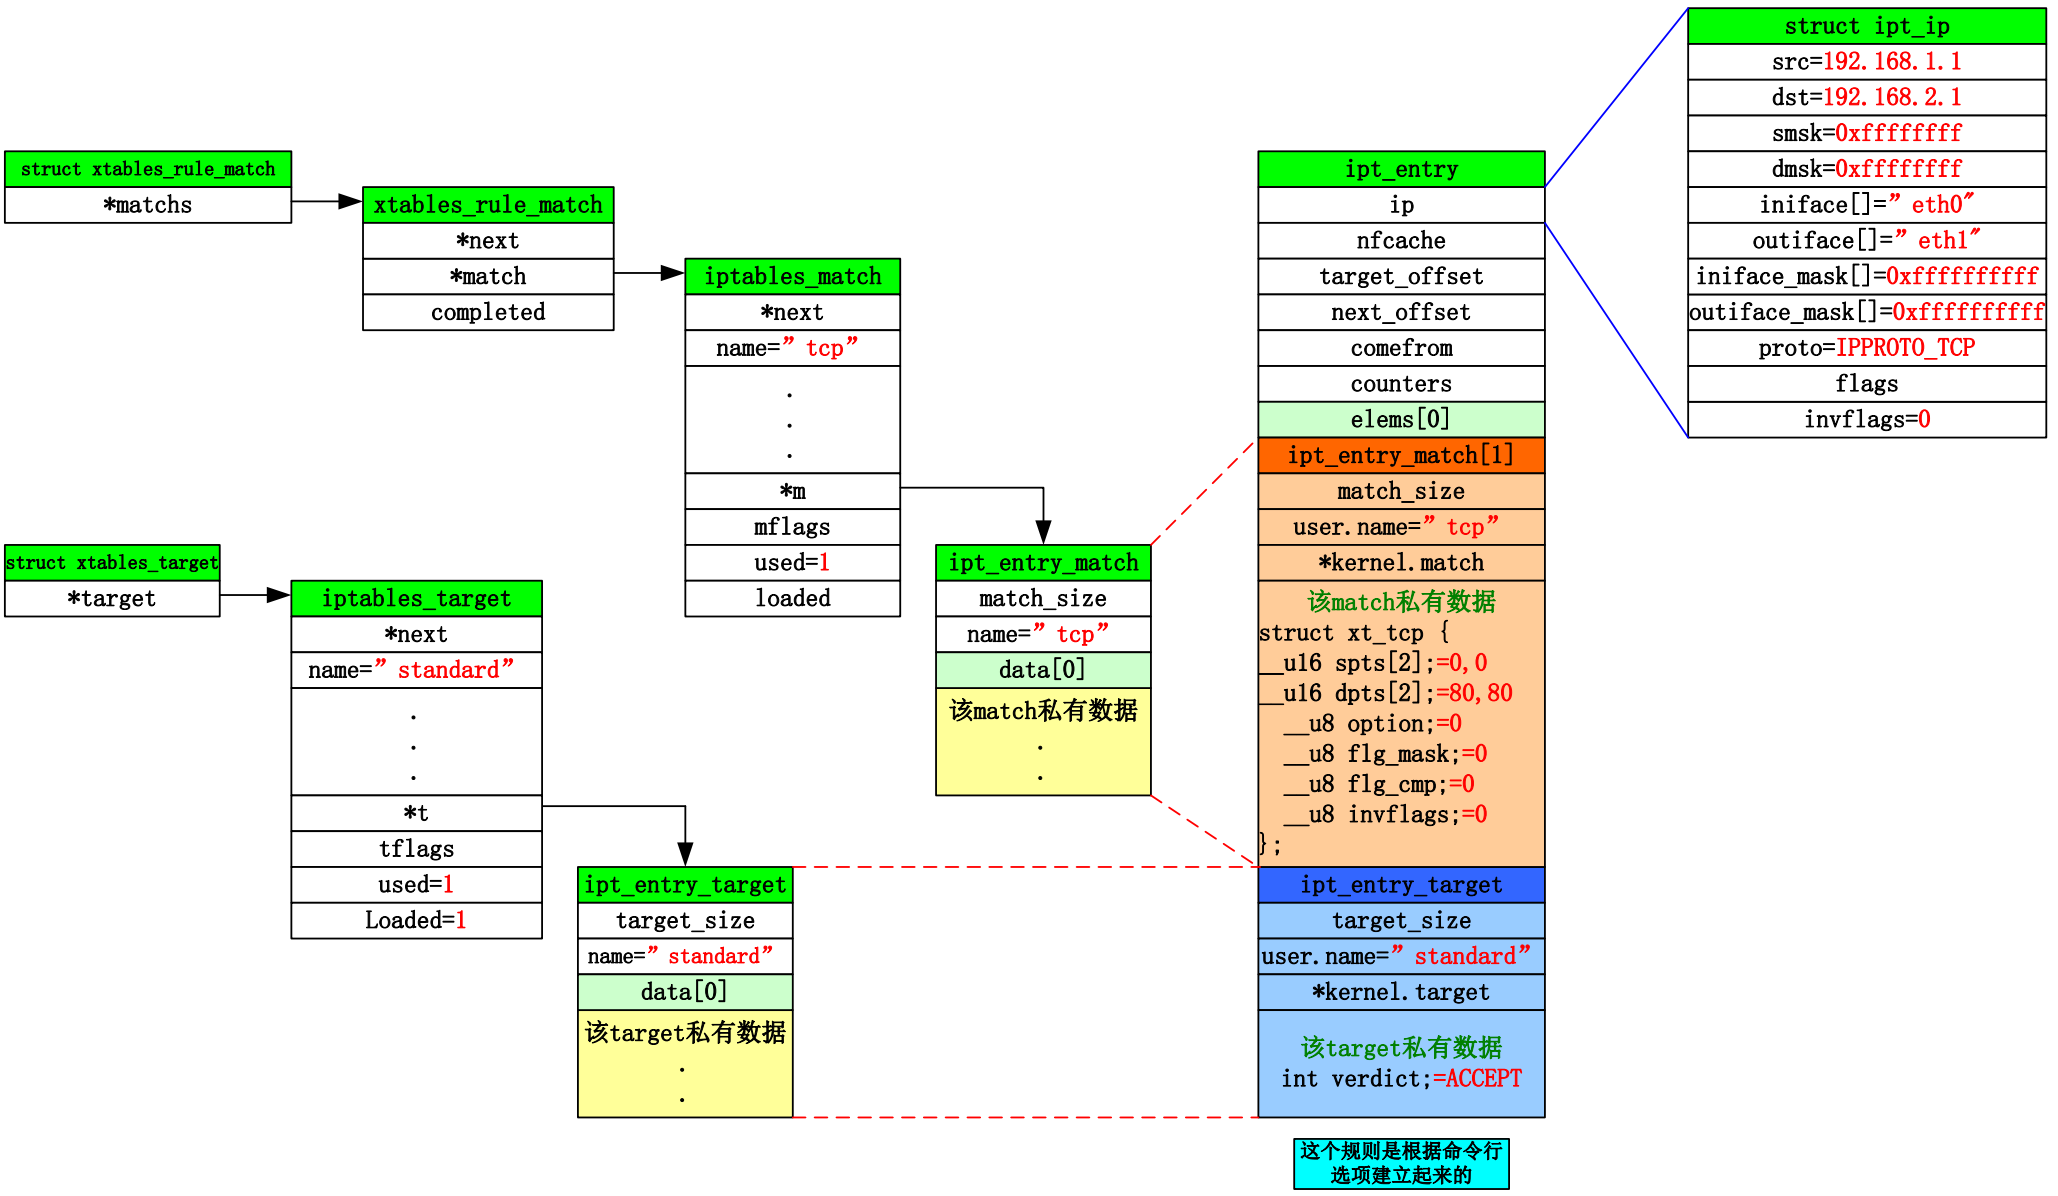

Iptables 对一个表中的规则是如何组织和操作的

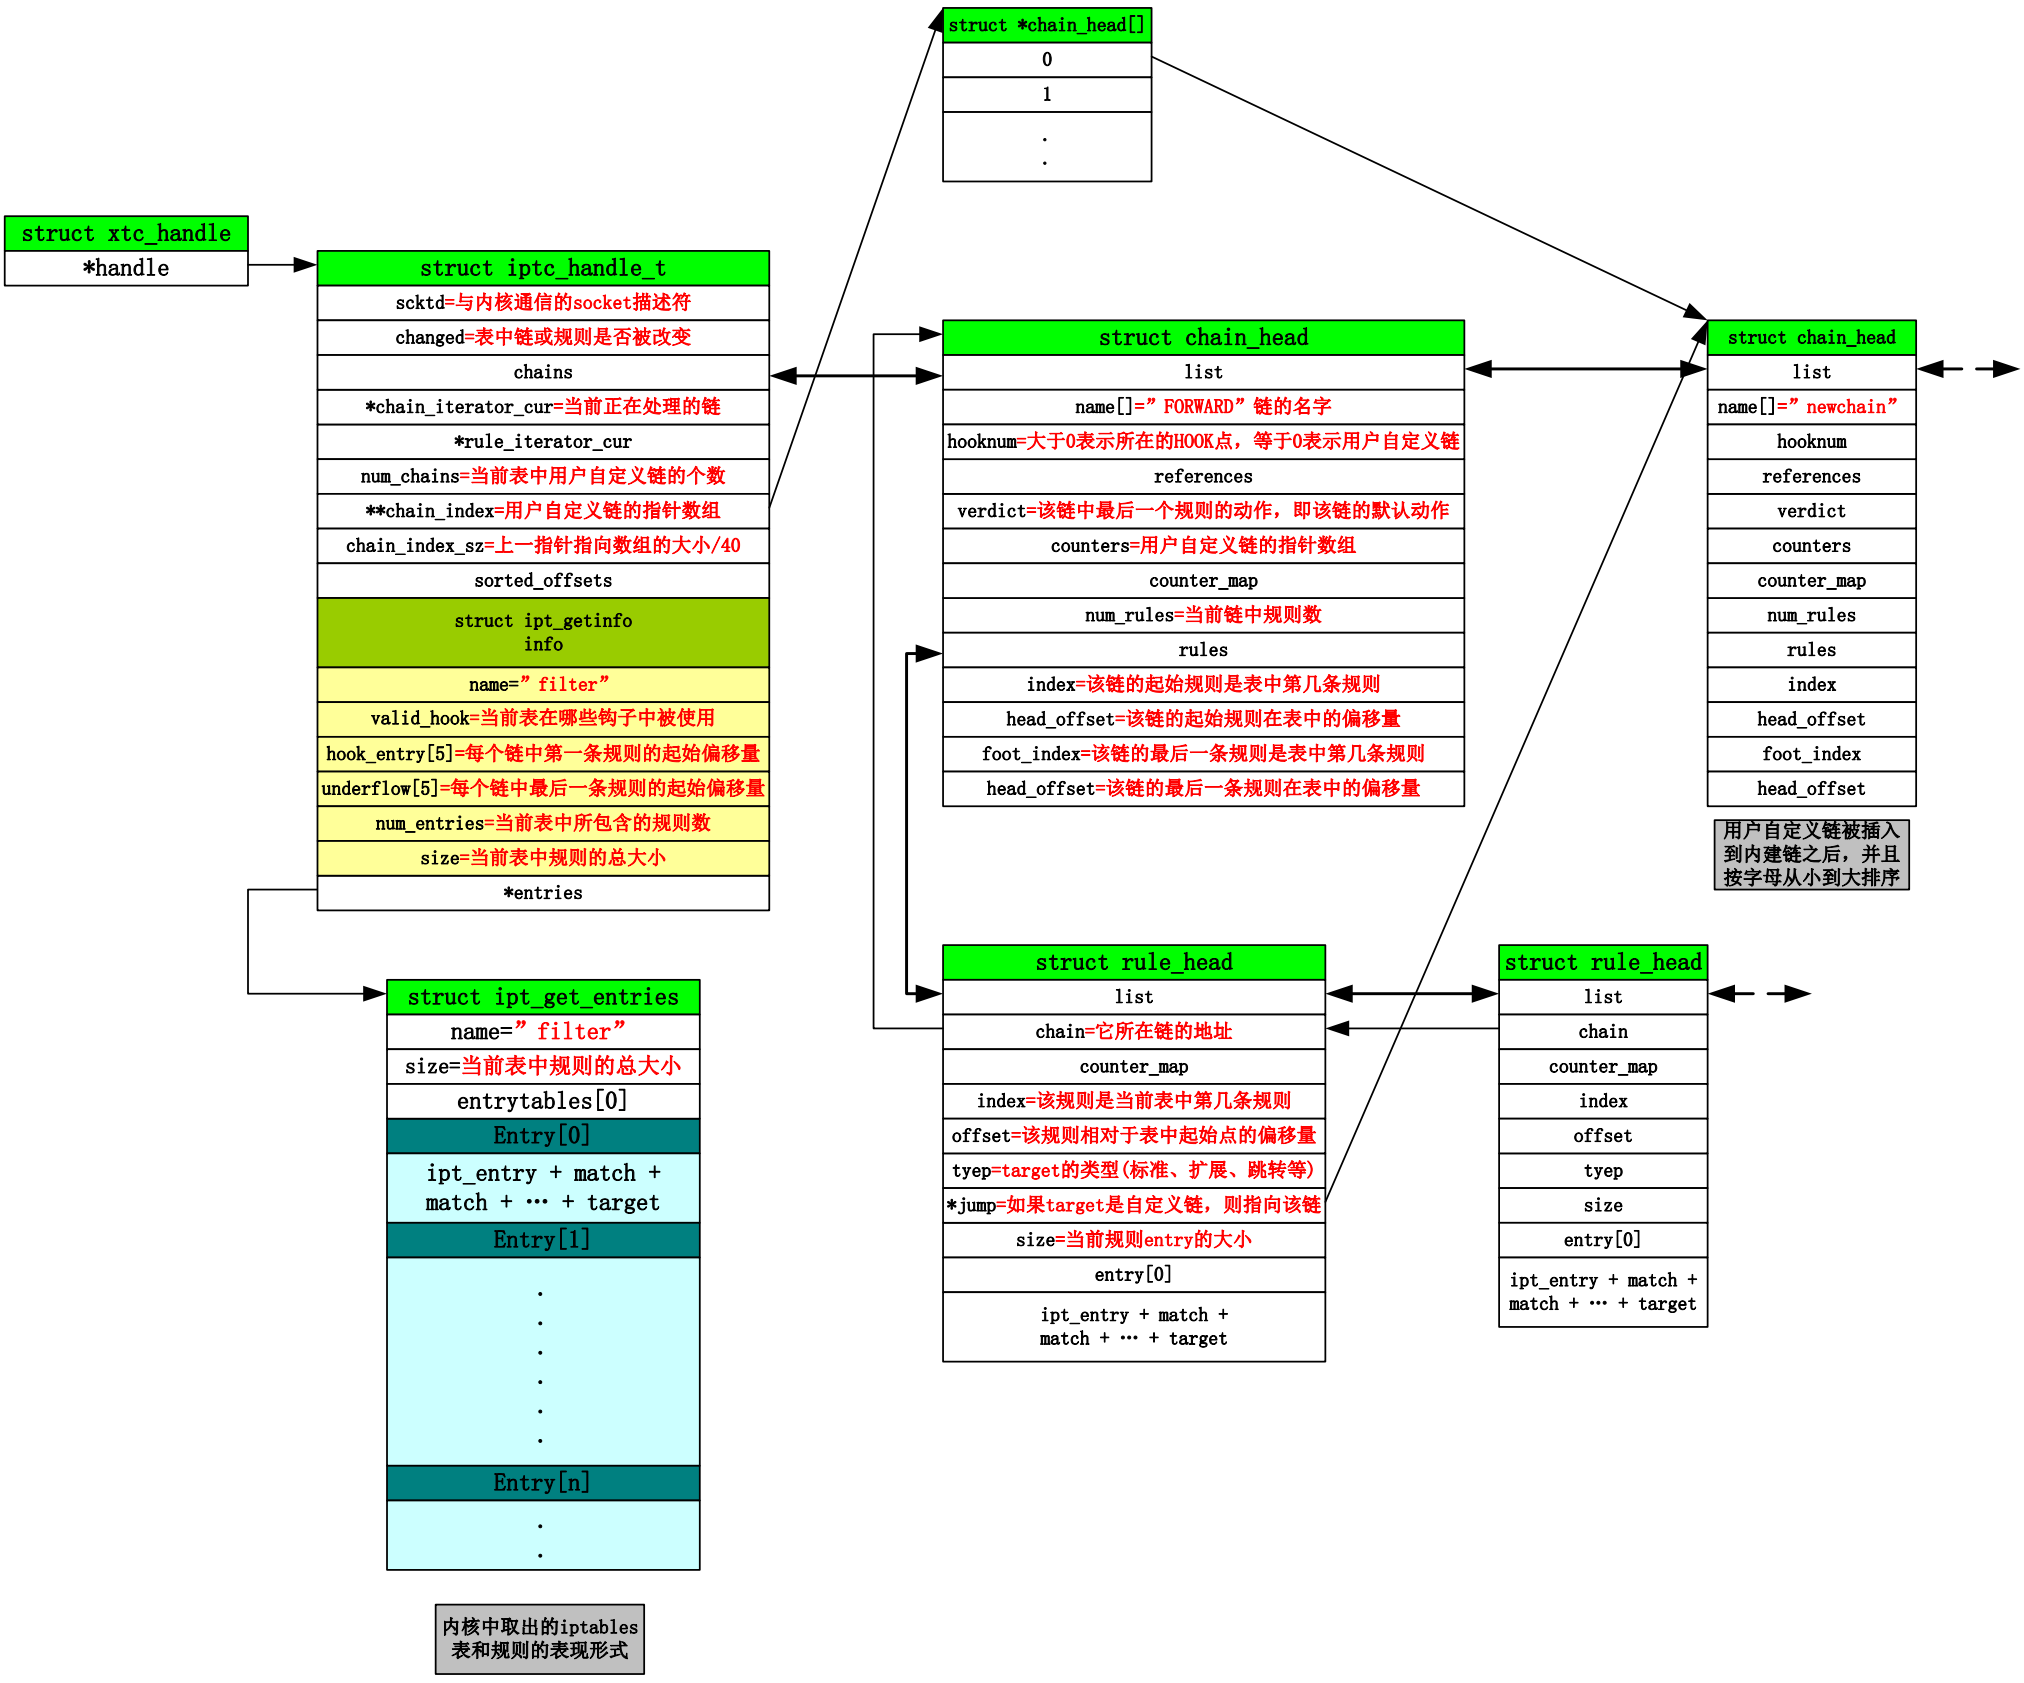

Iptables 如何组织规则与内核通信

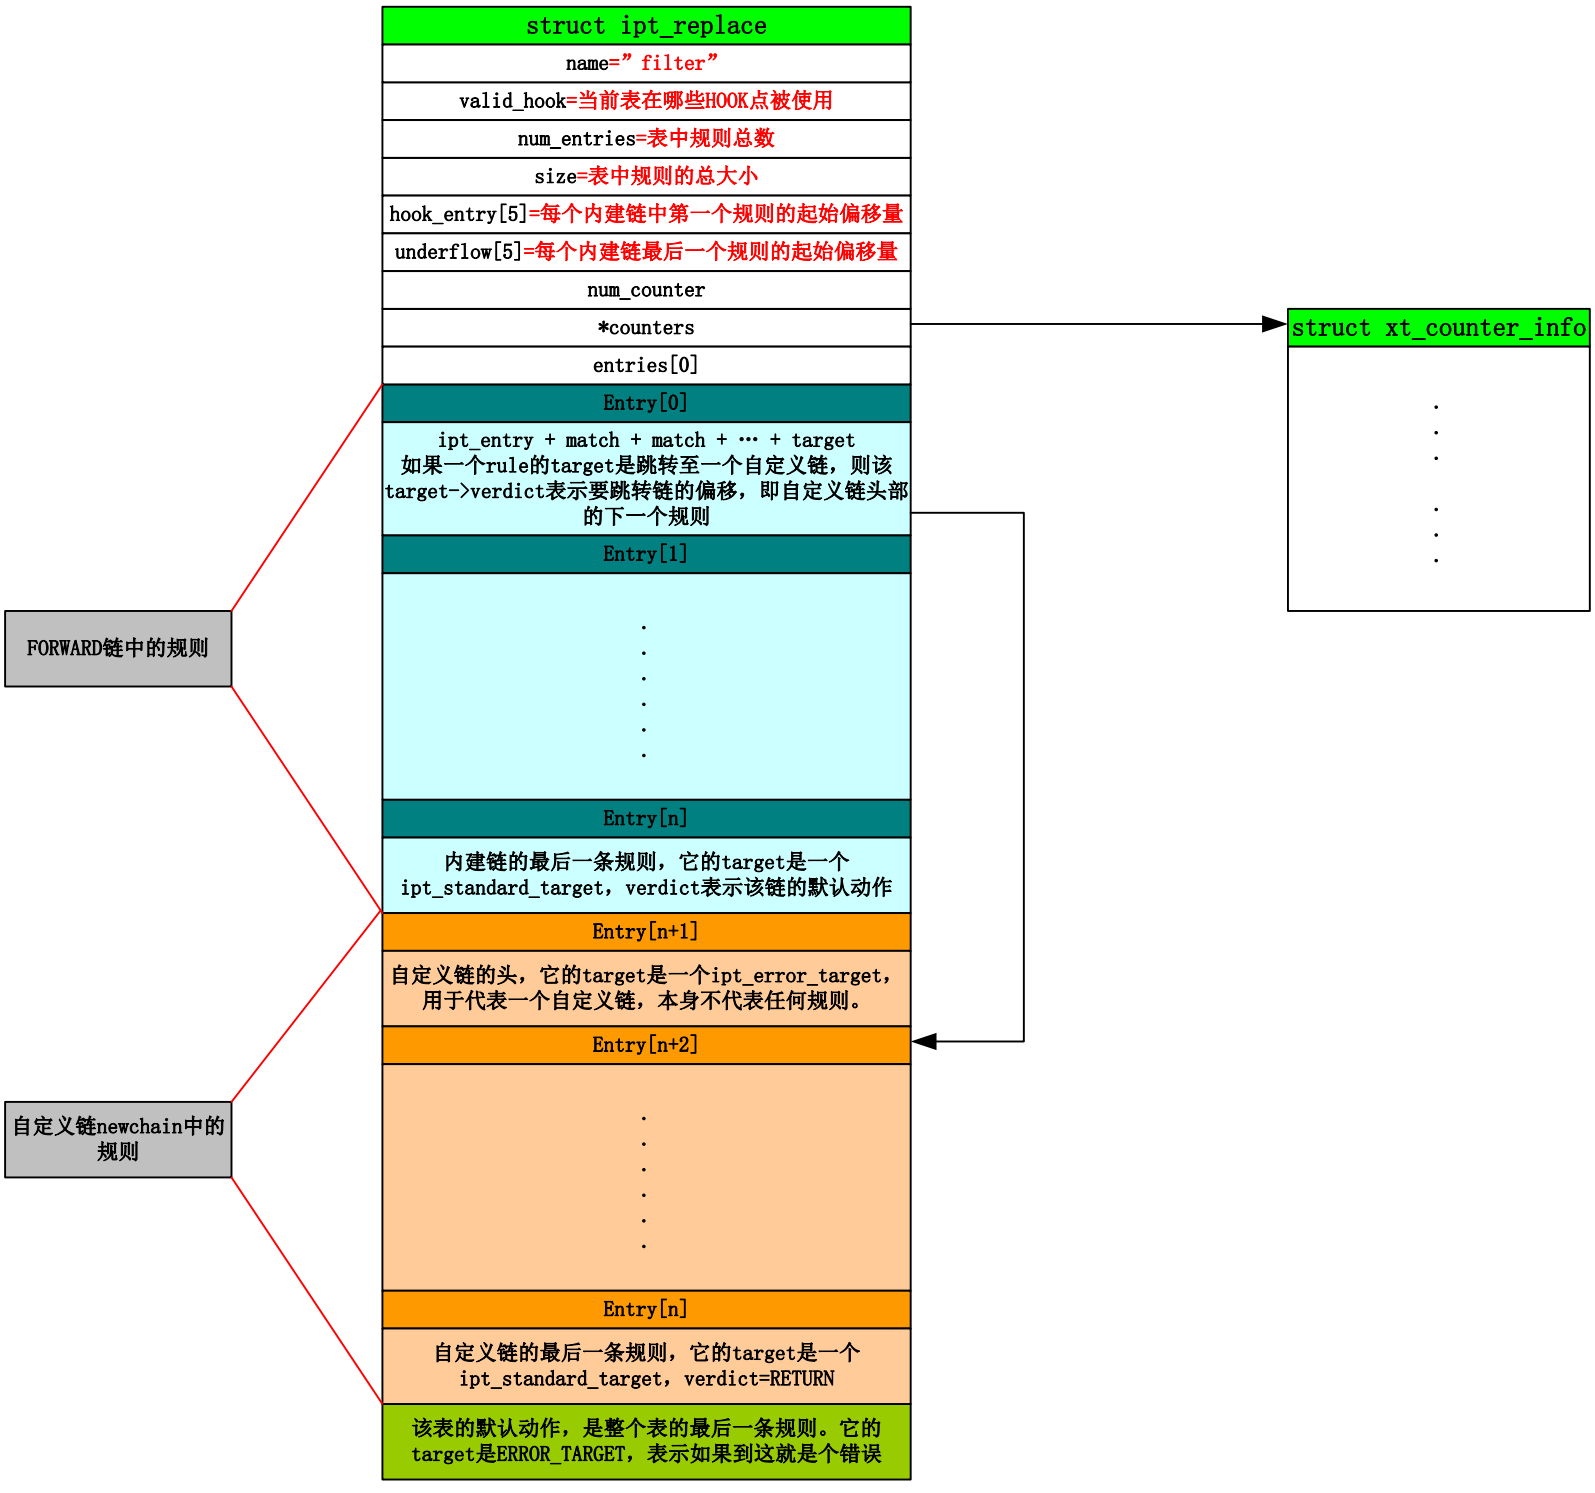

Iptable 的执行流程

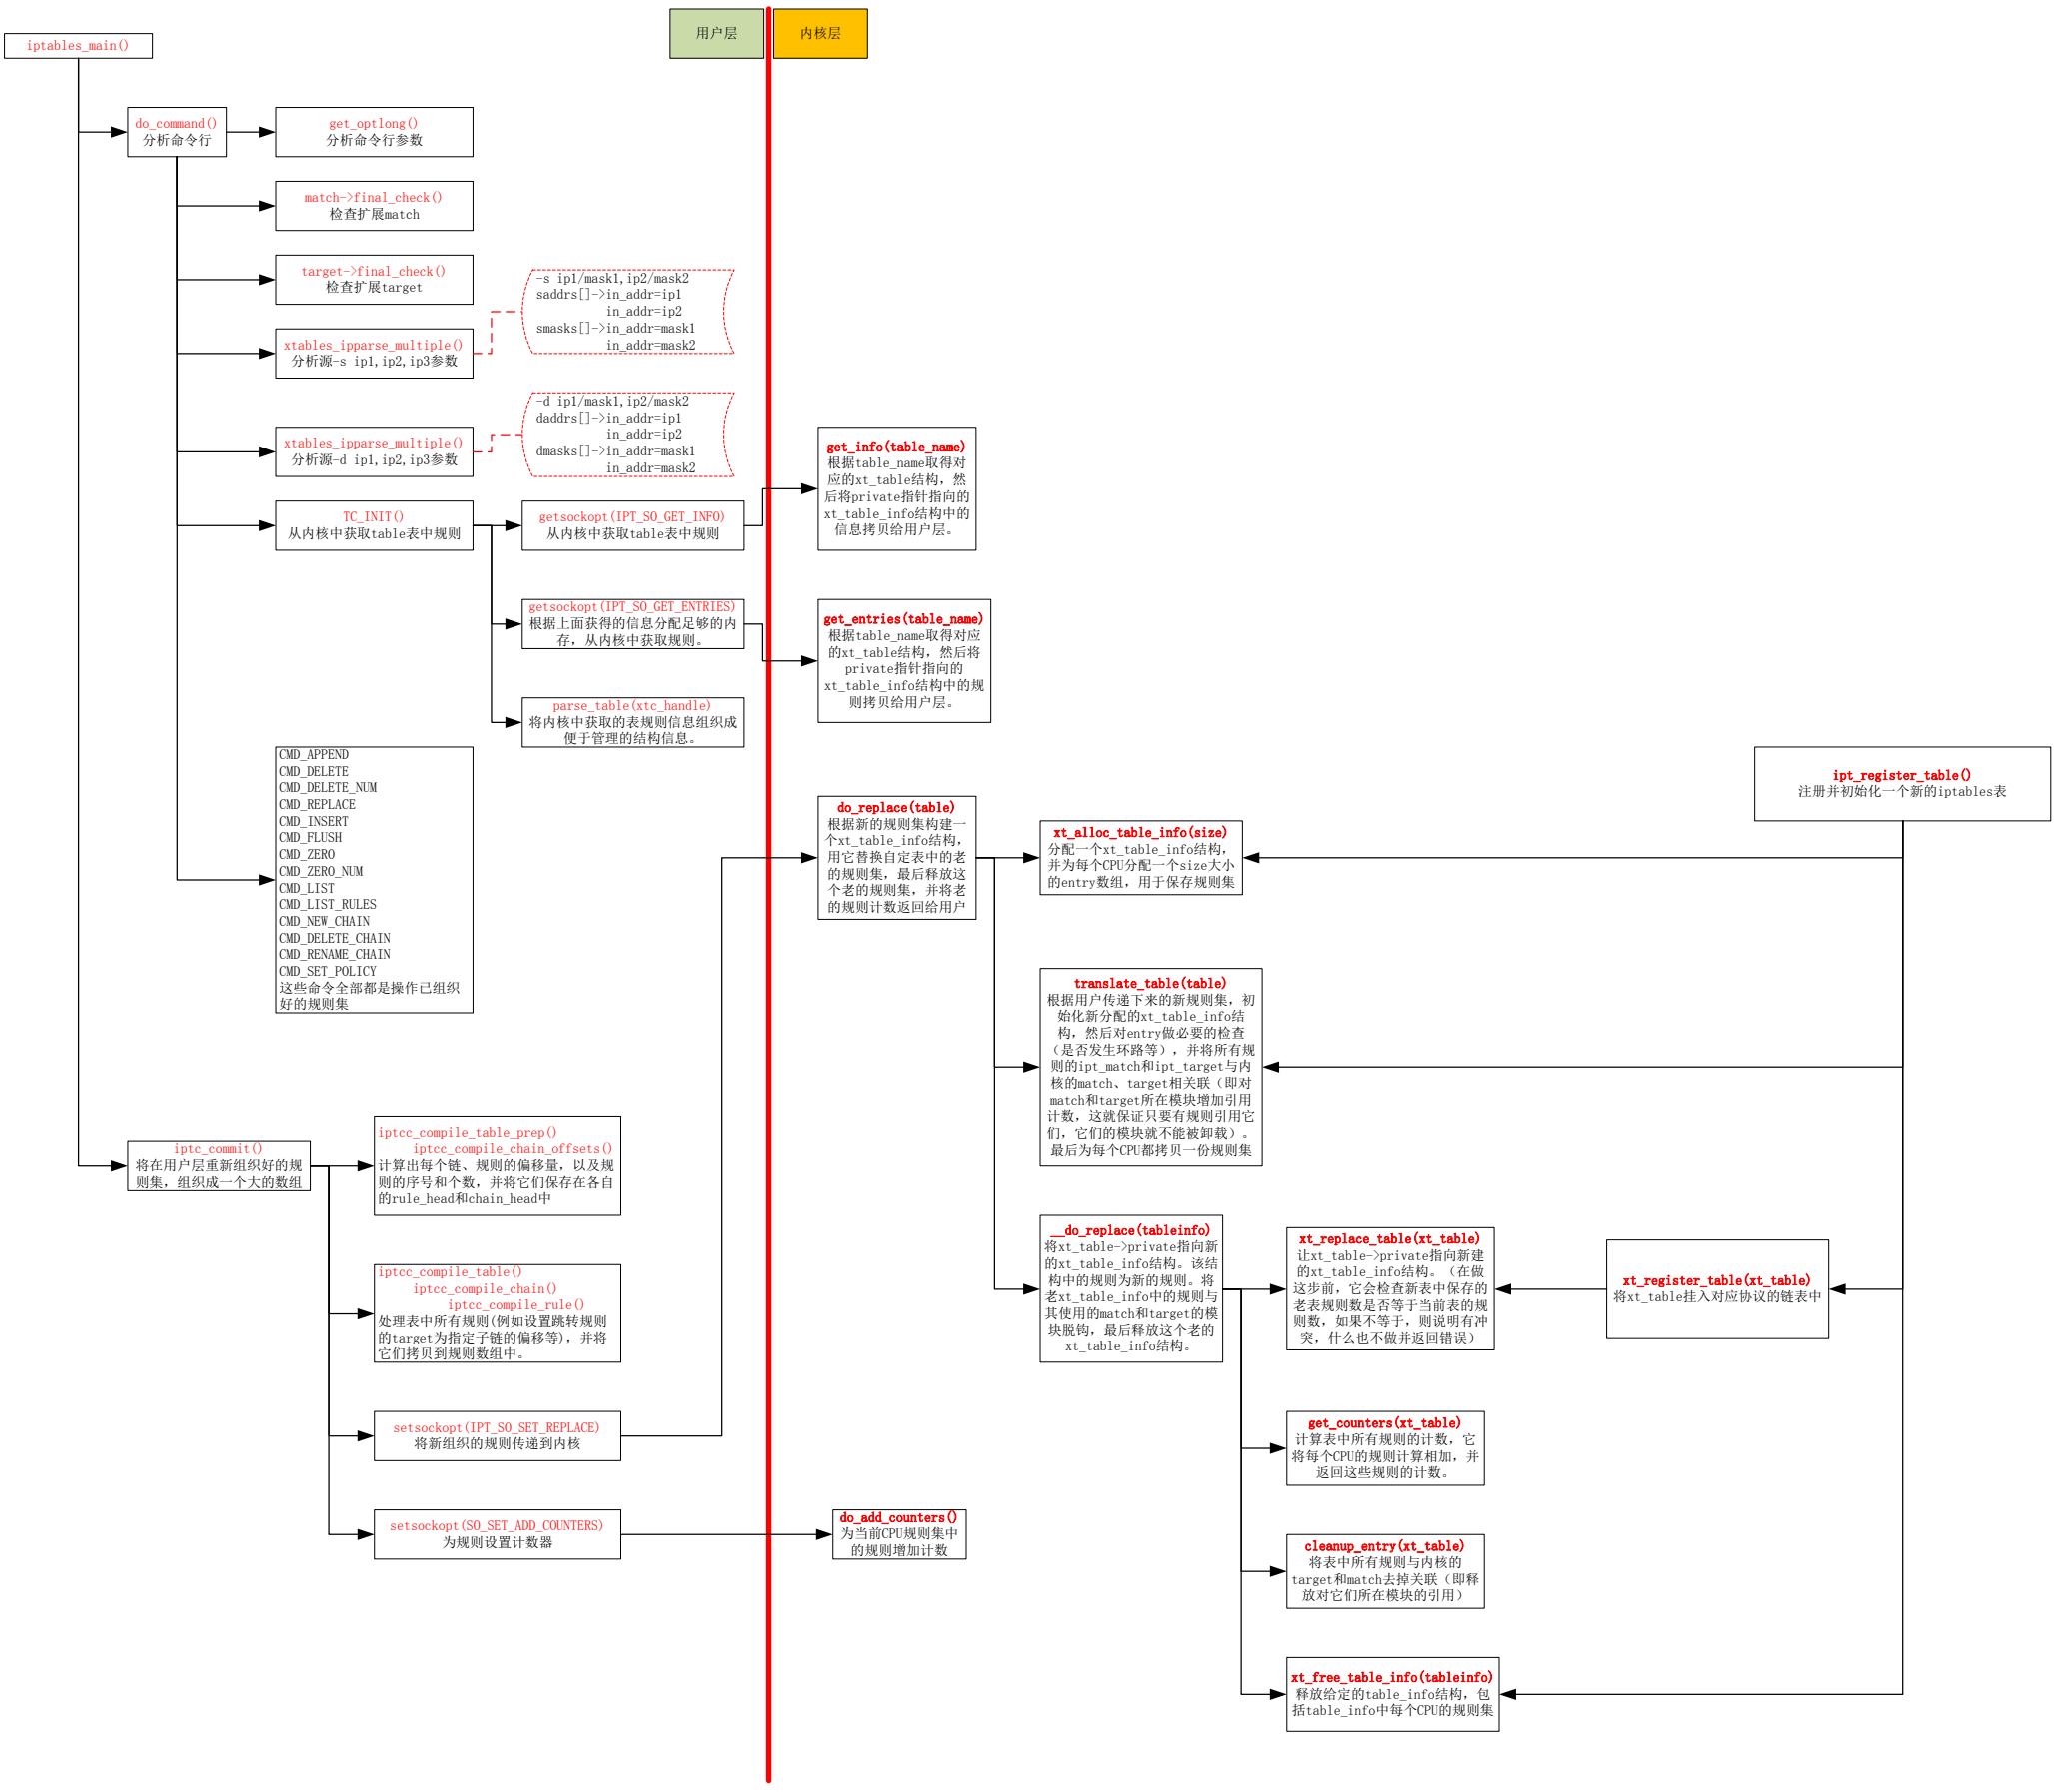

1 Iptables 包含以下 target

- 1.1 IPT_ACCEPT：(struct ipt_standard_target *)target->verdict = -NF_ACCEPT-1 < 0 （ipt_do_table()碰到这个 target 直接返回 NF_ACCEPT）
- 1.2 IPT_DROP：(struct ipt_standard_target *)target->verdict = -NF_DROP-1 < 0 （ipt_do_table()碰到这个 target 直接返回 NF_DROP）
- 1.3 IPT_QUEUE：(struct ipt_standard_target *)target->verdict = -NF_QUEUE-1 < 0 （ipt_do_table()碰到这个 target 直接返回 NF_QUEUE）
- 1.4 IPT_RETURN：(struct ipt_standard_target *)target->verdict = -NF_REPATE-1 < 0 （ipt_do_table()碰到这个 target 特殊处理）
- 1.5 跳转到子链 target：(struct ipt_standard_target *)target->verdict = 要跳转子链的偏移量 > 0 （ipt_do_table()碰到这个 target 会跳转到该子链处理）
- 1.6 IPT_CONTINUE： IPT_CONTINUE = XT_CONTINUE = 0xFFFFFFFF < 0（ipt_do_table()碰到这个 target 会处理下一条规则，这个 target 被扩展 target 使用）
  (它不是一个标准 target，但可被其它扩展 TARGET 用作返回值)
- 1.7 扩展 target：它是 struct xt_entry_target + date[] （ipt_do_table()碰到这个 target 会调用 target->target()处理，并根据返回值做处理。
  扩展 target 可返回 IPT_CONTINUE，或下面 netfilter 定义的值）

2 Netfilter 处理的返回值

- 2.1 NF_DROP
- 2.2 NF_ACCEPT
- 2.3 NF_STOLEN
- 2.4 NF_QUEUE
- 2.5 NF_REPEAT
- 2.6 NF_STOP